

ΠΑΝΕΠΙΣΤΗΜΙΟ ΘΕΣΣΑΛΙΑΣ

ΠΟΛΥΤΕΧΝΙΚΗ ΣΧΟΛΗ

ΤΜΗΜΑ ΗΛΕΚΤΡΟΛΟΓΩΝ ΜΗΧΑΝΙΚΩΝ ΚΑΙ ΜΗΧΑΝΙΚΩΝ ΥΠΟΛΟΓΙΣΤΩΝ

ΔΟΜΙΚΑ ΕΝΗΜΕΡΗ ΙΕΡΑΡΧΙΚΗ ΥΒΡΙΔΙΚΗ ΑΝΑΚΤΗΣΗ ΓΙΑ LONG-CONTEXT ΣΥΣΤΗΜΑΤΑ RAG

Εργασία Ειδικού Θέματος

Νικόλαος Παιδόπουλος

Επιβλέπων: Εμμανουήλ Βάβαλης

Ιούλιος 2026



ΠΑΝΕΠΙΣΤΗΜΙΟ ΘΕΣΣΑΛΙΑΣ

ΠΟΛΥΤΕΧΝΙΚΗ ΣΧΟΛΗ

ΤΜΗΜΑ ΗΛΕΚΤΡΟΛΟΓΩΝ ΜΗΧΑΝΙΚΩΝ ΚΑΙ ΜΗΧΑΝΙΚΩΝ ΥΠΟΛΟΓΙΣΤΩΝ

ΔΟΜΙΚΑ ΕΝΗΜΕΡΗ ΙΕΡΑΡΧΙΚΗ ΥΒΡΙΔΙΚΗ ΑΝΑΚΤΗΣΗ ΓΙΑ LONG-CONTEXT ΣΥΣΤΗΜΑΤΑ RAG

Εργασία Ειδικού Θέματος

Νικόλαος Παιδόπουλος

Επιβλέπων: Εμμανουήλ Βάβαλης

Ιούλιος 2026



UNIVERSITY OF THESSALY

SCHOOL OF ENGINEERING

DEPARTMENT OF ELECTRICAL AND COMPUTER ENGINEERING

STRUCTURE-AWARE HIERARCHICAL HYBRID RETRIEVAL FOR LONG-CONTEXT RAG SYSTEMS

Project

Nikolaos Paidopoulos

Supervisor: Emmanouil Vavalis

July 2026

Εγκρίνεται από την Επιτροπή Εξέτασης:

Επιβλέπων **Εμμανουήλ Βάβαλης**
Professor, Department of Electrical and Computer Engineering, University of Thessaly

Μέλος **George Thanos**
Laboratory Teaching Staff, Department of Electrical and Computer Engineering, University of Thessaly

Μέλος **Elias Houstis**
Emeritus Professor, Department of Electrical and Computer Engineering, University of Thessaly

Ευχαριστίες

Σελίδα με ευχαριστίες του συγγραφέα.

ΥΠΕΥΘΥΝΗ ΔΗΛΩΣΗ ΠΕΡΙ ΑΚΑΔΗΜΑΪΚΗΣ ΔΕΟΝΤΟΛΟΓΙΑΣ ΚΑΙ ΠΝΕΥΜΑΤΙΚΩΝ ΔΙΚΑΙΩΜΑΤΩΝ

«Με πλήρη επίγνωση των συνεπειών του νόμου περί πνευματικών δικαιωμάτων, δηλώνω ρητά ότι η παρούσα διπλωματική εργασία, καθώς και τα ηλεκτρονικά αρχεία και πηγαίοι κώδικες που αναπτύχθηκαν ή τροποποιήθηκαν στα πλαίσια αυτής της εργασίας, αποτελεί αποκλειστικά προϊόν προσωπικής μου εργασίας, δεν προσβάλλει κάθε μορφής δικαιώματα διανοητικής ιδιοκτησίας, προσωπικότητας και προσωπικών δεδομένων τρίτων, δεν περιέχει έργα/εισφορές τρίτων για τα οποία απαιτείται άδεια των δημιουργών/δικαιούχων και δεν είναι προϊόν μερικής ή ολικής αντιγραφής, οι πηγές δε που χρησιμοποιήθηκαν περιορίζονται στις βιβλιογραφικές αναφορές και μόνον και πληρούν τους κανόνες της επιστημονικής παράθεσης. Τα σημεία όπου έχω χρησιμοποιήσει ιδέες, κείμενο, αρχεία ή/και πηγές άλλων συγγραφέων, αναφέρονται ευδιάκριτα στο κείμενο με την κατάλληλη παραπομπή και η σχετική αναφορά περιλαμβάνεται στο τμήμα των βιβλιογραφικών αναφορών με πλήρη περιγραφή. Δηλώνω επίσης ότι τα αποτελέσματα της εργασίας δεν έχουν χρησιμοποιηθεί για την απόκτηση άλλου πτυχίου. Αναλαμβάνω πλήρως, ατομικά και προσωπικά, όλες τις νομικές και διοικητικές συνέπειες που δύναται να προκύψουν στην περίπτωση κατά την οποία αποδειχθεί, διαχρονικά, ότι η εργασία αυτή ή τμήμα της δεν μου ανήκει διότι είναι προϊόν λογοκλοπής».

Ο/Η Δηλών/ούσα

Νικόλαος Παιδόπουλος

Εργασία Ειδικού Θέματος

ΔΟΜΙΚΑ ΕΝΗΜΕΡΗ ΙΕΡΑΡΧΙΚΗ ΥΒΡΙΔΙΚΗ ΑΝΑΚΤΗΣΗ ΓΙΑ LONG-CONTEXT ΣΥΣΤΗΜΑΤΑ RAG

Νικόλαος Παιδόπουλος

Περίληψη

Η παρούσα εργασία πραγματεύεται τον σχεδιασμό, την υλοποίηση και την αξιολόγηση της *SAH-RAG* (*Structure-Aware Hierarchical RAG*), μίας δομικά ενήμερης, ιεραρχικής, υβριδικής αρχιτεκτονικής ανάκτησης πληροφορίας για συστήματα Retrieval-Augmented Generation (RAG) σε long-context σενάρια. Αφετηρία της εργασίας αποτελεί η παρατήρηση ότι, παρότι τα σύγχρονα γλωσσικά μοντέλα υποστηρίζουν ολοένα μεγαλύτερα παράθυρα συμφραζομένων, η αποτελεσματική αξιοποίηση της πληροφορίας παραμένει ανοιχτό ερευνητικό πρόβλημα, και ότι η ποιότητα του μηχανισμού ανάκτησης αποτελεί τον κύριο περιοριστικό παράγοντα ενός συστήματος RAG.

Η προτεινόμενη αρχιτεκτονική οργανώνει τη γνώση σε τρία επίπεδα. Τα έγγραφα αναλύονται από έναν ντετερμινιστικό structural parser, ο οποίος παράγει semantic parents που αντιστοιχούν σε λογικές ενότητες. Κάθε parent διασπάται σε μικρότερα child chunks, τα οποία δεν διαπερνούν ποτέ τα όρια του parent. Η ανάκτηση πραγματοποιείται παράλληλα από dense και learned-sparse αναπαραστάσεις μέσω του μοντέλου BGE-M3, ενώ οι δύο κατατάξεις συντήκονται με Reciprocal Rank Fusion. Τα αποτελέσματα συναθροίζονται σε επίπεδο parent και έπειτα document. Η υλοποίηση χαρακτηρίζεται από ντετερμινιστικότητα και αναπαραγωγιμότητα: κάθε τεχνούργημα έχει content-addressable ταυτότητα, όλες οι σειριοποιήσεις είναι byte-deterministic, και όλα τα στάδια είναι resume-safe μέσω SHA-256 manifests.

Η αξιολόγηση πραγματοποιήθηκε σε δύο φάσεις. Στην πρώτη φάση, μελετήθηκε συστηματικά η απόκριση της αρχιτεκτονικής ως προς τις παραμέτρους που η ίδια εκθέτει, με διαχωρισμό ανάπτυξης/ελέγχου, στατιστικά φυλασσόμενους κανόνες απόφασης και εκτέλεση κλειδωμένου ελέγχου. Η μελέτη κατέληξε σε μία παγωμένη διαμόρφωση λειτουργίας που συμπίπτει με την προεπιλεγμένη, με macro-document Recall@10 ίσο με 0,3961 στον κλειδωμένο διαχωρισμό ελέγχου. Στη δεύτερη φάση, πραγματοποιήθηκε συγκριτική μελέτη έναντι

δύο άλλων αρχιτεκτονικών — του LongRAG και του Metadata-RAG — υπό κοινό πρωτόκολλο αξιολόγησης (ίδιος embedder, ίδια ερωτήματα, ίδιο ground truth, ίδιος evaluator). Η προτεινόμενη αρχιτεκτονική υπερείχε σε όλα τα δεκαοκτώ μέτρα και σε όλα τα τέσσερα σύνολα δεδομένων, με σχετική βελτίωση 28,79% στο κύριο μέτρο έναντι του LongRAG. Το πλεονέκτημα αυξάνεται συστηματικά με τη μείωση του μέσου μήκους των εγγράφων, φτάνοντας το $+351\%$ στο σύνολο με τα συντομότερα έγγραφα.

Η αρχιτεκτονική προορίζεται για ετερογενή long-context σύνολα δεδομένων, με έμφαση στα νομικά κείμενα, και αξιολογήθηκε με σκοπό την ανάδειξη τόσο των δυνατοτήτων όσο και των περιορισμών της προσέγγισης. Η εργασία συνεισφέρει: (α) μία νέα αρχιτεκτονική ανάκτησης που συνδυάζει δομική ενημερότητα, ιεραρχική οργάνωση και υβριδικό σήμα ανάκτησης, (β) ένα κοινό πρωτόκολλο δίκαιης σύγκρισης για αρχιτεκτονικές RAG, (γ) εκτενή εμπειρικά αποτελέσματα απόκρισης παραμέτρων και συγκριτικής απόδοσης σε τέσσερα ετερογενή corpora, και (δ) μία επαναχρησιμοποιήσιμη υποδομή για μελλοντική έρευνα στη διαχείριση πληροφορίας σε LLMs με περιορισμένο context window.

Λέξεις-κλειδιά:

Retrieval-Augmented Generation (RAG), Ανάκτηση Πληροφορίας, Δομικά Ενήμερη Ανάκτηση, Ιεραρχική Οργάνωση, Υβριδική Αναζήτηση, Long-Context, Vector Databases, Embeddings

Εργασία Ειδικού Θέματος

ΔΟΜΙΚΑ ΕΝΗΜΕΡΗ ΙΕΡΑΡΧΙΚΗ ΥΒΡΙΔΙΚΗ ΑΝΑΚΤΗΣΗ ΓΙΑ LONG-CONTEXT ΣΥΣΤΗΜΑΤΑ RAG

Νικόλαος Παιδόπουλος

Περίληψη

This project addresses the design, implementation, and evaluation of *SAH-RAG* (*Structure-Aware Hierarchical RAG*), a structure-aware, hierarchical, hybrid retrieval architecture for Retrieval-Augmented Generation (RAG) systems in long-context scenarios. The work is motivated by the observation that, although modern language models support increasingly large context windows, the effective exploitation of information remains an open research problem, and the quality of the retrieval mechanism is the primary limiting factor of a RAG system.

The proposed architecture organizes knowledge into three levels. Documents are analyzed by a deterministic structural parser that produces semantic parents corresponding to logical units. Each parent is split into smaller child chunks that never cross parent boundaries. Retrieval is performed in parallel from dense and learned-sparse representations via the BGE-M3 model, and the two rankings are fused using Reciprocal Rank Fusion. Results are aggregated at the parent and then document level. The implementation is characterized by determinism and reproducibility: every artifact has a content-addressable identity, all serializations are byte-deterministic, and every stage is resume-safe via SHA-256 manifests.

The evaluation was carried out in two phases. In the first phase, the architecture's parameter response was systematically studied using development/test splits, statistically guarded decision rules, and a locked test execution. The study converged to a frozen operating configuration that coincides with the default one, with a macro-document Recall@10 of 0.3961 on the locked test split. In the second phase, a comparative study was conducted against two other retrieval architectures—LongRAG and Metadata-RAG—under a shared evaluation protocol (same embedder, same queries, same ground truth, same evaluator). The proposed architecture outperformed on all eighteen metrics and all four datasets, achieving a 28.79% relative improvement over LongRAG on the primary metric. The advantage grows systematically

as the mean document length decreases, reaching $+351\%$ on the dataset with the shortest documents.

The architecture is intended for heterogeneous long-context datasets, with emphasis on legal texts, and was evaluated with the aim of highlighting both the capabilities and the limitations of the approach. The work contributes: (a) a novel retrieval architecture that combines structural awareness, hierarchical organization, and hybrid retrieval signal, (b) a shared fair-comparison protocol for RAG architectures, (c) extensive empirical results on parameter response and comparative performance across four heterogeneous corpora, and (d) a reusable infrastructure for future research on information management in LLMs with limited context windows.

Keywords:

Retrieval-Augmented Generation (RAG), Information Retrieval, Structure-Aware Retrieval, Hierarchical Organization, Hybrid Search, Long-Context, Vector Databases, Embeddings

Πίνακας περιεχομένων

Ευχαριστίες **ix**

Περίληψη **xii**

Περίληψη **xiv**

Πίνακας περιεχομένων **xvii**

Κατάλογος σχημάτων **xxv**

Κατάλογος πινάκων **xxvii**

Συντομογραφίες **xxix**

1 Εισαγωγή **1**

1.1 Η Εξέλιξη των Μεγάλων Γλωσσικών Μοντέλων 1

1.2 Το Ερευνητικό Πρόβλημα 2

1.2.1 Περιορισμοί των Μεγάλων Γλωσσικών Μοντέλων 2

1.2.2 Το RAG ως Λύση 4

1.3 Κίνητρα 5

1.3.1 Γιατί το Long-Context Παραμένει Ανοιχτό Ερευνητικό Πρόβλημα . 5

1.3.2 Γιατί τα Νομικά Κείμενα Αποτελούν Κατάλληλο Πεδίο Αξιολόγησης 6

1.4 Συνεισφορά της Εργασίας 7

1.5 Δομή της Εργασίας 8

2 Σχετική Εργασία και Αρχιτεκτονικές Αναφοράς **11**

2.1 Ανάκτηση Πληροφορίας 11

2.2 Dense Retrieval 12

2.3 Retrieval-Augmented Generation 13
2.4 Σύγχρονες Αρχιτεκτονικές Ανάκτησης 15
2.5 Μεθοδολογία Επιλογής Αρχιτεκτονικών Αναφοράς 16
2.6 Αρχιτεκτονικές Αναφοράς και State-of-the-Art 17
2.7 Ερευνητικό Κενό 20

3 Προτεινόμενη Αρχιτεκτονική 23
3.1 Στόχοι Σχεδιασμού 23
3.2 Συνολική Αρχιτεκτονική του Συστήματος 24
3.3 Offline Stage 25
3.3.1 Έγγραφα Εισόδου 26
3.3.2 Ανάλυση Δεδομένων 26
3.3.3 Ιεραρχικός Διαχωρισμός 26
3.3.4 Διανυσματικές Αναπαραστάσεις 26
3.3.5 Βάση Δεδομένων 27
3.4 Online Stage 27
3.4.1 Ερώτημα Χρήστη και Διανυσματικές Αναπαραστάσεις 28
3.4.2 Υβριδική Αναζήτηση, Ανάκτηση και Κατάταξη 28
3.4.3 Ανάκτηση Εγγράφου 28
3.5 Σχεδιαστικές Αποφάσεις 29

4 Υλοποίηση 33
4.1 Δεδομένα και Canonical Μοντέλο 33
4.1.1 Σύνολα Δεδομένων 34
4.1.2 Canonical Envelope 35
4.2 Ανάλυση Δομημένων Εγγράφων 35
4.2.1 Στόχοι 35
4.2.2 Εναλλακτικές Στρατηγικές 36
4.2.3 Επιλεγμένη Υλοποίηση: DeterministicStructuralParser 37
4.2.4 Μοντέλο SemanticParent 38
4.2.5 Invariants 38
4.3 Ιεραρχικός Διαχωρισμός 39
4.3.1 Στόχοι 39

4.3.2 Εναλλακτικές Στρατηγικές 39
4.3.3 Επιλεγμένη Υλοποίηση: HierarchicalChildChunker 39
4.3.4 Παράμετροι Διαμόρφωσης 40
4.3.5 Αφαίρεση Tokenizer 41
4.3.6 Μοντέλο ChildChunk και Invariants 41
4.4 Διανυσματικές Αναπαραστάσεις 42
4.4.1 Απαιτήσεις 42
4.4.2 Επιλογή Μοντέλου: BGE-M3 42
4.4.3 Διαμόρφωση Embedding 43
4.4.4 Μοντέλα Δεδομένων 44
4.4.5 Παραγωγή και Αποθήκευση Shards 44
4.5 Διανυσματική Βάση Δεδομένων 45
4.5.1 Απαιτήσεις 45
4.5.2 Επιλογή: Qdrant 45
4.5.3 Δομή Collections 45
4.5.4 Ντετερμινιστικά Point IDs 46
4.5.5 Payload 46
4.5.6 Εισαγωγή 46
4.6 Pipeline Ανάκτησης 46
4.6.1 Υβριδική Αναζήτηση 46
4.6.2 Fusion με Reciprocal Rank Fusion 47
4.6.3 Συνάθροιση σε Parents 47
4.6.4 Ανάλυση σε Documents 47
4.7 Ντετερμινιστικότητα και Αναπαραγωγιμότητα 48
4.8 Σύνοψη Υποσυστημάτων 49

5 Πειραματική Αξιολόγηση I: Βέλτιστη Διαμόρφωση Λειτουργίας 51
5.1 Κίνητρα και Σκοπός 51
5.1.1 Γιατί δεν αρκεί μία grid search 51
5.1.2 Σκοπός 52
5.2 Μεθοδολογία 53
5.2.1 Αρχές Σχεδιασμού 53
5.2.2 Εκτιθέμενος Χώρος Παραμέτρων 53

5.2.3 Διαχωρισμός Ανάπτυξης/Ελέγχου 54
5.2.4 Κανόνες Απόφασης 55
5.3 Πειραματική Διαδικασία 56
5.4 Αποτελέσματα 58
5.4.1 Καμπύλες Απόκρισης 58
5.4.2 Κλασματικός παραγοντικός σχεδιασμός και Επιβεβαιωτικά Αποτελέσματα 59
5.4.3 Επιλογή Διαμόρφωσης 59
5.4.4 Κλειδωμένος Έλεγχος 60
5.4.5 Αποτελέσματα Υποθέσεων 60
5.5 Συζήτηση 61
5.5.1 H1: γιατί δεν εμφανίστηκε plateau 61
5.5.2 H2: μονότονο αλλά κορεσμένο 61
5.5.3 H3: το βάθος υποψηφίων κορεσμένο νωρίς 62
5.5.4 H5: το υβριδικό RRF κυριαρχεί 62
5.5.5 Σταθερότητα επιλογής 62
5.6 Περιορισμοί 62
5.6.1 Εύρος δεδομένων 62
5.6.2 Μη ελέγξιμες υποθέσεις 63
5.6.3 Bootstrap και πολλαπλές συγκρίσεις 63
5.6.4 Η αναζήτηση δεν είναι καθολική 63
5.6.5 Ελεγχόμενες προσαρμογές 63
5.7 Σύνοψη 63

6 Πειραματική Αξιολόγηση II: Συγκριτική Μελέτη 67
6.1 Πρωτόκολλο Δίκαιης Σύγκρισης 67
6.2 Συμμετέχουσες Αρχιτεκτονικές 68
6.2.1 SAH-RAG (Project-Owned Reference) 69
6.2.2 LongRAG (Controlled Adaptation) 69
6.2.3 Metadata-RAG (Paper-Derived Comparator) 69
6.2.4 PathRAG (Structural Comparator, μερική εκτέλεση) 69
6.3 Κύρια Σύγκριση: SAH-RAG vs LongRAG 70
6.3.1 Κύριο Μέτρο 70

6.3.2 Πλήρης Σύγκριση σε Όλα τα Μέτρα 70
6.3.3 Σύγκριση ανά Σύνολο Δεδομένων 70
6.4 Ερμηνεία των Αποτελεσμάτων 71
6.4.1 Η Υπόθεση της Κοκκομετρίας 71
6.4.2 Το CLERC ως Ακραία Περίπτωση 72
6.4.3 Το CUAD ως Περίπτωση Σύγκλισης 73
6.4.4 Το LaRA ως Περίπτωση Σύγκλισης 73
6.4.5 Σύνοψη Ερμηνείας 73
6.5 Σύγκριση με το Metadata-RAG 73
6.6 Περιορισμοί και Απειλές Εγκυρότητας 75
6.6.1 Εύρος Δεδομένων 75
6.6.2 Στατιστική Αβεβαιότητα 75
6.6.3 Ακρίβεια Αναπαράστασης 75
6.6.4 Επίπεδο Αξιολόγησης 75
6.6.5 Ελεγχόμενες Προσαρμογές 75
6.6.6 Tie-breaking 76
6.7 Σύνοψη 76

7 Μελλοντική Εργασία **77**
7.1 Βελτιώσεις Εντός του Τρέχοντος Πλαισίου 77
7.1.1 Συστηματική Απομόνωση Συστατικών (Ablation Study) 77
7.1.2 Επέκταση του Διαχωρισμού Δεδομένων 78
7.1.3 Επέκταση σε Εναπομείναντα Σύνολα Δεδομένων 78
7.1.4 Ενσωμάτωση Σταδίου Παραγωγής 78
7.1.5 Βελτιστοποίηση της Αποδοτικότητας 79
7.1.6 Επέκταση σε Πολυγλωσσικά και Πολυτροπικά Corpora 79
7.1.7 Επέκταση σε Δυναμικά Corpora 80
7.2 Επέκταση σε Μεγάλης Κλίμακας Δομημένα Corpora 80
7.2.1 Υποψήφια Πεδία Εφαρμογής 80
7.2.2 Προκλήσεις Κλίμακας 81
7.2.3 Ερευνητικά Ερωτήματα 81
7.3 Διαχείριση Πληροφορίας σε Γλωσσικά Μοντέλα Μειωμένου Context Window 82
7.3.1 Το Ερευνητικό Πρόβλημα 82

7.3.2 Προτεινόμενη Αρχιτεκτονική 83
7.3.3 Ερευνητικά Ερωτήματα 83
7.3.4 Αναμενόμενη Συνεισφορά 84
7.3.5 Σχέση με την Παρούσα Εργασία 84
7.4 Άλλες Κατευθύνσεις 85
7.4.1 Επέκταση των Δυνατοτήτων Ανάκτησης 85
7.4.2 Αξιολόγηση με Ανθρώπινους Χρήστες 85
7.4.3 Ενοποίηση με Βάσεις Δεδομένων Γνώσης 86
7.4.4 Εφαρμογή σε Πραγματικά Συστήματα 86
7.5 Σύνοψη 87

8 Συμπεράσματα **89**
8.1 Σύνοψη της Εργασίας 89
8.2 Κύρια Ευρήματα 90
8.2.1 Βέλτιστη Διαμόρφωση Λειτουργίας 90
8.2.2 Συγκριτική Αξιολόγηση 91
8.3 Συνεισφορές της Εργασίας 91
8.4 Περιορισμοί 92
8.5 Αναστοχασμός πάνω στα Αποτελέσματα 93
8.6 Προς το Μέλλον 94
8.7 Καταληκτική Παρατήρηση 95

Βιβλιογραφία **97**

ΠΑΡΑΡΤΗΜΑΤΑ **107**

Α Αρχιτεκτονικές που δεν Εκτελέστηκαν **109**
Α.1 Σύνοψη Αποκλεισμών 109
Α.2 Αναλυτική Τεκμηρίωση 109
Α.2.1 HippoRAG 2 109
Α.2.2 RAPTOR 110
Α.2.3 LightRAG 110
Α.2.4 DISRetrieval 110
Α.2.5 HiKEY 110

A.3 Μεθοδολογική Σημείωση 111

Β Πόροι, Δεδομένα και Κώδικας **113**

Β.1 Σύνολα Δεδομένων 113

Β.2 Κώδικας και Τεκμηρίωση 114

Β.3 Αναπαραγωγιμότητα 114

Κατάλογος σχημάτων

3.1 Συνολική αρχιτεκτονική του προτεινόμενου συστήματος. 25
3.2 Ροή επεξεργασίας του offline σταδίου της προτεινόμενης αρχιτεκτονικής. . 27
3.3 Ροή του online σταδίου της προτεινόμενης αρχιτεκτονικής. 29

Κατάλογος πινάκων

2.1 Συνοπτική σύγκριση των αρχιτεκτονικών αναφοράς. 21

4.1 Συνοπτικά στατιστικά των τεσσάρων συνόλων δεδομένων. Τα tokens είναι whitespace-based. 34

4.2 Σύνοψη υποσυστημάτων της αρχιτεκτονικής. 49

5.1 Εκτιθέμενες παράμετροι και τα πεδία τιμών τους. 53

5.2 Παγωμένες παράμετροι (αρχιτεκτονικά καθοριστικές ή συμβολαίου). . . . 54

5.3 Διαχωρισμός ανάπτυξης/ελέγχου ανά σύνολο δεδομένων. 55

5.4 Κανόνες απόφασης της μελέτης. 55

5.5 Μονοπαραγοντικές καμπύλες απόκρισης (macro Recall@10, 10% δείγμα ανάπτυξης). 58

5.6 Επιβεβαιωτική αξιολόγηση (πλήρης διαχωρισμός ανάπτυξης, macro R@10 στα τέσσερα σύνολα). 59

5.7 Κλειδωμένος έλεγχος στη παγωμένη διαμόρφωση. 60

5.8 Αποφάσεις υποθέσεων. 65

6.1 Κοινά συστατικά του πρωτοκόλλου σύγκρισης. 68

6.2 Κύριο μέτρο σύγκρισης: macro document Recall@10. 70

6.3 Σύγκριση σε όλα τα μέτρα (macro-averaged στα τέσσερα σύνολα). 71

6.4 Σύγκριση ανά σύνολο δεδομένων (document Recall@10). 72

6.5 Κοκκομετρία ανάκτησης και αποτελέσματα. 72

6.6 Σύγκριση τριών αρχιτεκτονικών (macro document Recall@10). 74

A.1 Αρχιτεκτονικές που δεν εκτελέστηκαν και αιτιολόγηση. 112

Συντομογραφίες

ANN	Approximate Nearest Neighbor
API	Application Programming Interface
BGE-M3	BAAI General Embedding M3
BM25	Best Matching 25
CUAD	Contract Understanding Atticus Dataset
CPU	Central Processing Unit
DPR	Dense Passage Retrieval
FP16	16-bit Floating Point
FP32	32-bit Floating Point
GPU	Graphics Processing Unit
ID	Identifier
IR	Information Retrieval
JSON	JavaScript Object Notation
JSONL	JSON Lines
LaRA	Long-context Retrieval Assessment
LLM	Large Language Model
MRR	Mean Reciprocal Rank
nDCG	normalized Discounted Cumulative Gain
NLP	Natural Language Processing
RAG	Retrieval-Augmented Generation
RRF	Reciprocal Rank Fusion
RST	Rhetorical Structure Theory
SHA	Secure Hash Algorithm
URL	Uniform Resource Locator
YAML	YAML Ain’t Markup Language

βλπ	βλέπε
κ.λπ.	και λοιπά
κ.ο.κ	και ούτω καθεξής
SAH-RAG	Structure-Aware Hierarchical RAG

Κεφάλαιο 1

Εισαγωγή

1.1 Η Εξέλιξη των Μεγάλων Γλωσσικών Μοντέλων

Η εξέλιξη των Μεγάλων Γλωσσικών Μοντέλων (Large Language Models – LLMs) έχει μεταβάλει ουσιαστικά τον τρόπο με τον οποίο προσεγγίζονται σήμερα τα προβλήματα της Επεξεργασίας Φυσικής Γλώσσας (Natural Language Processing – NLP). Μέχρι πριν από λίγα χρόνια, οι περισσότερες εφαρμογές απαιτούσαν την ανάπτυξη διαφορετικών μοντέλων για κάθε επιμέρους εργασία. Σήμερα, ένα μόνο μοντέλο μπορεί να χρησιμοποιηθεί για ένα ευρύ φάσμα εφαρμογών, από την παραγωγή κειμένου και τη μετάφραση μέχρι την περίληψη εγγράφων, την απάντηση ερωτήσεων και την υποστήριξη λήψης αποφάσεων.

Η αλλαγή αυτή δεν οφείλεται αποκλειστικά στην αύξηση της υπολογιστικής ισχύος ή στη διαθεσιμότητα μεγαλύτερων συνόλων δεδομένων. Σημαντικό ρόλο διαδραμάτισε η εμφάνιση της αρχιτεκτονικής *Transformer*, η οποία πρότεινε έναν διαφορετικό τρόπο μοντελοποίησης των σχέσεων μεταξύ των λέξεων μέσα σε ένα κείμενο, αξιοποιώντας τον μηχανισμό *self-attention* αντί των αναδρομικών νευρωνικών δικτύων που κυριαρχούσαν μέχρι τότε [1]. Η προσέγγιση αυτή επέτρεψε την αποτελεσματικότερη εκπαίδευση μοντέλων πολύ μεγαλύτερης κλίμακας και άνοιξε τον δρόμο για την ανάπτυξη συστημάτων όπως το BERT και αργότερα η οικογένεια GPT, τα οποία απέδειξαν ότι ένα προεκπαιδευμένο γλωσσικό μοντέλο μπορεί να μεταφερθεί με επιτυχία σε πλήθος διαφορετικών εργασιών χωρίς να απαιτείται εκ νέου σχεδιασμός της αρχιτεκτονικής του [2, 3]. Η μετάβαση αυτή άλλαξε σταδιακά και τον τρόπο με τον οποίο αντιμετωπίζεται η ίδια η έννοια της γλωσσικής κατανόησης: αντί να αναπτύσσονται πολλά εξειδικευμένα μοντέλα, η έρευνα στράφηκε προς τη δημιουργία γενικών μοντέλων που μπορούν να προσαρμόζονται δυναμικά στις απαιτήσεις κάθε προβλήματος.

Δεν άργησαν να εμφανιστούν και οι πρώτες εφαρμογές μεγάλης κλίμακας. Τα LLMs ενσωματώθηκαν σε συστήματα αναζήτησης πληροφορίας, βοηθούς προγραμματισμού, πλατφόρμες παραγωγής περιεχομένου και εργαλεία υποστήριξης επιστημονικής έρευνας. Αυτό οδήγησε την χρήση τους σε εξειδικευμένα πεδία, όπως η ιατρική, η οικονομία και η νομική επιστήμη, όπου η δυνατότητα κατανόησης και παραγωγής φυσικής γλώσσας μπορεί να μειώσει σημαντικά τον χρόνο επεξεργασίας μεγάλου όγκου πληροφοριών.

Η συνεχής αυτή εξέλιξη δημιούργησε εύλογα την εντύπωση ότι τα σύγχρονα γλωσσικά μοντέλα μπορούν να αποτελέσουν μια καθολική λύση για κάθε πρόβλημα που σχετίζεται με τη γνώση και τη γλώσσα. Στην πράξη όμως, η εικόνα είναι πιο σύνθετη. Παρότι οι δυνατότητές τους είναι ιδιαίτερα εντυπωσιακές, εξακολουθούν να εμφανίζουν περιορισμούς που επηρεάζουν την αξιοπιστία τους σε απαιτητικά περιβάλλοντα. Οι περιορισμοί αυτοί αποτελούν το βασικό κίνητρο για την ανάπτυξη νέων αρχιτεκτονικών και θα παρουσιαστούν αναλυτικά στην επόμενη ενότητα.

1.2 Το Ερευνητικό Πρόβλημα

Η εντυπωσιακή πρόοδος των Μεγάλων Γλωσσικών Μοντέλων δημιούργησε την εντύπωση ότι μπορούν να αποτελέσουν μια καθολική λύση για κάθε εργασία που σχετίζεται με τη γνώση και τη φυσική γλώσσα. Στην πράξη, όμως, η εικόνα είναι πιο σύνθετη. Όσο περισσότερο τα μοντέλα αυτά χρησιμοποιούνται σε πραγματικές εφαρμογές, τόσο πιο εμφανείς γίνονται ορισμένοι περιορισμοί τους. Οι περιορισμοί αυτοί δεν οφείλονται αποκλειστικά στην ποιότητα του ίδιου του μοντέλου, αλλά κυρίως στον τρόπο με τον οποίο αποκτά, αποθηκεύει και διαχειρίζεται τη γνώση. Οι σημαντικότεροι από αυτούς αφορούν την παραγωγή ανακριβών πληροφοριών (*hallucinations*), τη στατική γνώση που διαθέτουν μετά το τέλος της εκπαίδευσής τους (*knowledge cutoff*) και την αδυναμία αποτελεσματικής διαχείρισης πολύ μεγάλου όγκου πληροφορίας (*context window*).

1.2.1 Περιορισμοί των Μεγάλων Γλωσσικών Μοντέλων

Ένα από τα περισσότερο συζητημένα προβλήματα των LLMs είναι οι λεγόμενες *hallucinations*. Ο όρος περιγράφει την περίπτωση κατά την οποία το μοντέλο παράγει μια απάντηση η οποία παρουσιάζεται με βεβαιότητα, χωρίς όμως να ανταποκρίνεται στην πραγματικότητα. Το χαρακτηριστικό αυτό δεν αποτελεί απλώς ένα μεμονωμένο σφάλμα· είναι συνέπεια του

τρόπου λειτουργίας των ίδιων των γλωσσικών μοντέλων. Ένα LLM δεν «γνωρίζει» την απάντηση με την ανθρώπινη έννοια. Αντίθετα, προβλέπει ποια ακολουθία λέξεων είναι πιθανότερο να ακολουθήσει με βάση τα δεδομένα στα οποία εκπαιδεύτηκε. Όταν η απαιτούμενη πληροφορία δεν υπάρχει στη γνώση του ή όταν δεν μπορεί να εξαχθεί με επαρκή βεβαιότητα, το μοντέλο εξακολουθεί να παράγει απάντηση, με αποτέλεσμα αυτή να είναι λανθασμένη ή ακόμη και πλήρως κατασκευασμένη [4].

Το πρόβλημα γίνεται εντονότερο όταν τα μοντέλα χρησιμοποιούνται σε πεδία όπου η ακρίβεια αποτελεί βασική προϋπόθεση, όπως η ιατρική, η οικονομία ή η νομική επιστήμη. Σε τέτοιες περιπτώσεις, ακόμη και μία φαινομενικά μικρή ανακρίβεια μπορεί να οδηγήσει σε εσφαλμένα συμπεράσματα ή λανθασμένες αποφάσεις. Για τον λόγο αυτό, τα LLMs δεν μπορούν να αντιμετωπίζονται ως απόλυτη πηγή γνώσης, αλλά ως εργαλεία υποστήριξης, των οποίων οι απαντήσεις απαιτούν αξιολόγηση και επαλήθευση από τον χρήστη.

Ένας δεύτερος περιορισμός αφορά το *knowledge cutoff*. Η γνώση ενός LLM περιορίζεται στα δεδομένα που ήταν διαθέσιμα κατά την περίοδο εκπαίδευσής του και δεν ενημερώνεται αυτόματα όταν προκύπτουν νέα γεγονότα ή μεταβάλλονται υπάρχουσες πληροφορίες. Κατά συνέπεια, ακόμη και ένα ιδιαίτερα ισχυρό μοντέλο είναι δυνατόν να αδυνατεί να απαντήσει σωστά σε ερωτήματα που αφορούν πρόσφατες εξελίξεις ή πληροφορίες οι οποίες δεν συμπεριλήφθηκαν ποτέ στο σύνολο εκπαίδευσής του.

Εξίσου σημαντικός είναι και ο περιορισμός του *context window*. Αν και τα σύγχρονα μοντέλα υποστηρίζουν ολοένα μεγαλύτερα παράθυρα συμφραζομένων, η διαθέσιμη μνήμη παραμένει πεπερασμένη. Στις περισσότερες καθημερινές εφαρμογές το πρόβλημα αυτό περνά σχεδόν απαρατήρητο, καθώς η αλληλεπίδραση με το μοντέλο ολοκληρώνεται έπειτα από λίγες μόνο ανταλλαγές μηνυμάτων. Η εικόνα αλλάζει όταν απαιτείται η επεξεργασία μεγάλων εγγράφων, πολύωρων συνομιλιών ή σύνθετων συλλογισμών που βασίζονται σε μεγάλο όγκο πληροφορίας. Σε αυτές τις περιπτώσεις, το μοντέλο καλείται να διαχειριστεί περισσότερα δεδομένα από όσα μπορεί να διατηρήσει αποτελεσματικά στο διαθέσιμο context, γεγονός που οδηγεί σε απώλεια σημαντικών πληροφοριών και σταδιακή υποβάθμιση της ποιότητας των απαντήσεων. Το συγκεκριμένο ζήτημα αποτελεί τον βασικό άξονα της παρούσας εργασίας και θα αναλυθεί εκτενέστερα στα επόμενα κεφάλαια, όπου παρουσιάζεται η προτεινόμενη αρχιτεκτονική και ο τρόπος με τον οποίο επιχειρεί να αντιμετωπίσει το πρόβλημα του long-context.

1.2.2 Το RAG ως Λύση

Οι παραπάνω περιορισμοί ανέδειξαν την ανάγκη για αρχιτεκτονικές που δεν βασίζονται αποκλειστικά στην εσωτερική γνώση ενός γλωσσικού μοντέλου. Η βασική ιδέα είναι σχετικά απλή: αντί το LLM να προσπαθεί να απαντήσει χρησιμοποιώντας μόνο όσα «θυμάται» από την εκπαίδευσή του, μπορεί πρώτα να αναζητήσει σχετική πληροφορία σε μια εξωτερική πηγή γνώσης και στη συνέχεια να συνθέσει την τελική απάντηση αξιοποιώντας το ανακτημένο περιεχόμενο. Η προσέγγιση αυτή είναι γνωστή ως *Retrieval-Augmented Generation (RAG)* και αποτελεί πλέον μία από τις σημαντικότερες κατευθύνσεις έρευνας στον χώρο των σύγχρονων γλωσσικών μοντέλων [5].

Με την εισαγωγή ενός μηχανισμού ανάκτησης πληροφορίας, το μοντέλο αποκτά πρόσβαση σε δεδομένα τα οποία δεν ήταν απαραίτητα διαθέσιμα κατά την εκπαίδευσή του. Έτσι μειώνεται η πιθανότητα παραγωγής hallucinations, καθίσταται δυνατή η αξιοποίηση επικαιροποιημένων πληροφοριών και, κυρίως, η παραγόμενη απάντηση μπορεί να βασίζεται σε πραγματικά έγγραφα αντί σε στατιστικές προβλέψεις. Η ποιότητα του τελικού αποτελέσματος εξαρτάται πλέον όχι μόνο από το ίδιο το LLM αλλά και από την αποτελεσματικότητα του μηχανισμού ανάκτησης, τη δομή των δεδομένων και τον τρόπο με τον οποίο η πληροφορία οργανώνεται πριν ακόμη φτάσει στο μοντέλο.

Παρότι το RAG αντιμετωπίζει σημαντικό μέρος των παραπάνω αδυναμιών, δεν επιλύει αυτομάτως κάθε πρόβλημα. Η απόδοση του συστήματος επηρεάζεται από τον τρόπο κατάτμησης των εγγράφων, την ποιότητα των embeddings, τη στρατηγική ανάκτησης και, κυρίως, από την ικανότητα διαχείρισης μεγάλου όγκου πληροφορίας. Η παρατήρηση αυτή αποτελεί το βασικό σημείο εκκίνησης της παρούσας εργασίας. Αντί να εξεταστεί αποκλειστικά η εφαρμογή ενός ακόμη συστήματος RAG, η έρευνα εστιάζει στον σχεδιασμό μιας αρχιτεκτονικής η οποία οργανώνει αποτελεσματικότερα τη γνώση και δημιουργεί τις κατάλληλες προϋποθέσεις για την υποστήριξη εφαρμογών long-context, θέμα που αναλύεται στα επόμενα κεφάλαια.

1.3 Κίνητρα

1.3.1 Γιατί το Long-Context Παραμένει Ανοιχτό Ερευνητικό Πρόβλημα

Η συνεχής αύξηση των δυνατοτήτων των Μεγάλων Γλωσσικών Μοντέλων έχει οδηγήσει πολλούς ερευνητές στο ερώτημα εάν η απλή αύξηση του διαθέσιμου *context window* αρκεί για να επιλύσει οριστικά το πρόβλημα της διαχείρισης μεγάλου όγκου πληροφορίας. Παρότι τα νεότερα μοντέλα υποστηρίζουν ολοένα μεγαλύτερα παράθυρα συμφραζομένων, το ζήτημα δεν περιορίζεται αποκλειστικά στον αριθμό των tokens που μπορούν να εισαχθούν ως είσοδος. Η αποτελεσματική αξιοποίηση της πληροφορίας αποτελεί διαφορετικό πρόβλημα από την απλή αποθήκευσή της μέσα στο context [6].

Η αύξηση του μήκους του context συνοδεύεται από σημαντικό υπολογιστικό κόστος. Οι μηχανισμοί προσοχής (*attention*) που χρησιμοποιούνται στους Transformers παρουσιάζουν τετραγωνική αύξηση ως προς το μήκος της εισόδου [1]. Η διαχείριση εκατοντάδων χιλιάδων ή ακόμη και εκατομμυρίων tokens είναι εφικτή μόνο υπό συγκεκριμένες προϋποθέσεις και δεν αποτελεί πρακτική λύση για κάθε εφαρμογή μεγάλης κλίμακας.

Παράλληλα, η ύπαρξη μεγαλύτερου context δεν εγγυάται ότι το μοντέλο θα αξιοποιήσει σωστά όλες τις διαθέσιμες πληροφορίες. Η σχετική βιβλιογραφία δείχνει ότι η απόδοση των LLMs υποβαθμίζεται όταν σημαντικές πληροφορίες βρίσκονται διάσπαρτες μέσα σε ιδιαίτερα μεγάλα κείμενα, ενώ έχουν παρατηρηθεί φαινόμενα όπου το μοντέλο δίνει μεγαλύτερη βαρύτητα στην αρχή ή στο τέλος του context σε σχέση με το ενδιάμεσο περιεχόμενο [6]. Επομένως, η πρόκληση δεν είναι μόνο η αύξηση του διαθέσιμου χώρου μνήμης, αλλά κυρίως η αποτελεσματική οργάνωση και ανάκτηση της πληροφορίας που πραγματικά απαιτείται για την παραγωγή της απάντησης.

Η παρούσα εργασία ακολουθεί διαφορετική προσέγγιση. Αντί να αντιμετωπίζει το long-context ως πρόβλημα που επιλύεται αποκλειστικά με μεγαλύτερα μοντέλα ή μεγαλύτερο context window, εξετάζει τον σχεδιασμό μιας αρχιτεκτονικής — της SAH-RAG — η οποία οργανώνει τη γνώση πριν αυτή φτάσει στο γλωσσικό μοντέλο. Η βασική υπόθεση είναι ότι ένα κατάλληλα δομημένο σύστημα εξωτερικής μνήμης μπορεί να περιορίσει σημαντικά την ανάγκη διατήρησης ολόκληρου του διαθέσιμου corpus μέσα στο context, διατηρώντας παράλληλα υψηλή ποιότητα ανάκτησης και παραγωγής απαντήσεων. Υπό αυτή την οπτική, η αρχιτεκτονική λειτουργεί συμπληρωματικά προς τα σύγχρονα LLMs και μπορεί να αξιοποιηθεί ανεξάρτητα από το μέγεθος του context window που υποστηρίζει κάθε μοντέλο.

1.3.2 Γιατί τα Νομικά Κείμενα Αποτελούν Κατάλληλο Πεδίο Αξιολόγησης

Η επιλογή του συνόλου δεδομένων αποτελεί καθοριστικό παράγοντα για την αξιολόγηση μιας τέτοιας αρχιτεκτονικής. Η προτεινόμενη αρχιτεκτονική προορίζεται για ετερογενή long-context σύνολα δεδομένων, με έμφαση στα νομικά κείμενα. Τα νομικά έγγραφα δεν επιλέγονται επειδή στόχος είναι η ανάπτυξη ενός ακόμη εξειδικευμένου νομικού εργαλείου, αλλά επειδή αποτελούν ένα ιδιαίτερα απαιτητικό περιβάλλον αξιολόγησης, μέσα στο οποίο μπορούν να αναδειχθούν τόσο οι δυνατότητες όσο και οι περιορισμοί της προτεινόμενης προσέγγισης.

Τα νομικά κείμενα παρουσιάζουν χαρακτηριστικά που δύσκολα συναντώνται ταυτόχρονα σε άλλα σύνολα δεδομένων. Πρόκειται για πραγματικά έγγραφα, τα οποία χρησιμοποιούνται στην καθημερινή πρακτική και συνεπώς αντανακλούν προβλήματα πραγματικών εφαρμογών. Επιπλέον, είναι συνήθως μεγάλης έκτασης, γεγονός που τα καθιστά ιδιαίτερα κατάλληλα για τη μελέτη τεχνικών διαχείρισης long-context. Η πληροφορία δεν είναι συγκεντρωμένη σε μία μόνο παράγραφο· κατανέμεται σε ολόκληρο το έγγραφο και συχνά απαιτείται συνδυασμός απομακρυσμένων τμημάτων για την εξαγωγή ασφαλών συμπερασμάτων.

Ένα ακόμη χαρακτηριστικό των νομικών εγγράφων είναι η εσωτερική τους δομή. Σε αρκετές περιπτώσεις η δομή αυτή είναι εμφανής, όπως συμβαίνει στη νομοθεσία όπου υπάρχουν άρθρα, παράγραφοι και εδάφια. Υπάρχουν όμως και περιπτώσεις, κυρίως στη νομολογία, όπου τα όρια των επιμέρους νοηματικών ενοτήτων δεν είναι πάντοτε σαφή. Η αναγνώρισή τους απαιτεί είτε κατάλληλους αλγοριθμικούς μηχανισμούς είτε γνώση του ίδιου του αντικειμένου. Η παρατήρηση αυτή επηρεάζει άμεσα τον σχεδιασμό της προτεινόμενης αρχιτεκτονικής, καθώς η οργάνωση της γνώσης προηγείται της διαδικασίας ανάκτησης.

Για τους λόγους αυτούς, τα νομικά κείμενα και, ειδικότερα, οι δικαστικές αποφάσεις αποτελούν ένα από τα κύρια πεδία αξιολόγησης της προτεινόμενης αρχιτεκτονικής. Οι αποφάσεις αυτές συνδυάζουν μεγάλο μήκος, ανομοιογενή δομή και αυξημένες απαιτήσεις ως προς τη διατήρηση του νοηματικού περιεχομένου. Εάν η προτεινόμενη αρχιτεκτονική μπορεί να λειτουργήσει αποτελεσματικά σε ένα τέτοιο περιβάλλον, τότε η εφαρμογή της σε λιγότερο σύνθετα σύνολα δεδομένων αναμένεται να είναι ακόμη πιο άμεση. Υπό αυτή την έννοια, τα νομικά δεδομένα λειτουργούν ως ένα απαιτητικό πεδίο αξιολόγησης για τη γενική αρχιτεκτονική διαχείρισης γνώσης και όχι ως ο τελικός προορισμός της έρευνας.

1.4 Συνεισφορά της Εργασίας

Η παρούσα εργασία πραγματεύεται τον σχεδιασμό και την υλοποίηση της SAH-RAG (*Structure-Aware Hierarchical RAG*), μίας αρχιτεκτονικής σημασιολογικής ανάκτησης και παραγωγής κειμένου, η οποία αξιοποιεί σύγχρονες τεχνικές Retrieval-Augmented Generation (RAG) και οργανώνει τη γνώση με τρόπο που να υποστηρίζει απαιτητικές εφαρμογές μεγάλης κλίμακας. Βασικός στόχος δεν είναι η ανάπτυξη ενός ακόμη εξειδικευμένου συστήματος για νομικά δεδομένα, αλλά η διερεύνηση μιας περισσότερο γενικής αρχιτεκτονικής, ικανής να αποτελέσει τη βάση για εφαρμογές στις οποίες η πληροφορία υπερβαίνει τα όρια του διαθέσιμου context ενός γλωσσικού μοντέλου.

Η εργασία αξιολογείται σε ετερογενή long-context σύνολα δεδομένων, με έμφαση σε νομικά κείμενα. Το corpus περιλαμβάνει έγγραφα μεγάλης έκτασης, ανομοιογενή δομή και εξειδικευμένη ορολογία, χαρακτηριστικά που το καθιστούν αντιπροσωπευτικό των προκλήσεων που συναντώνται σε εφαρμογές long-context. Η αξιολόγηση επικεντρώνεται κυρίως στη νομολογία, δηλαδή στις δικαστικές αποφάσεις, οι οποίες συνδυάζουν μεγάλο μήκος, σύνθετη εσωτερική δομή και την ανάγκη ταυτόχρονης αξιοποίησης πληροφοριών που βρίσκονται διάσπαρτες στο έγγραφο.

Η συνεισφορά της εργασίας δεν περιορίζεται στην εφαρμογή τεχνικών RAG σε νομικά δεδομένα. Αντίθετα, επιχειρείται η διερεύνηση ενός διαφορετικού τρόπου οργάνωσης και αξιοποίησης της γνώσης, ο οποίος δημιουργεί τις απαραίτητες προϋποθέσεις για την υποστήριξη εφαρμογών long-context. Η προτεινόμενη αρχιτεκτονική αντιμετωπίζει το RAG ως ένα επιμέρους δομικό στοιχείο ενός ευρύτερου συστήματος εξωτερικής μνήμης και όχι ως τελικό σκοπό της έρευνας. Υπό αυτή την οπτική, τα νομικά δεδομένα λειτουργούν ως ένα ιδιαίτερα απαιτητικό πεδίο αξιολόγησης, ενώ η αρχιτεκτονική προορίζεται για ευρύτερα long-context σύνολα δεδομένων.

Τα βασικά ερευνητικά ερωτήματα που καθοδηγούν την παρούσα εργασία είναι τα ακόλουθα:

- Μπορεί η αναγνώριση της εσωτερικής δομής των εγγράφων να οδηγήσει σε αποτελεσματικότερη οργάνωση του corpus και βελτιωμένη ανάκτηση;

- Επηρεάζει η χρήση hierarchical chunking την ποιότητα της ανάκτησης σε σχέση με μία επίπεδη (flat) προσέγγιση;

- Μπορεί μία hybrid retrieval αρχιτεκτονική να επιτύχει καλύτερα αποτελέσματα από ένα αποκλειστικά dense retrieval σύστημα στο ίδιο corpus;
- Είναι δυνατόν η οργάνωση των δεδομένων σε διακριτές δομικές οντότητες να διευκολύνει μελλοντικές επεκτάσεις της αρχιτεκτονικής, χωρίς να μεταβληθεί ο βασικός μηχανισμός retrieval;
- Πώς συγκρίνεται η προτεινόμενη αρχιτεκτονική με καθιερωμένες προσεγγίσεις ανάκτησης (baselines) και με σύγχρονα συστήματα RAG (state-of-the-art), υπό συνθήκες δίκαιης σύγκρισης;

Εφόσον η SAH-RAG αποδειχθεί αποτελεσματική σε ένα τόσο σύνθετο περιβάλλον, η ίδια φιλοσοφία μπορεί να μεταφερθεί και σε άλλα πεδία όπου απαιτείται αξιόπιστη διαχείριση μεγάλου όγκου γνώσης και παραγωγή τεκμηριωμένων απαντήσεων.

1.5 Δομή της Εργασίας

Η παρούσα εργασία οργανώνεται σε οκτώ κεφάλαια και δύο παραρτήματα. Κάθε κεφάλαιο εξετάζει διαφορετική πτυχή του προβλήματος και συμβάλλει σταδιακά στην παρουσίαση της προτεινόμενης αρχιτεκτονικής.

1. Στο Κεφάλαιο 1 παρουσιάζεται το αντικείμενο της εργασίας, το ερευνητικό πρόβλημα που επιχειρείται να αντιμετωπιστεί, τα κίνητρα για την ανάπτυξη ενός συστήματος ανάκτησης γνώσης για long-context σενάρια, καθώς και η συνεισφορά και η δομή της εργασίας.
2. Στο Κεφάλαιο 2 πραγματοποιείται επισκόπηση της σχετικής βιβλιογραφίας. Παρουσιάζονται οι θεμελιώδεις προσεγγίσεις στην ανάκτηση πληροφορίας, οι σύγχρονες αρχιτεκτονικές RAG, οι τεχνικές διαχείρισης long-context, καθώς και οι δέκα αρχιτεκτονικές αναφοράς (baselines και state-of-the-art) που χρησιμοποιούνται στη συνέχεια για τη σύγκριση.
3. Στο Κεφάλαιο 3 περιγράφεται η προτεινόμενη αρχιτεκτονική του συστήματος. Παρουσιάζονται οι βασικές σχεδιαστικές επιλογές, η συνολική ροή της επεξεργασίας, καθώς και ο διαχωρισμός του συστήματος στα στάδια προετοιμασίας της γνώσης (*offline stage*) και ανάκτησης πληροφορίας (*online stage*).

4. Στο Κεφάλαιο 4 παρουσιάζεται αναλυτικά η υλοποίηση της προτεινόμενης αρχιτεκτονικής. Περιγράφονται τα σύνολα δεδομένων και το canonical data model, τα επιμέρους υποσυστήματα (parsing, chunking, embeddings, storage, retrieval), οι εναλλακτικές λύσεις που εξετάστηκαν, οι τεχνικές επιλογές που πραγματοποιήθηκαν, καθώς και οι μηχανισμοί ντετερμινιστικότητας και αναπαραγωγιμότητας.

5. Στο Κεφάλαιο 5 πραγματοποιείται η πρώτη φάση της πειραματικής αξιολόγησης, η οποία στοχεύει στη διερεύνηση του ερωτήματος «πότε η προτεινόμενη αρχιτεκτονική αποδίδει βέλτιστα». Παρουσιάζεται μία σταδιακή, στατιστικά φυλασσόμενη μελέτη παραμέτρων, με σαφή διαχωρισμό μεταξύ screening, confirmatory και locked test splits, καθώς και τα τελεσίδικα αποτελέσματα των υποθέσεων.

6. Στο Κεφάλαιο 6 παρουσιάζεται η δεύτερη φάση της πειραματικής αξιολόγησης, η οποία απαντά στο ερώτημα «πώς συγκρίνεται η προτεινόμενη αρχιτεκτονική με άλλες αρχιτεκτονικές ανάκτησης, υπό συνθήκες δίκαιης σύγκρισης». Περιγράφεται το κοινό πρωτόκολλο αξιολόγησης, οι συμμετέχουσες αρχιτεκτονικές (LongRAG, Metadata-RAG), τα συγκριτικά αποτελέσματα, η ερμηνεία τους και οι περιορισμοί των συμπερασμάτων.

7. Στο Κεφάλαιο 7 συζητούνται πιθανές επεκτάσεις της προτεινόμενης αρχιτεκτονικής και παρουσιάζονται κατευθύνσεις για μελλοντική έρευνα, με ιδιαίτερη έμφαση (α) στην εφαρμογή σε μεγάλης κλίμακας δομημένα corpora και (β) στη διαχείριση πληροφορίας σε γλωσσικά μοντέλα μειωμένου context window μέσω μηχανισμών εξωτερικής μνήμης.

8. Τέλος, στο Κεφάλαιο 8 συνοψίζονται τα βασικά συμπεράσματα της εργασίας, οι συνεισφορές της, οι περιορισμοί της προτεινόμενης προσέγγισης και τα σημαντικότερα σημεία που προέκυψαν από την υλοποίηση και την αξιολόγηση του συστήματος.

Η εργασία συνοδεύεται από δύο παραρτήματα. Το Παράρτημα Α τεκμηριώνει τις αρχιτεκτονικές αναφοράς που δεν κατέστη δυνατό να εκτελεστούν, με ρητή αναφορά των λόγων αποκλεισμού. Το Παράρτημα Β συγκεντρώνει τους εξωτερικούς πόρους (σύνολα δεδομένων, κώδικας, προδιαγραφές αναπαραγωγιμότητας) που χρησιμοποιήθηκαν ή παρήχθησαν.

Κεφάλαιο 2

Σχετική Εργασία και Αρχιτεκτονικές Αναφοράς

2.1 Ανάκτηση Πληροφορίας

Η ανάκτηση πληροφορίας (*Information Retrieval – IR*) αποτελεί έναν από τους παλαιότερους και σημαντικότερους τομείς της επιστήμης της πληροφορικής. Αντικείμενό της είναι η αναζήτηση σχετικών πληροφοριών μέσα από μεγάλες συλλογές εγγράφων, με στόχο την επιστροφή εκείνων που ικανοποιούν καλύτερα το πληροφοριακό αίτημα του χρήστη [7]. Παρότι οι πρώτες εφαρμογές εμφανίστηκαν αρκετές δεκαετίες πριν, οι βασικές αρχές της ανάκτησης πληροφορίας εξακολουθούν να αποτελούν τη βάση των σύγχρονων μηχανών αναζήτησης και των συστημάτων διαχείρισης γνώσης.

Οι πρώτες προσεγγίσεις βασίζονταν σχεδόν αποκλειστικά στη λεξικογραφική αντιστοίχιση (*lexical matching*). Ένα έγγραφο θεωρούνταν σχετικό όταν περιείχε τις ίδιες ή παρόμοιες λέξεις με αυτές που υπήρχαν στο ερώτημα του χρήστη. Στο πλαίσιο αυτό αναπτύχθηκαν μοντέλα όπως το Boolean Retrieval, το Vector Space Model και αργότερα η οικογένεια αλγορίθμων BM25, τα οποία χρησιμοποιούνται ακόμη και σήμερα σε αρκετές εφαρμογές λόγω της απλότητας και της αποτελεσματικότητάς τους [8, 9].

Παρόλα αυτά, οι μέθοδοι αυτές εμφανίζουν έναν βασικό περιορισμό. Η συνάφεια μεταξύ δύο κειμένων εκτιμάται κυρίως από τις κοινές λέξεις που περιέχουν και όχι από το πραγματικό τους νόημα. Έτσι, δύο έγγραφα που αναφέρονται στην ίδια έννοια χρησιμοποιώντας διαφορετική ορολογία ενδέχεται να θεωρηθούν άσχετα μεταξύ τους. Αντίστοιχα, δύο κείμενα που χρησιμοποιούν τις ίδιες λέξεις αλλά σε διαφορετικό σημασιολογικό πλαίσιο μπορεί

να εμφανιστούν λανθασμένα ως ιδιαίτερα σχετικά. Το πρόβλημα αυτό έχει αναφερθεί εκτενώς στη βιβλιογραφία και αποτέλεσε ένα από τα βασικά κίνητρα για την ανάπτυξη νεότερων τεχνικών ανάκτησης πληροφορίας [7].

Η σημαντική πρόοδος των μοντέλων βαθιάς μάθησης και της επεξεργασίας φυσικής γλώσσας οδήγησε σταδιακά στη μετάβαση από τις καθαρά λεξικογραφικές μεθόδους σε σημασιολογικές προσεγγίσεις. Αντί να συγκρίνονται μόνο οι λέξεις, επιχειρείται πλέον η αναπαράσταση του νοήματος ενός κειμένου σε μορφή διανυσμάτων υψηλής διάστασης (*embeddings*), επιτρέποντας την αναζήτηση με βάση τη σημασιολογική ομοιότητα και όχι αποκλειστικά τη λεκτική αντιστοίχιση [10].

Η μετάβαση αυτή σηματοδότησε μία ουσιαστική αλλαγή στον τρόπο με τον οποίο σχεδιάζονται τα σύγχρονα συστήματα ανάκτησης γνώσης. Τα τελευταία χρόνια η έρευνα δεν επικεντρώνεται μόνο στη βελτίωση των αλγορίθμων αναζήτησης, αλλά και στον τρόπο οργάνωσης, αναπαράστασης και αποθήκευσης της γνώσης πριν από τη διαδικασία της ανάκτησης. Η εξέλιξη αυτή οδήγησε στην ανάπτυξη των συστημάτων *Dense Retrieval*, τα οποία παρουσιάζονται στην επόμενη ενότητα.

2.2 Dense Retrieval

Η ανάπτυξη των μοντέλων βαθιάς μάθησης άλλαξε σημαντικά τον τρόπο με τον οποίο προσεγγίζεται το πρόβλημα της ανάκτησης πληροφορίας. Αντί η αναζήτηση να βασίζεται αποκλειστικά στις κοινές λέξεις μεταξύ ενός ερωτήματος και ενός εγγράφου, εισήχθη η έννοια της σημασιολογικής αναπαράστασης του κειμένου μέσω διανυσμάτων (*embeddings*). Με τον τρόπο αυτό, η σύγκριση πραγματοποιείται πλέον σε έναν διανυσματικό χώρο, όπου η απόσταση μεταξύ δύο διανυσμάτων εκφράζει τον βαθμό σημασιολογικής τους ομοιότητας [10].

Στα συστήματα Dense Retrieval τόσο το ερώτημα όσο και τα έγγραφα μετατρέπονται σε διανυσματικές αναπαραστάσεις μέσω ενός νευρωνικού μοντέλου. Η διαδικασία αυτή πραγματοποιείται συνήθως από έναν encoder, ο οποίος εκπαιδεύεται ώστε κείμενα με παρόμοιο νόημα να τοποθετούνται κοντά μεταξύ τους στον διανυσματικό χώρο. Κατά τη διάρκεια της αναζήτησης δεν συγκρίνονται πλέον οι ίδιες οι λέξεις, αλλά τα αντίστοιχα embeddings των κειμένων, χρησιμοποιώντας μετρικές ομοιότητας όπως η συνημιτονοειδής ομοιότητα (*cosine similarity*) ή το εσωτερικό γινόμενο (*dot product*) [11].

Η σημαντικότερη διαφορά σε σχέση με τις κλασικές μεθόδους είναι ότι η ανάκτηση βασίζεται στο νόημα και όχι αποκλειστικά στη μορφή των λέξεων. Για παράδειγμα, δύο κείμενα που χρησιμοποιούν διαφορετική ορολογία αλλά περιγράφουν την ίδια έννοια μπορούν να αναγνωριστούν ως σχετικά, ακόμη και όταν δεν υπάρχει άμεση λεκτική αντιστοίχιση. Το χαρακτηριστικό αυτό βελτίωσε σημαντικά την ποιότητα πολλών εφαρμογών αναζήτησης και αποτέλεσε τη βάση για την ανάπτυξη των σύγχρονων συστημάτων ερωταποκρίσεων (*Question Answering*) [10].

Παρόλα αυτά, η αποκλειστική χρήση dense embeddings δεν λύνει όλα τα προβλήματα. Σε αρκετές περιπτώσεις, ιδιαίτερα σε εξειδικευμένα πεδία όπως τα νομικά ή τα ιατρικά κείμενα, συγκεκριμένοι όροι, αριθμοί άρθρων, κωδικοί ή αναφορές σε νομοθετήματα έχουν καθοριστική σημασία. Τα μοντέλα σημασιολογικής αναζήτησης είναι δυνατόν να αποδώσουν μικρότερη βαρύτητα σε τέτοιες ακριβείς λεκτικές αντιστοιχίσεις, καθώς δίνουν προτεραιότητα στη συνολική σημασία του κειμένου και όχι στην ακριβή εμφάνιση μιας λέξης [12].

Η παρατήρηση αυτή οδήγησε στη σταδιακή ανάπτυξη υβριδικών προσεγγίσεων, στις οποίες συνδυάζονται τα πλεονεκτήματα της σημασιολογικής και της λεξικογραφικής αναζήτησης. Αντί να θεωρούνται ανταγωνιστικές τεχνικές, οι δύο μορφές ανάκτησης λειτουργούν συμπληρωματικά, επιτρέποντας την καλύτερη διαχείριση τόσο της σημασιολογικής συνάφειας όσο και των ακριβών λεκτικών αντιστοιχίσεων. Η φιλοσοφία αυτή υιοθετείται πλέον σε αρκετά σύγχρονα Retrieval-Augmented Generation συστήματα και αποτελεί τη βάση πάνω στην οποία σχεδιάζονται πολλές σύγχρονες αρχιτεκτονικές ανάκτησης γνώσης [13].

2.3 Retrieval-Augmented Generation

Η εμφάνιση των Μεγάλων Γλωσσικών Μοντέλων (*Large Language Models – LLMs*) επέτρεψε την ανάπτυξη συστημάτων παραγωγής φυσικής γλώσσας με ιδιαίτερα υψηλή ποιότητα. Ωστόσο, τα μοντέλα αυτά παρουσιάζουν έναν σημαντικό περιορισμό. Η γνώση τους παραμένει ουσιαστικά στατική, καθώς περιορίζεται στα δεδομένα που χρησιμοποιήθηκαν κατά την εκπαίδευσή τους. Κατά συνέπεια, δεν μπορούν να αξιοποιήσουν νεότερη πληροφορία, ενώ σε αρκετές περιπτώσεις παράγουν ανακριβείς ή μη τεκμηριωμένες απαντήσεις (*hallucinations*) [5, 4].

Για την αντιμετώπιση του προβλήματος αυτού προτάθηκε η αρχιτεκτονική *Retrieval-Augmented Generation (RAG)*. Η βασική ιδέα είναι σχετικά απλή. Πριν το γλωσσικό μοντέλο

δημιουργήσει μία απάντηση, πραγματοποιείται αναζήτηση σε μία εξωτερική βάση γνώσης. Τα σχετικά έγγραφα που εντοπίζονται ανακτώνται και εισάγονται στο *context* του μοντέλου, ώστε η τελική απάντηση να βασίζεται όχι μόνο στις παραμέτρους του LLM αλλά και σε πραγματικά δεδομένα που υπάρχουν διαθέσιμα τη στιγμή της εκτέλεσης [5].

Η προσέγγιση αυτή παρουσιάζει δύο σημαντικά πλεονεκτήματα. Αρχικά, επιτρέπει την αξιοποίηση γνώσης η οποία μπορεί να ενημερώνεται χωρίς να απαιτείται επανεκπαίδευση του μοντέλου. Παράλληλα, οι απαντήσεις μπορούν να συνοδεύονται από τα αντίστοιχα έγγραφα που χρησιμοποιήθηκαν κατά τη διαδικασία της ανάκτησης, βελτιώνοντας σημαντικά τη διαφάνεια και τη δυνατότητα επαλήθευσης των αποτελεσμάτων. Για τον λόγο αυτό, τα συστήματα RAG έχουν υιοθετηθεί ευρέως σε εφαρμογές ερωταποκρίσεων, αναζήτησης γνώσης και υποστήριξης λήψης αποφάσεων [14].

Παρά τη σημαντική πρόοδο που εισήγαγε η συγκεκριμένη αρχιτεκτονική, η συνολική απόδοση ενός συστήματος RAG εξακολουθεί να εξαρτάται σε μεγάλο βαθμό από την ποιότητα του μηχανισμού ανάκτησης. Εάν η διαδικασία retrieval επιστρέψει ελλιπή ή μη σχετικά έγγραφα, ακόμη και ένα ιδιαίτερα ισχυρό γλωσσικό μοντέλο είναι πιθανό να παράγει ανακριβείς απαντήσεις. Με άλλα λόγια, το στάδιο της ανάκτησης αποτελεί τον βασικό περιοριστικό παράγοντα (*bottleneck*) ενός RAG συστήματος [14].

Τα τελευταία χρόνια η έρευνα έχει μετατοπιστεί από το ίδιο το γλωσσικό μοντέλο προς τη βελτίωση της διαδικασίας retrieval. Μελετώνται νέες μέθοδοι δημιουργίας embeddings, διαφορετικές στρατηγικές chunking, τεχνικές επανακατάταξης (*reranking*), καθώς και υβριδικές μέθοδοι που συνδυάζουν σημασιολογική και λεξικογραφική αναζήτηση. Η γενική τάση της βιβλιογραφίας δείχνει ότι σημαντικό μέρος της βελτίωσης ενός συστήματος RAG προέρχεται πλέον από τον τρόπο οργάνωσης και ανάκτησης της γνώσης και όχι αποκλειστικά από την επιλογή ενός μεγαλύτερου γλωσσικού μοντέλου [14, 15].

Η παρούσα εργασία ακολουθεί ακριβώς αυτή τη φιλοσοφία. Αντί να επικεντρώνεται στην ανάπτυξη ενός νέου γλωσσικού μοντέλου, εξετάζει τη διαδικασία οργάνωσης και ανάκτησης της γνώσης πριν από το στάδιο της παραγωγής κειμένου. Το ενδιαφέρον επομένως μετατοπίζεται στην αρχιτεκτονική του retrieval subsystem, το οποίο αποτελεί το βασικό αντικείμενο μελέτης της παρούσας εργασίας.

2.4 Σύγχρονες Αρχιτεκτονικές Ανάκτησης

Η συνεχής βελτίωση των Μεγάλων Γλωσσικών Μοντέλων τα τελευταία χρόνια δεν συνοδεύτηκε μόνο από μεγαλύτερα μοντέλα ή περισσότερες παραμέτρους. Αντίθετα, σημαντικό μέρος της έρευνας μετατοπίστηκε προς την πλευρά της ανάκτησης πληροφορίας. Έγινε γρήγορα αντιληπτό ότι ακόμη και το ισχυρότερο γλωσσικό μοντέλο δεν μπορεί να παράγει αξιόπιστες απαντήσεις όταν η διαδικασία retrieval επιστρέφει ελλιπή ή μη σχετικά έγγραφα. Για τον λόγο αυτό, μεγάλο μέρος της σύγχρονης βιβλιογραφίας επικεντρώνεται πλέον στον σχεδιασμό αποδοτικότερων retrieval pipelines, τα οποία οργανώνουν και ανακτούν αποτελεσματικότερα τη γνώση πριν αυτή εισαχθεί στο LLM [14].

Μία από τις σημαντικότερες κατευθύνσεις αφορά τη μετάβαση από καθαρά dense retrieval συστήματα σε υβριδικές προσεγγίσεις. Παρότι τα dense embeddings αποτυπώνουν αποτελεσματικά τη σημασιολογική πληροφορία ενός κειμένου, εξακολουθούν να δυσκολεύονται σε περιπτώσεις όπου η ακριβής λεκτική αντιστοίχιση παίζει καθοριστικό ρόλο. Αυτό συμβαίνει ιδιαίτερα σε τεχνικά πεδία όπου η ακριβής ορολογία έχει καθοριστική σημασία, όπως στα νομικά ή τα ιατρικά κείμενα, όπου ένας αριθμός άρθρου, ένας κωδικός ή ακόμη και ένας μοναδικός όρος μπορεί να αλλάξει πλήρως το νόημα ενός εγγράφου. Για τον λόγο αυτό, αρκετές σύγχρονες αρχιτεκτονικές συνδυάζουν dense και sparse retrieval, αξιοποιώντας τα πλεονεκτήματα και των δύο προσεγγίσεων [12].

Η λογική αυτή οδήγησε στην ανάπτυξη των λεγόμενων *hybrid retrieval systems*. Αντί να βασίζονται αποκλειστικά σε μία στρατηγική αναζήτησης, πραγματοποιούν παράλληλα σημασιολογική και λεξικογραφική ανάκτηση, ενώ στη συνέχεια συγχωνεύουν τα αποτελέσματα χρησιμοποιώντας τεχνικές κατάταξης, όπως το Reciprocal Rank Fusion (RRF). Η συγκεκριμένη προσέγγιση εμφανίζει σταθερά καλύτερη συμπεριφορά σε heterogeneous corpora, όπου συνυπάρχουν τόσο σημασιολογικές όσο και αυστηρά λεκτικές σχέσεις μεταξύ των εγγράφων [16].

Παράλληλα με την εξέλιξη των embeddings, ιδιαίτερη έμφαση δόθηκε και στον τρόπο με τον οποίο οργανώνονται τα ίδια τα έγγραφα πριν αποθηκευτούν σε μία βάση διανυσμάτων. Τα πρώτα RAG συστήματα αντιμετώπιζαν κάθε chunk ως μία ανεξάρτητη οντότητα. Η προσέγγιση αυτή απλοποιεί σημαντικά την υλοποίηση, όμως απομακρύνει το chunk από το ευρύτερο συμφραζόμενό του. Ένα μικρό τμήμα κειμένου μπορεί να ανακτηθεί σωστά, χωρίς όμως να μεταφέρει στον χρήστη ολόκληρη τη λογική ενότητα στην οποία ανήκει.

Για την αντιμετώπιση του προβλήματος αυτού εμφανίστηκαν οι ιεραρχικές αρχιτεκτο-

νικές ανάκτησης (*hierarchical retrieval*). Σε αυτές τα μικρά chunks χρησιμοποιούνται αποκλειστικά για την αναζήτηση, ενώ η τελική πληροφορία που επιστρέφεται αντιστοιχεί σε μία μεγαλύτερη δομική οντότητα, όπως ένα άρθρο, μία ενότητα ή ένα ολόκληρο κεφάλαιο. Με τον τρόπο αυτό συνδυάζεται η υψηλή ακρίβεια της αναζήτησης με τη διατήρηση του απαραίτητου συμφραζομένου του εγγράφου [17].

Μία ακόμη κατεύθυνση της βιβλιογραφίας αφορά την εισαγωγή ενός επιπλέον σταδίου επανακατάταξης (*reranking*). Μετά την αρχική ανάκτηση των υποψήφιων εγγράφων, χρησιμοποιούνται ισχυρότερα μοντέλα, συνήθως Cross-Encoders ή Late Interaction μοντέλα όπως το ColBERT, ώστε να επανεκτιμηθεί η συνάφεια κάθε αποτελέσματος. Παρότι η διαδικασία αυτή αυξάνει τον υπολογιστικό φόρτο, σε αρκετές εφαρμογές οδηγεί σε αισθητή βελτίωση της τελικής ποιότητας των αποτελεσμάτων [18].

Τέλος, το ζήτημα της διαχείρισης μεγάλου όγκου πληροφορίας έχει αναδειχθεί σε αυτοτελές ερευνητικό αντικείμενο. Η εργασία των Liu et al. έδειξε ότι η απλή αύξηση του context window δεν αρκεί για την ορθή αξιοποίηση της πληροφορίας, καθώς τα μοντέλα τείνουν να δίνουν μεγαλύτερη βαρύτητα στην αρχή ή στο τέλος του context και να αγνοούν το ενδιάμεσο περιεχόμενο [6]. Το φαινόμενο αυτό αποτελεί βασικό κίνητρο για αρχιτεκτονικές που οργανώνουν τη γνώση πριν αυτή εισαχθεί στο μοντέλο, αντί να βασίζονται αποκλειστικά στο μέγεθος του διαθέσιμου παραθύρου.

Συνολικά, παρατηρείται ότι οι περισσότερες σύγχρονες αρχιτεκτονικές δεν βασίζονται πλέον σε μία μόνο τεχνική ανάκτησης. Αντίθετα, υιοθετούν μία πολυεπίπεδη διαδικασία η οποία συνδυάζει διαφορετικές στρατηγικές indexing, embedding, retrieval και reranking. Η τάση αυτή δείχνει ότι η βελτίωση ενός συστήματος RAG δεν εξαρτάται αποκλειστικά από το ίδιο το γλωσσικό μοντέλο, αλλά σε μεγάλο βαθμό από τον τρόπο με τον οποίο οργανώνεται και ανακτάται η διαθέσιμη γνώση πριν αυτή εισαχθεί στο στάδιο της παραγωγής κειμένου. Η παρατήρηση αυτή αποτελεί και το βασικό σημείο εκκίνησης της παρούσας εργασίας.

2.5 Μεθοδολογία Επιλογής Αρχιτεκτονικών Αναφοράς

Για την αξιολόγηση της προτεινόμενης αρχιτεκτονικής κρίθηκε απαραίτητος ο καθορισμός ενός συνόλου αρχιτεκτονικών αναφοράς (baselines) και state-of-the-art προσεγγίσεων, οι οποίες θα χρησιμοποιηθούν ως σημεία σύγκρισης. Δεδομένου του μεγάλου πλήθους σχετικών εργασιών, ακολουθήθηκε μία συστηματική διαδικασία επιλογής, η οποία περιγράφεται

συνοπτικά παρακάτω.

Αρχικά συγκεντρώθηκε ένα εκτεταμένο σύνολο σχετικών δημοσιεύσεων, το οποίο περιλάμβανε τόσο θεμελιώδεις εργασίες όσο και σύγχρονες state-of-the-art προσεγγίσεις. Για κάθε υποψήφια εργασία ορίστηκε ένα σύνολο χαρακτηριστικών (*features*) που περιγράφουν τη σχεδιαστική της φιλοσοφία: ο τρόπος αναπαράστασης των εγγράφων, η στρατηγική chunking, ο τύπος ανάκτησης (dense, sparse, hybrid, graph-based), η χρήση ή μη ιεραρχικής οργάνωσης, η αξιοποίηση μεταδεδομένων, η υποστήριξη long-context σεναρίων και η στοχευμένη εφαρμογή σε νομικά ή άλλα εξειδικευμένα πεδία. Κάθε εργασία βαθμολογήθηκε ως προς τη σχεδιαστική της εγγύτητα με την προτεινόμενη αρχιτεκτονική, με βάση σταθμισμένα κριτήρια, ενώ παράλληλα εντοπίστηκαν εκείνα τα χαρακτηριστικά που, εφόσον απουσίαζαν, θα καθιστούσαν τη σύγκριση μη εύλογη.

Από το αρχικό σύνολο υποψηφίων επιλέχθηκαν τελικά δέκα αρχιτεκτονικές, οι οποίες καλύπτουν συμπληρωματικές κατευθύνσεις: μεγάλες μονάδες ανάκτησης, αναδρομικές περιλήψεις, γράφοι γνώσης, σχεσιακές διαδρομές, μνήμη μεγάλου εύρους, ρητορικές δομές, ιεραρχική γνώση, εμπλουτισμό μέσω μεταδεδομένων και λογικά καθοδηγούμενη συλλογιστική. Η επιλογή δεν αποσκοπεί απλώς στη σύγκριση διαφορετικών υλοποιήσεων, αλλά στην εξέταση διαφορετικών υποθέσεων σχετικά με το πώς πρέπει να οργανώνεται και να ανακτάται η γνώση από μεγάλα και σύνθετα corpora. Οι αρχιτεκτονικές αυτές παρουσιάζονται στην επόμενη ενότητα.

2.6 Αρχιτεκτονικές Αναφοράς και State-of-the-Art

Η παρούσα ενότητα παρουσιάζει συνοπτικά τις δέκα αρχιτεκτονικές αναφοράς, δίνοντας έμφαση στη βασική τους ιδέα, στη συνεισφορά τους και στους περιορισμούς τους σε σχέση με την προτεινόμενη προσέγγιση.

LongRAG. Το LongRAG [19] αμφισβητεί την καθιερωμένη πρακτική της ανάκτησης πολύ μικρών passages. Αντί να τεμαχίζει το corpus σε εκατομμύρια μικρές μονάδες, σχηματίζει πολύ μεγαλύτερες retrieval units (τάξης μερικών χιλιάδων tokens), μειώνοντας σημαντικά το πλήθος των υποψήφιων μονάδων. Η αρχιτεκτονική συνδυάζει έναν *long retriever* με έναν *long reader*, ώστε το βάρος της επεξεργασίας να μεταφέρεται από την αναζήτηση ανάμεσα σε πάρα πολλά μικρά chunks προς την αξιοποίηση λίγων αλλά πλουσιότερων μονάδων. Βασικός περιορισμός της προσέγγισης είναι η μειωμένη ακρίβεια της ανάκτησης, καθώς ένα μεγάλο

unit μπορεί να περιλαμβάνει τη σχετική πληροφορία αλλά και σημαντική ποσότητα άσχετου περιεχομένου, ενώ δεν μοντελοποιούνται ρητά εσωτερικές δομές των εγγράφων.

RAPTOR. Το RAPTOR [20] οργανώνει το corpus σε ένα αναδρομικό δέντρο αφαιρετικών περιλήψεων. Τα αρχικά chunks ενσωματώνονται, ομαδοποιούνται και συνοψίζονται, ενώ η ίδια διαδικασία εφαρμόζεται επαναληπτικά ώστε να δημιουργηθούν πολλαπλά επίπεδα αφαίρεσης. Κατά την ανάκτηση μπορούν να επιστραφούν τόσο λεπτομερή φύλλα όσο και υψηλότερου επιπέδου περιλήψεις, επιτρέποντας την υποστήριξη ερωτημάτων που απαιτούν ευρύτερη κατανόηση. Ωστόσο, η ποιότητα των εσωτερικών κόμβων εξαρτάται από το μοντέλο παραγωγής περιλήψεων, ενώ το κόστος της διαδικασίας clustering και summarization είναι σημαντικό και η προκύπτουσα ιεραρχία βασίζεται κυρίως σε embedding similarity και όχι στη φυσική δομή των εγγράφων.

HippoRAG 2. Το HippoRAG [21] και η μετεξέλιξή του HippoRAG 2 [22] αντλούν έμπνευση από τη θεωρία του ιπποκάμπειου δείκτη και συνδυάζουν εξαγωγή πληροφορίας με LLM, γράφους γνώσης και Personalized PageRank. Στόχος είναι η υποστήριξη associative και multi-hop ανάκτησης μέσω γράφου, αντί να βασίζονται αποκλειστικά στην άμεση ομοιότητα query–passage. Η προσέγγιση προσφέρει ισχυρή υποστήριξη για σύνθετες πληροφοριακές ανάγκες, αλλά η ποιότητα του γράφου εξαρτάται από την εξαγωγή οντοτήτων και σχέσεων, το indexing είναι ακριβότερο από μία απλή vector pipeline, ενώ απαιτείται προσεκτική διαχείριση seeds, βαρών και mappings.

LightRAG. Το LightRAG [23] συνδυάζει graph-based text indexing με vector retrieval. Εξάγει οντότητες και σχέσεις από τα chunks και χρησιμοποιεί *dual-level retrieval*, ώστε να καλύψει τόσο low-level, entity-focused αναζήτηση όσο και high-level, thematic αναζήτηση, υποστηρίζοντας παράλληλα incremental integration νέων δεδομένων. Η αρχιτεκτονική έχει ωστόσο περισσότερα κινούμενα μέρη από ένα απλό retriever και απαιτεί αυστηρή διαχείριση cache και graph state. Επιπλέον, η dual-level ανάκτηση δεν εγγυάται από μόνη της ότι οι ανακτημένες σχέσεις σχηματίζουν την καλύτερη διαδρομή απάντησης.

PathRAG. Το PathRAG [24] εστιάζει στην ανάκτηση σχεσιακών διαδρομών από ένα indexing graph. Η βασική του θέση είναι ότι το κύριο πρόβλημα των graph-based RAG συστημάτων δεν είναι πάντα η έλλειψη πληροφορίας, αλλά η πλεονάζουσα και μη οργανωμένη

πληροφορία. Χρησιμοποιεί pruning και path-based prompting, ώστε να επιστρέφει επιλεγμένες σχεσιακές διαδρομές αντί για ολόκληρες γειτονιές ή graph communities. Η απόδοσή του εξαρτάται έντονα από την πληρότητα του γράφου και από τα hop limits και pruning rules, τα οποία μπορούν να περιορίσουν το retrieval.

MemoRAG. Το MemoRAG [25] εισάγει μία dual-system αρχιτεκτονική. Ένα ελαφρύτερο long-range memory model δημιουργεί global memory του corpus και παράγει clues ή draft information για το query, τα οποία καθοδηγούν στη συνέχεια το retrieval, ενώ ένα ισχυρότερο σύστημα παράγει την τελική απάντηση. Η προσέγγιση αντιμετωπίζει την περίπτωση κατά την οποία το information need δεν εκφράζεται πλήρως στο query. Ωστόσο, η clue generation μπορεί να εισαγάγει bias πριν από το retrieval, ενώ η μέθοδος απαιτεί σημαντικούς υπολογιστικούς πόρους και ισχυρά long-context μοντέλα.

KAG. Το KAG [26] σχεδιάστηκε για επαγγελματικούς και domain-specific χώρους γνώσης, όπου η απλή vector similarity δεν αρκεί. Συνδυάζει γράφους γνώσης, αρχικά chunks, semantic parsing και logical-form-guided reasoning, με βασικά στοιχεία την αμοιβαία διασύνδεση δομημένης γνώσης και κειμένου και τη λογική ανάλυση του query. Το KAG έχει υψηλό κόστος υλοποίησης και μοντελοποίησης, καθώς η κατασκευή κατάλληλης domain ontology μπορεί να απαιτεί ανθρώπινη γνώση ή domain-specific configuration, γεγονός που περιορίζει την άμεση μεταφορά της μεθόδου σε ετερογενή corpora.

DISRetrieval. Το DISRetrieval [27] οργανώνει τα long documents με βάση τη ρητορική τους δομή. Χρησιμοποιεί τη Θεωρία Ρητορικής Δομής (*Rhetorical Structure Theory*, RST) για την κατασκευή discourse trees σε επίπεδο πρότασης, LLM-enhanced representations για τους ενδιάμεσους κόμβους και hierarchical evidence retrieval για την επιλογή συνεκτικών τμημάτων. Η μέθοδος εξαρτάται από neural discourse parsing και LLM summarization, ενώ η ποιότητα του RST parser μπορεί να διαφέρει μεταξύ γλωσσών και domains. Η κατασκευή discourse trees είναι επίσης σημαντικά ακριβότερη από το deterministic chunking.

HiKEY. Το HiKEY [28] είναι ένα ιεραρχικό, δενδρικό πλαίσιο ανάκτησης που αντιμετωπίζει τη δομή του εγγράφου ως πρωτεύον σήμα ανάκτησης, αντί για απλά text chunks ή εικόνες σελίδας. Χρησιμοποιεί Document Hierarchical Parsing (DHP) για να ανακατασκευάσει ένα λογικό ετερογενές γράφο με ρητές σχέσεις γονέα–παιδιού. Κατά την ανάκτηση ακολουθεί

μια στρατηγική coarse-to-fine: πρώτα εκτελεί καθολικό routing με ιεραρχικά ευρετήρια για να περιορίσει το corpus, έπειτα κατατάσσει τις ενότητες με μια στρατηγική πολυτροπικής σύντηξης που επιλέγει τα πιο διακριτικά τεκμήρια, και τελικά συναρμολογεί έναν token-efficient υπογράφο τεκμηρίων μέσω υβριδικής δομικής-σημασιολογικής συσκευασίας. Το HiKEY έχει ισχυρή εξάρτηση από OCR και layout parsing, γεγονός που μπορεί να περιορίσει την εφαρμογή του σε καθαρά κείμενα ή σε corpora χωρίς ομοιόμορφη δομή.

Metadata-RAG. Το Metadata-RAG [29] είναι ένα multi-stage RAG πλαίσιο που αξιοποιεί μεταδεδομένα παραγόμενα από LLM για οικονομικά έγγραφα. Περιλαμβάνει προσεγγίσεις όπου document- και chunk-level metadata χρησιμοποιούνται για filtering, query restriction, contextual enrichment ή reranking. Η metadata-based retrieval μπορεί να περιορίσει τον χώρο αναζήτησης με βάση attributes όπως πηγή, κατηγορία, ημερομηνία, τύπο εγγράφου ή ταυτότητα ενότητας, πριν εφαρμοστεί σημασιολογική ομοιότητα. Πρόκειται για μία φθηνότερη και πιο ελεγχόμενη προσέγγιση, της οποίας όμως η αποτελεσματικότητα εξαρτάται από την ποιότητα, την πληρότητα και τη συνέπεια των διαθέσιμων μεταδεδομένων.

2.7 Ερευνητικό Κενό

Η ανασκόπηση της βιβλιογραφίας δείχνει ότι τα συστήματα Retrieval-Augmented Generation έχουν πλέον ωριμάσει ως προς τη βασική τους αρχιτεκτονική. Η διαδικασία δημιουργίας embeddings, η χρήση εξωτερικών vector databases και η αξιοποίηση ενός LLM για την παραγωγή της τελικής απάντησης αποτελούν πλέον καθιερωμένες πρακτικές. Παρόλα αυτά, αρκετές σχεδιαστικές επιλογές εξακολουθούν να αποτελούν αντικείμενο ενεργής έρευνας, όπως προκύπτει από τη συγκριτική ανάλυση των δέκα αρχιτεκτονικών αναφοράς.

Ένα πρώτο ζήτημα αφορά τον τρόπο με τον οποίο οργανώνεται το corpus πριν από τη δημιουργία των embeddings. Στη βιβλιογραφία συναντώνται κυρίως τεχνικές flat chunking, όπου κάθε τμήμα κειμένου αντιμετωπίζεται ως μία αυτόνομη μονάδα πληροφορίας. Η προσέγγιση αυτή απλοποιεί σημαντικά την υλοποίηση, ωστόσο δεν αξιοποιεί απαραίτητα τη φυσική δομή που υπάρχει σε πολλά είδη εγγράφων. Από την άλλη πλευρά, οι ιεραρχικές ή graph-based προσεγγίσεις (RAPTOR, LightRAG, HippoRAG 2, PathRAG, KAG) εισάγουν σημαντική πολυπλοκότητα, συχνά βασιζόμενες σε μοντέλα παραγωγής περιλήψεων ή εξαγωγής οντοτήτων, τα οποία αυξάνουν τόσο το κόστος όσο και τη μη-ντετερμινιστικότητα του pipeline.

Πίνακας 2.1: Συνοπτική σύγκριση των αρχιτεκτονικών αναφοράς.

Αρχιτεκτονική	**Κύρια ιδέα**	**Κύρια συνεισφορά**	**Βασικός περιορισμός**
LongRAG	Μεγάλες μονάδες ανάκτησης	Διατήρηση εκτεταμένου συμφραζομένου	Χαμηλότερη granularity
RAPTOR	Αναδρομικό δέντρο περιλήψεων	Ανάκτηση σε πολλά επίπεδα αφαίρεσης	Κόστος και πιθανή παραμόρφωση
HippoRAG 2	Γράφος γνώσης και PPR	Associative και multi-hop ανάκτηση	Εξάρτηση από graph quality
LightRAG	Dual-level graph–vector	Local και global knowledge	Κόστος εξαγωγής και πολυπλοκότητα
PathRAG	Ανάκτηση σχεσιακών διαδρομών	Μείωση redundancy, explainability	Εξάρτηση από πληρότητα γράφου
MemoRAG	Global memory και clues	Implicit information needs	Κίνδυνος clue bias
KAG	Λογικά καθοδηγούμενος γράφος	Domain rules και συλλογιστική	Υψηλό κόστος μοντελοποίησης
DISRetrieval	Ρητορική ιεραρχία (RST)	Γλωσσολογικά θεμελιωμένη ανάκτηση	Εξάρτηση από parser
HiKEY	Ιεραρχική πολυτροπική ανάκτηση	Routing και πολυτροπική σύντηξη	Εξάρτηση από OCR/layout
Metadata-RAG	Φιλτράρισμα μεταδεδομένων	Απλή, ερμηνεύσιμη μείωση χώρου	Εξάρτηση από metadata coverage

Ένα δεύτερο ζήτημα αφορά τη διαδικασία της ανάκτησης. Πολλές εργασίες βασίζονται αποκλειστικά σε dense retrieval, χρησιμοποιώντας τη σημασιολογική ομοιότητα μεταξύ embeddings ως μοναδικό κριτήριο αναζήτησης. Αντίθετα, τα τελευταία χρόνια εμφανίζονται όλο και περισσότερες υβριδικές προσεγγίσεις, οι οποίες συνδυάζουν dense και sparse retrieval. Η αποτελεσματικότητα των προσεγγίσεων αυτών έχει ήδη μελετηθεί σε αρκετά datasets, παραμένει όμως περιορισμένη η συστηματική αξιολόγησή τους κάτω από δίκαιες συνθήκες σύγκρισης, με κοινό canonical dataset envelope και κοινά ground-truth projections.

Ένα τρίτο ζήτημα αφορά την ισορροπία μεταξύ granularity και context. Οι προσεγγίσεις μεγάλων μονάδων (LongRAG) θυσιάζουν την ακρίβεια της αναζήτησης για χάρη της διατήρησης ευρύτερου context, ενώ οι προσεγγίσεις μικρών chunks επιτυγχάνουν καλύτερη σημασιολογική διάκριση αλλά χάνουν τη σύνδεση με το ευρύτερο νόημα. Λύσεις που συνδυάζουν και τα δύο, μέσω parent–child ιεραρχιών, έχουν προταθεί (LlamaIndex Parent Retriever pat-

tern) αλλά συνήθως αξιολογούνται σε μικρότερη κλίμακα ή σε διαφορετικά corpora.

Ένα τέταρτο ζήτημα αφορά την αξιοπιστία και την αναπαραγωγιμότητα. Οι LLM-based εξαγωγές και οι παραγωγές περιλήψεων εισάγουν στοιχεία μη-νετερμινισμού, τα οποία δυσχεραίνουν τη σύγκριση μεταξύ αρχιτεκτονικών. Παράλληλα, όταν πολλά chunks, graph nodes ή summaries αντιστοιχούν στο ίδιο document, η αρχιτεκτονική πρέπει να συνδυάσει τα σήματα χωρίς να χάσει την canonical ταυτότητα του εγγράφου, τη σειρά προέλευσης, τη σχέση child–parent και την προέλευση κάθε score.

Με βάση τα παραπάνω, η παρούσα εργασία δεν επιχειρεί να προτείνει έναν νέο αλγόριθμο retrieval ούτε ένα νέο γλωσσικό μοντέλο. Αντίθετα, επικεντρώνεται στον συνολικό σχεδιασμό του retrieval pipeline, εξετάζοντας κατά πόσο διαφορετικές αρχιτεκτονικές επιλογές μπορούν να βελτιώσουν την ποιότητα της ανάκτησης γνώσης σε ετερογενή long-context δεδομένα, με έμφαση στα νομικά κείμενα, υπό συνθήκες δίκαιης σύγκρισης.

Πιο συγκεκριμένα, η εργασία διερευνά τα ακόλουθα ερευνητικά ερωτήματα:

- Μπορεί η αναγνώριση της εσωτερικής δομής των εγγράφων να οδηγήσει σε αποτελεσματικότερη οργάνωση του corpus και βελτιωμένη ανάκτηση;
- Επηρεάζει η χρήση hierarchical chunking την ποιότητα της ανάκτησης σε σχέση με μία επίπεδη (*flat*) προσέγγιση;
- Μπορεί μία hybrid retrieval αρχιτεκτονική να επιτύχει καλύτερα αποτελέσματα από ένα αποκλειστικά dense retrieval σύστημα στο ίδιο corpus;
- Είναι δυνατόν η οργάνωση των δεδομένων σε διακριτές δομικές οντότητες να διευκολύνει μελλοντικές επεκτάσεις της αρχιτεκτονικής, χωρίς να μεταβληθεί ο βασικός μηχανισμός retrieval;
- Πώς συγκρίνεται η προτεινόμενη αρχιτεκτονική με τις δέκα αρχιτεκτονικές αναφοράς, υπό συνθήκες δίκαιης σύγκρισης και κοινού canonical dataset envelope;

Τα παραπάνω ερωτήματα αποτελούν το σημείο εκκίνησης της παρούσας εργασίας και καθοδηγούν τον σχεδιασμό της προτεινόμενης αρχιτεκτονικής, η οποία παρουσιάζεται αναλυτικά στο επόμενο κεφάλαιο.

Κεφάλαιο 3

Προτεινόμενη Αρχιτεκτονική

3.1 Στόχοι Σχεδιασμού

Στο κεφάλαιο αυτό παρουσιάζεται η προτεινόμενη αρχιτεκτονική του συστήματος, καθώς και οι βασικές σχεδιαστικές επιλογές που ακολουθήθηκαν. Η αρχιτεκτονική σχεδιάζεται με στόχο την αποδοτική ανάκτηση πληροφορίας από μεγάλα, δομημένα έγγραφα, διατηρώντας όσο το δυνατόν περισσότερο τη λογική και σημασιολογική δομή τους. Η προσέγγιση που ακολουθείται δεν αντιμετωπίζει τα έγγραφα ως μια απλή ακολουθία από ανεξάρτητα chunks. Αντίθετα, γίνεται προσπάθεια να αναγνωριστούν οι επιμέρους δομικές ενότητες κάθε εγγράφου και να αξιοποιηθούν κατά την διαδικασία της ανάκτησης.

Το σύστημα βασίζεται σε δύο βασικά στάδια. Αρχικά κατασκευάζεται μία εξωτερική βάση γνώσης (*offline stage*), όπου πραγματοποιείται η επεξεργασία των εγγράφων, η δημιουργία των embeddings και η αποθήκευσή τους σε διανυσματική βάση δεδομένων. Στη συνέχεια ακολουθεί το *online stage*, κατά το οποίο ένα ερώτημα μετατρέπεται σε διανυσματική αναπαράσταση και αναζητούνται τα περισσότερο σχετικά έγγραφα μέσα στη βάση.

Κατά τον σχεδιασμό της αρχιτεκτονικής θα δοθεί ιδιαίτερη έμφαση στη διατήρηση της δομής των εγγράφων. Για τον λόγο αυτό δεν επιλέγεται η απλή διάσπαση του κειμένου σε μεγάλου μεγέθους τμήματα, όπως συμβαίνει αρκετές φορές στη βιβλιογραφία[14, 17]. Αντί αυτού, σχεδιάζεται μια ιεραρχική αναπαράσταση των εγγράφων, όπου μικρότερα τμήματα χρησιμοποιούνται αποκλειστικά για την αναζήτηση, ενώ η πληροφορία επιστρέφεται στον χρήστη ως μία μεγαλύτερη και ολοκληρωμένη νοηματική ενότητα.

Η αρχιτεκτονική παραμένει όσο το δυνατόν πιο ανεξάρτητη από συγκεκριμένα μοντέλα ή τεχνολογίες. Παρότι στην παρούσα εργασία επιλέγονται συγκεκριμένα εργαλεία, όπως ο

BGE-M3 για τη δημιουργία embeddings και η Qdrant ως vector database, οι επιλογές αυτές αποτελούν υλοποιητικές αποφάσεις και όχι περιορισμούς της προτεινόμενης μεθοδολογίας. Αντίστοιχα εργαλεία θα μπορούσαν να χρησιμοποιηθούν χωρίς να αλλάζει η συνολική φιλοσοφία του συστήματος.

Στις επόμενες ενότητες παρουσιάζεται αρχικά η συνολική εικόνα της αρχιτεκτονικής και στη συνέχεια περιγράφονται συνοπτικά τα επιμέρους στάδια που την αποτελούν. Η λεπτομερής ανάλυση κάθε υποσυστήματος, καθώς και η πειραματική αξιολόγησή του, θα παρουσιαστούν στα επόμενα κεφάλαια της εργασίας.

3.2 Συνολική Αρχιτεκτονική του Συστήματος

Η συνολική αρχιτεκτονική του συστήματος παρουσιάζεται στο Σχήμα 3.1. Σχεδιάστηκε έτσι ώστε κάθε επιμέρους στάδιο να εκτελεί μία συγκεκριμένη λειτουργία, χωρίς όμως να εξαρτάται από τα υπόλοιπα. Το διάγραμμα είναι περιγραφικό – και επαρκές για το σημείο αυτό – να αντιληφθούμε το γενικό πλάνο της αρχιτεκτονικής της εργασίας.

Η λειτουργία του συστήματος διαχωρίζεται σε δύο βασικά στάδια. Το πρώτο αφορά την προετοιμασία και οργάνωση της γνώσης (*offline stage*), ενώ το δεύτερο αφορά την πραγματική διαδικασία ανάκτησης πληροφορίας κατά την υποβολή ενός ερωτήματος (*online stage*). Ο διαχωρισμός αυτός επιτρέπει το μεγαλύτερο υπολογιστικό κόστος να μεταφέρεται εκτός χρόνου εκτέλεσης, ώστε η αναζήτηση να παραμένει όσο το δυνατόν ταχύτερη.

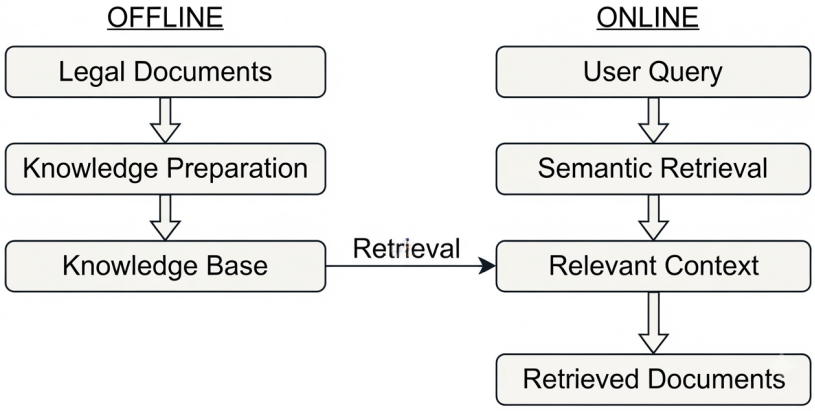
Κατά το *offline stage* τα έγγραφα εισάγονται στο σύστημα και υποβάλλονται σε μία σειρά από στάδια επεξεργασίας. Αρχικά επιχειρείται η αναγνώριση της δομής κάθε εγγράφου και η οργάνωσή του σε διακριτές νοηματικές ενότητες. Στη συνέχεια δημιουργείται μία ιεραρχική αναπαράσταση των δεδομένων, παράγονται οι διανυσματικές αναπαραστάσεις των μικρότερων τμημάτων του κειμένου και τελικά αυτές αποθηκεύονται σε εξωτερική βάση διανυσμάτων μαζί με τα απαραίτητα μεταδεδομένα.

Το *online stage* ενεργοποιείται κάθε φορά που ο χρήστης υποβάλλει ένα νέο ερώτημα. Το ερώτημα μετατρέπεται στην αντίστοιχη διανυσματική αναπαράσταση και εκτελείται υβριδική αναζήτηση στη βάση δεδομένων. Τα αποτελέσματα που επιστρέφονται δεν αποτελούν την τελική απάντηση, αλλά χρησιμοποιούνται ώστε να ανακτηθούν οι αντίστοιχες μεγαλύτερες νοηματικές ενότητες των αρχικών εγγράφων. Έτσι αποφεύγεται η επιστροφή απομονωμένων προτάσεων ή μικρών αποσπασμάτων που συχνά δεν επαρκούν για την κατανόηση

του περιεχομένου.

Η προτεινόμενη αρχιτεκτονική ακολουθεί μία ροή επεξεργασίας όπου κάθε στάδιο παράγει την απαραίτητη πληροφορία για το επόμενο. Παρότι η υλοποίηση της παρούσας εργασίας επικεντρώνεται κυρίως στο σύστημα ανάκτησης γνώσης, η δομή αυτή επιτρέπει μελλοντικά την εύκολη ενσωμάτωση ενός συστήματος παραγωγής κειμένου, χωρίς να απαιτούνται αλλαγές στον τρόπο με τον οποίο οργανώνεται και ανακτάται η γνώση. Για τον λόγο αυτό, η έξοδος του συστήματος δεν είναι απλώς μία λίστα από σχετικά chunks, αλλά ένα σύνολο ολοκληρωμένων νοηματικών ενοτήτων που μπορούν να αξιοποιηθούν είτε απευθείας από τον χρήστη είτε ως είσοδος σε επόμενα στάδια επεξεργασίας.

Στις επόμενες ενότητες παρουσιάζονται συνοπτικά τα επιμέρους στάδια της αρχιτεκτονικής. Η αναλυτική περιγραφή του σχεδιασμού, των επιλογών που πραγματοποιήθηκαν και των πειραματικών αποτελεσμάτων θα δοθεί στα αντίστοιχα κεφάλαια της εργασίας.



Σχήμα 3.1: Συνολική αρχιτεκτονική του προτεινόμενου συστήματος.

3.3 Offline Stage

Το πρώτο στάδιο της αρχιτεκτονικής αφορά την κατασκευή της βάσης γνώσης και εκτελείται πριν το σύστημα δεχθεί οποιοδήποτε ερώτημα από τον χρήστη. Πρόκειται για μία διαδικασία που πραγματοποιείται μία φορά για κάθε έκδοση του συνόλου δεδομένων και περιλαμβάνει όλες τις απαραίτητες ενέργειες ώστε τα έγγραφα να μετατραπούν σε μορφή κατάλληλη για αποδοτική αναζήτηση.

3.3.1 Έγγραφα Εισόδου

Η είσοδος του συστήματος αποτελείται από το διαθέσιμο σύνολο εγγράφων. Περισσότερες πληροφορίες σχετικά με τα δεδομένα, πέρα από όσες έχουμε ήδη αναφερθεί στα προηγούμενα κεφάλαια, θα αναφέρονται μόνο εφόσον υπάρξει σχετική άδεια. Ωστόσο, ανεξάρτητα από το περιεχόμενο του εκάστοτε corpus, η ίδια διαδικασία μπορεί να εφαρμοστεί χωρίς ουσιαστικές αλλαγές και σε άλλα σύνολα μεγάλων εγγράφων.

3.3.2 Ανάλυση Δεδομένων

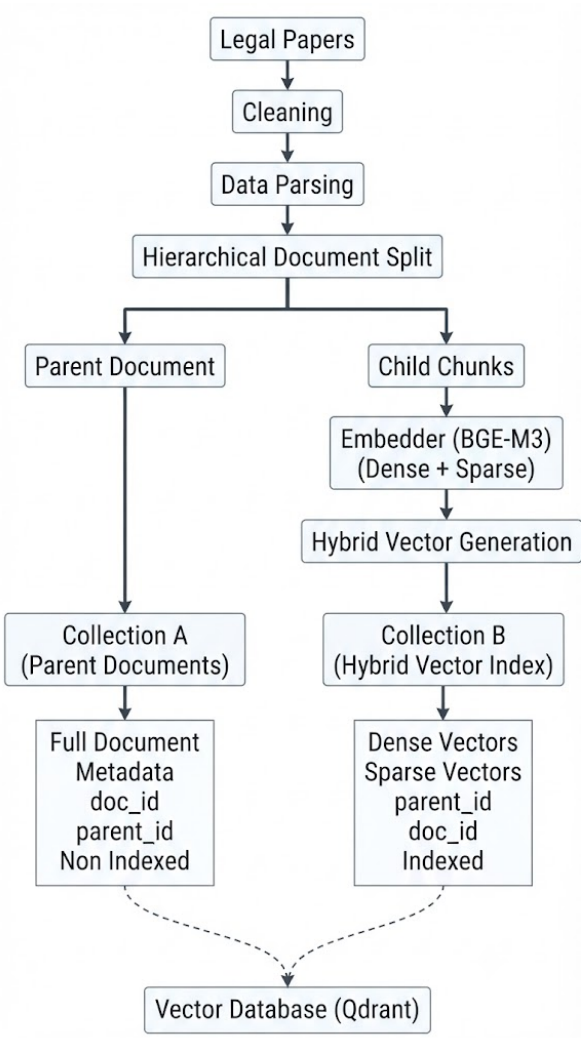
Η πρώτη σχεδιαστική απόφαση αφορά την επεξεργασία των εγγράφων πριν αυτά εισαχθούν στη βάση δεδομένων. Αντί να δημιουργηθούν απευθείας διανυσματικές αναπαραστάσεις για ολόκληρα τα έγγραφα, επιλέγεται να προηγηθεί μία διαδικασία ανάλυσης της δομής τους. Με τον τρόπο αυτό επιχειρείται να διατηρηθεί η λογική οργάνωση της πληροφορίας και να αποφευχθεί η απώλεια σημαντικών σχέσεων μεταξύ των επιμέρους τμημάτων του κειμένου.

3.3.3 Ιεραρχικός Διαχωρισμός

Μετά την αναγνώριση της δομής ακολουθεί η δημιουργία μιας ιεραρχικής αναπαράστασης των εγγράφων. Κάθε μεγαλύτερη νοηματική ενότητα συνδέεται με μικρότερα τμήματα κειμένου τα οποία θα χρησιμοποιηθούν αποκλειστικά κατά την αναζήτηση. Η επιλογή αυτή επιτρέπει να διαχωριστεί η διαδικασία της ανάκτησης από την τελική παρουσίαση των αποτελεσμάτων, χωρίς να απαιτείται επεξεργασία ολόκληρου του εγγράφου κάθε φορά που εκτελείται ένα ερώτημα.

3.3.4 Διανυσματικές Αναπαραστάσεις

Στη συνέχεια παράγονται οι διανυσματικές αναπαραστάσεις των μικρότερων αυτών τμημάτων και αποθηκεύονται μαζί με τα απαραίτητα μεταδεδομένα σε εξωτερική διανυσματική βάση δεδομένων. Τα μεγαλύτερα τμήματα των εγγράφων διατηρούνται επίσης στη βάση, όμως δεν συμμετέχουν άμεσα στη διαδικασία αναζήτησης. Ο ρόλος τους είναι διαφορετικός· χρησιμοποιούνται αποκλειστικά όταν χρειάζεται να ανακτηθεί το πλήρες περιεχόμενο μιας σχετικής νοηματικής ενότητας.



Σχήμα 3.2: Ροή επεξεργασίας του offline σταδίου της προτεινόμενης αρχιτεκτονικής.

3.3.5 Βάση Δεδομένων

Το αποτέλεσμα του *offline stage* είναι μία πλήρως οργανωμένη βάση γνώσης, η οποία μπορεί να χρησιμοποιηθεί από το στάδιο της ανάκτησης χωρίς να απαιτείται εκ νέου επεξεργασία των αρχικών εγγράφων. Η συνολική ροή του σταδίου παρουσιάζεται σχηματικά στο Σχήμα 3.2.

3.4 Online Stage

Αφού ολοκληρωθεί η κατασκευή της βάσης γνώσης, το σύστημα είναι έτοιμο να δεχθεί ερωτήματα από τον χρήστη. Σε αντίθεση με το *offline stage*, όπου πραγματοποιούνται όλες οι απαιτητικές υπολογιστικά διαδικασίες, το *online stage* έχει ως κύριο στόχο την όσο το

δυνατόν ταχύτερη ανάκτηση της σχετικής πληροφορίας.

3.4.1 Ερώτημα Χρήστη και Διανυσματικές Αναπαραστάσεις

Η διαδικασία ξεκινά με την εισαγωγή ενός ερωτήματος φυσικής γλώσσας. Το ερώτημα μετατρέπεται στην αντίστοιχη διανυσματική του αναπαράσταση χρησιμοποιώντας το ίδιο μοντέλο που χρησιμοποιήθηκε και κατά την κατασκευή της βάσης. Με αυτόν τον τρόπο διασφαλίζεται ότι τα διανύσματα των ερωτημάτων και των αποθηκευμένων εγγράφων βρίσκονται στον ίδιο σημασιολογικό χώρο.

3.4.2 Υβριδική Αναζήτηση, Ανάκτηση και Κατάταξη

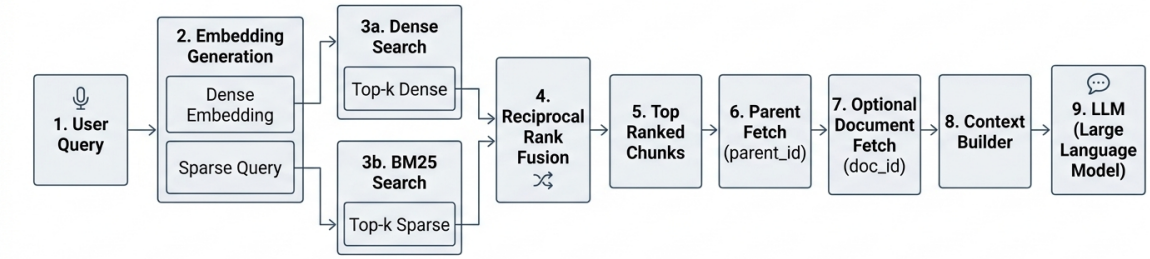
Στη συνέχεια πραγματοποιείται η αναζήτηση στη διανυσματική βάση δεδομένων. Η αναζήτηση δεν βασίζεται αποκλειστικά στη σημασιολογική ομοιότητα, αλλά συνδυάζει διαφορετικές μορφές πληροφορίας, ώστε να λαμβάνονται υπόψη τόσο το νόημα όσο και η ακριβής αντιστοίχιση σημαντικών όρων. Τα επιμέρους αποτελέσματα συγχωνεύονται σε μία ενιαία κατάταξη και επιστρέφονται τα περισσότερο σχετικά τμήματα κειμένου.

3.4.3 Ανάκτηση Εγγράφου

Στο σημείο αυτό όμως η διαδικασία δεν ολοκληρώνεται. Τα τμήματα που ανακτώνται αντιστοιχούν στα μικρότερα στοιχεία της ιεραρχικής δομής και χρησιμοποιούνται αποκλειστικά για τον εντοπισμό της πληροφορίας. Για κάθε αποτέλεσμα αναζητείται το αντίστοιχο γονικό έγγραφο (*parent document*), το οποίο περιέχει την πλήρη νοηματική ενότητα από την οποία προήλθε το συγκεκριμένο τμήμα.

Η επιλογή αυτή επιτρέπει στο σύστημα να συνδυάζει τα πλεονεκτήματα των μικρών chunks με την πληρότητα μεγαλύτερων ενοτήτων κειμένου. Η αναζήτηση πραγματοποιείται σε μικρότερα τμήματα, γεγονός που διευκολύνει τον ακριβή εντοπισμό της πληροφορίας, ενώ η τελική έξοδος περιλαμβάνει μεγαλύτερα αποσπάσματα τα οποία μπορούν να διαβαστούν και να ερμηνευθούν χωρίς να χάνεται το απαραίτητο συμφραζόμενο.

Το τελικό αποτέλεσμα του *online stage* δεν αποτελεί ακόμη απάντηση σε κάποιο ερώτημα, αλλά ένα σύνολο σχετικών νοηματικών ενοτήτων ταξινομημένων ως προς τη συνάφειά τους. Η πληροφορία αυτή μπορεί να αξιοποιηθεί απευθείας από τον χρήστη ή να αποτελέσει είσοδο για μεταγενέστερα στάδια επεξεργασίας, όπως ένα σύστημα παραγωγής κειμένου ή



Σχήμα 3.3: Ροή του online σταδίου της προτεινόμενης αρχιτεκτονικής.

ένας agent. Η συνολική ροή παρουσιάζεται στο Σχήμα 3.3.

3.5 Σχεδιαστικές Αποφάσεις

Η σχεδίαση της προτεινόμενης αρχιτεκτονικής βασίστηκε στην παραδοχή ότι η ποιότητα ενός συστήματος ανάκτησης γνώσης δεν εξαρτάται αποκλειστικά από το μοντέλο αναζήτησης που χρησιμοποιείται[14, 5]. Εξίσου σημαντικό ρόλο παίζει ο τρόπος με τον οποίο οργανώνεται η πληροφορία πριν ακόμη αποθηκευτεί στη βάση δεδομένων. Για τον λόγο αυτό, η εργασία δεν επικεντρώνεται μόνο στην επιλογή ενός embedder ή μιας vector database, αλλά αντιμετωπίζει ολόκληρη τη διαδικασία ως μία ενιαία αλυσίδα επεξεργασίας.

Γιατί δεν χρησιμοποιείται flat chunking;

Μία από τις πρώτες αποφάσεις ήταν να μη χρησιμοποιηθεί η απλή διάσπαση των εγγράφων σε ανεξάρτητα τμήματα σταθερού μεγέθους. Αν και η προσέγγιση αυτή είναι ιδιαίτερα διαδεδομένη στη βιβλιογραφία, παρουσιάζει έναν βασικό περιορισμό. Τα όρια των chunks καθορίζονται συνήθως από τον αριθμό των tokens και όχι από τη φυσική δομή του εγγράφου. Έτσι, είναι πιθανό δύο συνεχόμενα τμήματα να ανήκουν στην ίδια λογική ενότητα ή, αντίθετα, ένα μόνο chunk να περιέχει πληροφορία από διαφορετικά θέματα. Η παρατήρηση αυτή αποτέλεσε την αφετηρία για την υιοθέτηση μιας περισσότερο δομικής προσέγγισης.

Γιατί επιλέγεται ιεραρχική αναπαράσταση;

Για τον ίδιο λόγο επιλέγεται η δημιουργία μιας ιεραρχικής αναπαράστασης των εγγράφων. Τα μικρότερα τμήματα χρησιμοποιούνται αποκλειστικά για την αναζήτηση, ενώ η πληροφορία οργανώνεται γύρω από μεγαλύτερες νοηματικές ενότητες. Με τον τρόπο αυτό η διαδικασία της ανάκτησης αποσυνδέεται από τον τρόπο παρουσίασης των αποτελεσμάτων. Το σύστημα αναζητά μικρά και περισσότερο εξειδικευμένα τμήματα κειμένου, όμως επιστρέφει στον χρήστη ολόκληρες ενότητες, οι οποίες μπορούν να διαβαστούν χωρίς να χάνεται το απαραίτητο συμφραζόμενο.

Γιατί επιλέγεται hybrid retrieval;

Αντίστοιχη λογική ακολουθήθηκε και στην επιλογή της μεθόδου ανάκτησης. Η αποκλειστική χρήση σημασιολογικής αναζήτησης θεωρήθηκε ότι ενδέχεται να μην είναι επαρκής σε corpora όπου συγκεκριμένοι όροι, αριθμοί, κωδικοί ή αναφορές έχουν ιδιαίτερη σημασία — όπως συμβαίνει συχνά στα νομικά, τα ιατρικά και τα τεχνικά κείμενα. Από την άλλη πλευρά, μία καθαρά λεξικογραφική αναζήτηση αδυνατεί να εντοπίσει έγγραφα με παρόμοιο νόημα όταν χρησιμοποιείται διαφορετική ορολογία. Για τον λόγο αυτό σχεδιάζεται ένα υβριδικό σχήμα ανάκτησης, στο οποίο συνδυάζονται και οι δύο μορφές πληροφορίας.

Γιατί επιλέγεται εξωτερική vector database;

Παράλληλα, επιλέγεται η αποθήκευση της γνώσης σε εξωτερική διανυσματική βάση δεδομένων και όχι η δυναμική δημιουργία embeddings κατά την εκτέλεση κάθε ερωτήματος. Η επιλογή αυτή μεταφέρει το μεγαλύτερο υπολογιστικό κόστος στο *offline stage*, επιτρέποντας στο σύστημα να ανταποκρίνεται σημαντικά ταχύτερα όταν δεχθεί ένα νέο ερώτημα. Επιπλέον, η ανεξάρτητη αποθήκευση της γνώσης καθιστά ευκολότερη τη μελλοντική αντικατάσταση επιμέρους υποσυστημάτων χωρίς να απαιτείται επανασχεδιασμός της συνολικής αρχιτεκτονικής.

Τέλος, όλες οι παραπάνω επιλογές πραγματοποιήθηκαν έχοντας ως βασικό στόχο τη δημιουργία ενός συστήματος το οποίο μπορεί να αποτελέσει τη βάση για πιο σύνθετες εφαρμογές. Η έξοδος της διαδικασίας ανάκτησης δεν περιορίζεται σε μία λίστα από σχετικά chunks, αλλά παράγει ένα σύνολο ολοκληρωμένων νοηματικών ενοτήτων. Η πληροφορία αυτή μπορεί να αξιοποιηθεί άμεσα από τον χρήστη, ενώ παράλληλα είναι κατάλληλη ώστε να χρησι-

μοποιηθεί ως είσοδος από ένα σύστημα παραγωγής κειμένου ή από έναν agent σε επόμενη φάση της έρευνας.

Κεφάλαιο 4

Υλοποίηση

Στο προηγούμενο κεφάλαιο παρουσιάστηκε η συνολική αρχιτεκτονική του προτεινόμενου συστήματος καθώς και οι βασικές σχεδιαστικές αποφάσεις που οδήγησαν στη συγκεκριμένη μορφή του. Η περιγραφή όμως της αρχιτεκτονικής από μόνη της δεν αρκεί για να τεκμηριώσει την αποτελεσματικότητα της προτεινόμενης προσέγγισης.

Στο παρόν κεφάλαιο παρουσιάζεται αναλυτικά η υλοποίηση κάθε επιμέρους σταδίου του συστήματος. Για κάθε υποσύστημα περιγράφονται αρχικά οι διαθέσιμες εναλλακτικές λύσεις και αιτιολογείται η επιλογή που πραγματοποιήθηκε. Στη συνέχεια παρουσιάζεται η διαδικασία υλοποίησης, τα μοντέλα δεδομένων που χρησιμοποιούνται, οι αλγόριθμοι που παράγουν κάθε τεχνούργημα και οι invariants που κάθε στάδιο διατηρεί. Η παρουσίαση ακολουθεί την ίδια σειρά με την οποία εκτελείται το *offline pipeline*.

Στόχος του κεφαλαίου δεν είναι μόνο η παρουσίαση της τελικής υλοποίησης, αλλά και η τεκμηρίωση των επιλογών που πραγματοποιήθηκαν κατά την ανάπτυξη του συστήματος. Ιδιαίτερη έμφαση δίνεται στη *ντετερμινιστικότητα* της pipeline: κάθε αναγνωριστικό, κάθε σπάσιμο ισοπαλίας, κάθε μορφή σειριοποίησης και κάθε κανόνας συνάθροισης αποτελούν ντετερμινιστικές συναρτήσεις της εισόδου. Η ιδιότητα αυτή καθιστά το σύστημα ελέγξιμο, επαναλήψιμο και δίκαια συγκρίσιμο με άλλες αρχιτεκτονικές.

4.1 Δεδομένα και Canonical Μοντέλο

Η αξιολόγηση της προτεινόμενης αρχιτεκτονικής πραγματοποιείται σε τέσσερα ετερογενή σύνολα δεδομένων, τα οποία έχουν κανονικοποιηθεί σε ένα ενιαίο σχήμα (canonical envelope) ώστε να είναι άμεσα συγκρίσιμα μεταξύ τους και να μπορούν να καταναλωθούν

από την ίδια pipeline χωρίς τροποποιήσεις.

4.1.1 Σύνολα Δεδομένων

Τα τέσσερα σύνολα καλύπτουν ένα ευρύ φάσμα μηκών εγγράφων, μηκών ερωτημάτων και δομών ground truth:

- **LaRA**: σύνολο μακρών εγγράφων με σύντομα στοχευμένα ερωτήματα. 131 έγγραφα, μέσο μήκος $\approx 40\,463$ whitespace tokens, ground truth ακριβώς ενός σχετικού εγγράφου ανά ερώτημα. Αποτελεί το ακραίο σενάριο long-context.

- **CLERK (CLERC)**: νομική νομολογία με σύντομα έγγραφα και μακρά ερωτήματα. 2 756 έγγραφα, μέσο μήκος ≈ 233 tokens, αλλά μέσο μήκος ερωτήματος $\approx 16\,322$ χαρακτήρες. Η μέση cardinality του ground truth είναι 2.77 (μέγιστο 9).

- **CUAD**: συμβόλαια με πολλαπλά ερωτήματα ανά έγγραφο. 510 έγγραφα, μέσο μήκος $\approx 7\,861$ tokens, 20 910 ερωτήματα συνολικά. Χαρακτηρίζεται από την κυριαρχία της *αρνητικής κλάσης*: το 67.9% των ερωτημάτων έχει κενό ground truth.

- **GreekBarBench**: ελληνόγλωσσο σύνολο νομικών ερωτήσεων. 284 έγγραφα, μέσο μήκος $\approx 10\,162$ tokens, ένα ερώτημα ανά έγγραφο. Είναι το μόνο μη αγγλόφωνο σύνολο.

Ο Πίνακας 4.1 συνοψίζει τα βασικά στατιστικά.

Πίνακας 4.1: Συνοπτικά στατιστικά των τεσσάρων συνόλων δεδομένων. Τα tokens είναι whitespace-based.

Μέτρο	**LaRA**	**CLERK**	**CUAD**	**GreekBarBench**
Έγγραφα	131	2 756	510	284
Ερωτήματα	2 326	1 000	20 910	284
Μέσο μήκος εγγράφου (tokens)	40 464	233	7 861	10 162
Μέσο μήκος ερωτήματος (χαρακτήρες)	112	16 322	260	194
Μέση cardinality GT	1.00	2.77	1.00	1.00
Κενά GT	0	0	14 208	0

Η επιλογή των τεσσάρων αυτών συνόλων δεν είναι τυχαία. Η *αντιστροφή* μεταξύ μήκους εγγράφου και μήκους ερωτήματος (LaRA: μακρά έγγραφα/σύντομα ερωτήματα· CLERK: σύντομα έγγραφα/μακρά ερωτήματα) διασφαλίζει ότι καμία αρχιτεκτονική δεν ευνοείται συστηματικά από ένα μόνο καθεστώς μήκους. Παράλληλα, η παρουσία της ελληνικής γλώσσας (GreekBarBench) και της αρνητικής κλάσης (CUAD) ασκεί πίεση σε διαφορετικές πτυχές του retrieval subsystem.

4.1.2 Canonical Envelope

Κάθε σύνολο είναι οργανωμένο σε τέσσερα αρχεία:

- `documents.jsonl`: τα canonical έγγραφα,
- `examples.jsonl`: τα ερωτήματα μαζί με το ground truth τους,
- `validation.json`: αναφορά επικύρωσης,
- `manifest.json`: ταυτότητα και checksums.

Το κύριο μοντέλο εισόδου είναι το `CanonicalDocument`, το οποίο περιλαμβάνει τα πεδία `doc_id`, `dataset`, `text_raw`, `text_normalized` και προαιρετικά `title`, `source_path`, `source_row` και `metadata`. Η διάκριση μεταξύ `text_raw` και `text_normalized` επιτρέπει τη διατήρηση της ακριβούς αρχικής μορφής παράλληλα με την κανονικοποιημένη εκδοχή στην οποία εφαρμόζονται όλα τα επόμενα στάδια.

Το μοντέλο `CanonicalExample` συνδέει ένα `CanonicalQuery` με το αντίστοιχο `CanonicalGroundTruth`. Το ground truth περιλαμβάνει τύπο (`GroundTruthType`), τη λίστα `relevant_ids` με τα canonical αναγνωριστικά των σχετικών εγγράφων, και προαιρετικά `answers`, `choices` ή `spans`. Οι validators επιβάλλουν τη συνέπεια μεταξύ `query_id` και `dataset` στα δύο συστατικά.

4.2 Ανάλυση Δομημένων Εγγράφων

4.2.1 Στόχοι

Το πρώτο στάδιο της προτεινόμενης αρχιτεκτονικής αφορά την ανάλυση των εγγράφων με σκοπό την αναγνώριση της εσωτερικής τους δομής. Παρότι τα έγγραφα του συνόλου

δεδομένων αποτελούνται από φυσικό κείμενο, στην πράξη περιλαμβάνουν λογικές ενότητες, οι οποίες δεν είναι πάντοτε εύκολο να εντοπιστούν με αυτοματοποιημένο τρόπο.

Η ύπαρξη αυτών των ενοτήτων θεωρείται ιδιαίτερα σημαντική για την υπόλοιπη διαδικασία ανάκτησης πληροφορίας. Εάν η δομή ενός εγγράφου αγνοηθεί και το κείμενο αντιμετωπιστεί ως μία απλή ακολουθία προτάσεων, είναι πιθανό να χαθεί πληροφορία σχετικά με τα όρια μεταξύ διαφορετικών θεματικών ή νοηματικών ενοτήτων [14, 17].

Στην παρούσα εργασία δεν επιχειρείται η ανακατασκευή της αρχικής μορφοποίησης των εγγράφων. Αντίθετα, στόχος είναι η αναγνώριση νοηματικών ή δομικών οντοτήτων (semantic parents) οι οποίες θα χρησιμοποιηθούν στα επόμενα στάδια της επεξεργασίας. Αξίζει να σημειωθεί ότι η ύπαρξη σταθερής δομής δεν είναι δεδομένη σε όλα τα κείμενα. Σε ορισμένες κατηγορίες εγγράφων τα όρια των ενοτήτων είναι εμφανή, ενώ σε άλλες η δομή προκύπτει κυρίως από το περιεχόμενο και τον τρόπο γραφής. Για τον λόγο αυτό, η διαδικασία parsing αντιμετωπίζεται ως ανεξάρτητο στάδιο της αρχιτεκτονικής.

4.2.2 Εναλλακτικές Στρατηγικές

Η αναγνώριση της δομής ενός δομημένου εγγράφου μπορεί να πραγματοποιηθεί με περισσότερους από έναν τρόπους:

- **Rule-based parsing**: χρήση κανονικών εκφράσεων και κανόνων για την αναγνώριση προτύπων (αριθμήσεις, επικεφαλίδες). Απλή στην υλοποίηση, αποδοτική όταν τα έγγραφα ακολουθούν συγκεκριμένη μορφή.

- **Σημασιολογικές προσεγγίσεις**: αξιοποίηση embeddings για τον εντοπισμό αλλαγών στο νόημα μεταξύ διαδοχικών τμημάτων.

- **Neural discourse parsing**: τεχνικές όπως η Θεωρία Ρητορικής Δομής (RST) που χρησιμοποιούνται από συστήματα όπως το DISRetrieval [27].

- **LLM-based parsing**: χρήση γλωσσικών μοντέλων για την αναγνώριση δομικών ορίων.

Οι δύο τελευταίες προσεγγίσεις παρουσιάζουν σημαντικά κόστη και εισάγουν μη-ντετερμινισμό, ο οποίος δυσχεραίνει την αναπαραγωγιμότητα. Στο πλαίσιο της παρούσας εργασίας, επιλέγεται μία rule-based προσέγγιση, εμπλουτισμένη με κλιμακωτά φίλτρα που μειώνουν τα false positives.

4.2.3 Επιλεγμένη Υλοποίηση: DeterministicStructuralParser

Ο parser υλοποιείται στην κλάση `DeterministicStructuralParser`. Η μέθοδος `parse()` εκτελεί τέσσερα βήματα:

Βήμα 1: Κατάτμηση σε παραγράφους. Η συνάρτηση `iter_paragraph_spans()` χωρίζει το κανονικοποιημένο κείμενο σε blocks χρησιμοποιώντας την κανονική έκφραση `(?:\r?\n[\t]*){2,}`, η οποία ανιχνεύει δύο ή περισσότερες διαδοχικές αλλαγές γραμμής. Κάθε block διατηρεί τα ακριβή όρια `start` και `end` στο αρχικό κείμενο.

Βήμα 2: Ανίχνευση επικεφαλίδων. Η συνάρτηση `detect_heading_reason()` ταξινομεί ένα block ως επικεφαλίδα μέσω τριών κλιμακωτών κανόνων:

- **Named**: το block ταιριάζει με λέξεις-κλειδιά όπως `chapter`, `section`, `article`, `part` ή τα ελληνικά αντίστοιχά τους.
- **Numbered**: το block ξεκινά με αρίθμηση της μορφής `1.`, `1.2.3`, `(1)` ή `IV.` και ικανοποιεί επιπλέον κριτήρια (`_looks_like_numbered_heading()`).
- **Uppercase**: τουλάχιστον το 90% των αλφαβητικών χαρακτήρων είναι κεφαλαία.

Πριν από τους τρεις κανόνες εφαρμόζονται βασικά φίλτρα: μήκος έως 120 χαρακτήρες, έως 14 λέξεις, τουλάχιστον 4 αλφαβητικοί χαρακτήρες, όχι URL-like ή equation-like μοτίβα.

Βήμα 3: Ομαδοποίηση. Τα blocks ομαδοποιούνται σε ενότητες, καθεμία από τις οποίες ξεκινά από ένα heading block. Εάν το πρώτο heading δεν είναι το πρώτο block, το αρχικό τμήμα εξάγεται ως ξεχωριστή ομάδα (preamble). Οι πολύ μικρές ομάδες (κάτω από `minimum_parent_characters` = 20 χαρακτήρες) συγχωνεύονται με τη γειτονική τους.

Βήμα 4: Κατασκευή parents. Για κάθε ομάδα δημιουργείται ένα `SemanticParent`. Το αναγνωριστικό `parent_id` παράγεται από τη συνάρτηση `build_parent_id()` και έχει τη μορφή `parent-{dataset}-{index:06d}-{fingerprint}`, όπου το fingerprint είναι τα πρώτα 12 δεκαεξαδικά ψηφία του SHA-256 του identity tuple.

4.2.4 Μοντέλο SemanticParent

Το κύριο μοντέλο εξόδου είναι το `SemanticParent`, το οποίο φέρει τρεις κατηγορίες πληροφορίας:

- **Ταυτότητα**: `parent_id`, `doc_id`, `dataset`.
- **Περιεχόμενο**: `text_normalized`, `text_raw`, `normalized_char_span`, `raw_char_span`, `token_span`, `token_count`.
- **Προέλευση**: `start_boundary` και `end_boundary` ως πλειάδες `BoundaryEvidence`, καθεμία με μέθοδο από το enum `BoundaryMethod` (DocumentStart, DocumentEnd, ExplicitHeading, DocumentPreamble, ParagraphBreak).

Οι validators επιβάλλουν ότι ένας parent δεν μπορεί να είναι γονέας του εαυτού του (`parent_parent_id!=parent_id`) και ότι αν το `normalized_char_span` είναι μη κενό, το `text_normalized` είναι επίσης μη κενό.

4.2.5 Invariants

Ο parser εγγυάται ότι:

1. το κείμενο κάθε parent ισούται με το ακριβές slice του κανονικοποιημένου κειμένου στο διάστημα του parent·
2. τα διαστήματα των parents είναι ξένα μεταξύ τους και η ένωσή τους καλύπτει το μη-κενό περιεχόμενο του εγγράφου·
3. τα `parent_id` είναι μοναδικά εντός του εγγράφου·
4. τα `doc_id` και `dataset` κάθε parent συμφωνούν με αυτά του εγγράφου.

Ο parser υπολογίζει επίσης ένα `source_fingerprint` (SHA-256 των `doc_id`, `dataset`, `text_raw`, `text_normalized`) το οποίο χρησιμοποιείται από τα επόμενα στάδια για ανίχνευση αποκλίσεων.

4.3 Ιεραρχικός Διαχωρισμός

4.3.1 Στόχοι

Η διαδικασία διαχωρισμού των εγγράφων σε μικρότερα τμήματα αποτελεί ένα από τα σημαντικότερα στάδια ενός συστήματος RAG. Η ποιότητα των chunks επηρεάζει άμεσα τόσο την ανάκτηση πληροφορίας όσο και την ποιότητα των τελικών απαντήσεων.

Στην παρούσα εργασία ο στόχος δεν είναι απλώς η δημιουργία μικρότερων αποσπασμάτων. Αντίθετα, επιδιώκεται η διατήρηση της σχέσης μεταξύ των επιμέρους τμημάτων και της αρχικής δομικής οντότητας. Κάθε chunk οφείλει να ανήκει σε ακριβώς έναν parent, χωρίς να διαπερνά τα όρια μεταξύ parents.

4.3.2 Εναλλακτικές Στρατηγικές

Στη βιβλιογραφία έχουν προταθεί αρκετές τεχνικές:

- **Fixed-size chunking**: διαχωρισμός ανά πρόταση ή ανά σταθερό αριθμό tokens. Απλό αλλά διασπά ενότητες.
- **Recursive splitting**: τα όρια επιλέγονται με βάση τη μορφοποίηση.
- **Semantic chunking**: εντοπισμός αλλαγών νοήματος μέσω embeddings.
- **Hierarchical chunking**: πολλαπλά επίπεδα αναπαράστασης (π.χ. RAPTOR [20], HiKEY [28]).
- **Flat chunking**: ανεξάρτητα chunks σταθερού μεγέθους, η προσέγγιση που κυριαρχεί σε κλασικά RAG συστήματα.

Η αρχιτεκτονική επιλέγει μία *ιεραρχική* στρατηγική με ρητή εξάρτηση από τα όρια των parents.

4.3.3 Επιλεγμένη Υλοποίηση: HierarchicalChildChunker

Η κλάση `HierarchicalChildChunker` υλοποιεί τη στρατηγική. Η μέθοδος `chunk_document()` δέχεται ένα `ParsedDocument` και επιστρέφει μία πλειάδα `ChildChunk`. Για κάθε parent:

1. Το κείμενο του parent tokenοποιείται μέσω ενός `OffsetTokenizer`.
2. Η συνάρτηση `build_token_windows()` υπολογίζει τα διαστήματα tokens.
3. Για κάθε διάστημα, η `_build_chunk()` κατασκευάζει ένα `ChildChunk`.

Ο αλγόριθμος των windows έχει τρία χαρακτηριστικά:

- δεν παράγει ποτέ τελικό chunk μικρότερο από `minimum_final_chunk_tokens`·
- δεν παράγει δύο πανομοιότυπα διαδοχικά windows·
- είναι ντετερμινιστικός.

Όταν το φυσικό τελευταίο παράθυρο θα ήταν μικρότερο από το ελάχιστο, ο αλγόριθμος το μετατοπίζει προς τα πίσω ώστε να αγκυρωθεί στο τέλος του parent (anchored final window).

4.3.4 Παράμετροι Διαμόρφωσης

Η διαμόρφωση `ChildChunkerConfig` έχει τις εξής τιμές:

Παράμετρος	**Τιμή**
`chunker_id`	`hierarchical_token_chunker`
`chunker_version`	`0.3.0`
`chunk_size`	`256` (συνολικά tokens εισόδου μοντέλου)
`chunk_overlap`	`32` (content tokens)
`minimum_final_chunk_tokens`	`127` (υπολογισμένο)
`preserve_parent_boundaries`	`True` (υποχρεωτικό)
`include_empty_parents`	`False`

Το `chunk_size` αφορά το σύνολο των tokens που δέχεται το μοντέλο (περιλαμβανομένων των ειδικών tokens). Δεδομένου ότι η BGE-M3 προσθέτει δύο ειδικά tokens ([CLS] και [SEP]), το ωφέλιμο περιεχόμενο ανά chunk είναι $256 - 2 = 254$ content tokens. Η τιμή `minimum_final_chunk_tokens` είναι εξ ορισμού το ήμισυ του content budget: $\lfloor 254/2 \rfloor = 127$.

Οι τιμές των `chunk_size` και `chunk_overlap` δεν επιλέχθηκαν αυθαίρετα. Όπως τεκμηριώνεται στην πειραματική αξιολόγηση (Κεφάλαιο 5), αποτελούν το αποτέλεσμα συστηματικής μελέτης παραμέτρων.

4.3.5 Αφαίρεση Tokenizer

Ο chunker δεν εξαρτάται από συγκεκριμένο tokenizer, αλλά από το πρωτόκολλο `OffsetTokenizer`. Το πρωτόκολλο απαιτεί τρεις μεθόδους/ιδιότητες:

- `tokenizer_id`: μία συμβολοσειρά που ταυτοποιεί τον tokenizer.
- `special_tokens_count`: ο αριθμός ειδικών tokens που ο tokenizer προσθέτει αυτόματα (για την BGE-M3, δύο: [CLS] και [SEP]).
- `tokenize_with_offsets(text)`: μία μέθοδος που επιστρέφει μία πλειάδα από `TokenSpan` με ακριβή offsets χαρακτήρων για κάθε token.

Το πρωτόκολλο απαιτεί την παραγωγή `TokenSpan` με ακριβή offsets χαρακτήρων. Αυτό επιτρέπει στον chunker να παράγει chunks των οποίων το κείμενο είναι ακριβώς το slice του αρχικού κειμένου στο αντίστοιχο διάστημα.

Παρέχονται δύο υλοποιήσεις:

- `RegexOffsetTokenizer`: tokenizer χωρίς εξαρτήσεις, για δοκιμές.
- `HuggingFaceOffsetTokenizer`: προσαρμογέας για fast tokenizers του Hugging Face με `offset_mapping`.

Ο προσαρμογέας Hugging Face παράγει `tokenizer_id` της μορφής `huggingface:{model_id}@{revision}:fast`, το οποίο δεσμεύει τη ταυτότητα του tokenizer στο μοντέλο *και* στο revision. Αυτό καθιστά το `chunker_config_hash` σταθερό μεταξύ εκτελέσεων.

4.3.6 Μοντέλο ChildChunk και Invariants

Το `ChildChunk` φέρει δύο δείκτες θέσης:

- `chunk_index`: θέση στο σύνολο των chunks του εγγράφου, ξεκινώντας από το μηδέν·

- `parent_chunk_index`: θέση εντός του parent.

Οι validators επιβάλλουν:

- `chunk_overlap<chunk_size`·
- το `normalized_char_span` του chunk να περιέχεται στο `parent_normalized_char_span`·
- εάν `token_span` ορίζεται, το μήκος του να ισούται με `token_count`.

Το `chunk_id` παράγεται από τη `build_chunk_id()` και συνδυάζει dataset, doc_id, parent_id, chunker config hash και `parent_chunk_index`.

4.4 Διανυσματικές Αναπαραστάσεις

4.4.1 Απαιτήσεις

Η δημιουργία embeddings μετατρέπει τα chunks σε μορφή κατάλληλη για σημασιολογική αναζήτηση. Οι απαιτήσεις της παρούσας εργασίας διαφοροποιούνται από αυτές ενός γενικού συστήματος αναζήτησης:

- **Πολυγλωσσία**: το GreekBarBench απαιτεί υποστήριξη ελληνικών.
- **Υβριδικότητα**: απαιτείται ταυτόχρονη παραγωγή dense *και* sparse αναπαραστάσεων.
- **Μεγάλο μήκος εισόδου**: τα νομικά κείμενα και τα ερωτήματα του CLERK (μέσος όρος 16 322 χαρακτήρες) απαιτούν μεγάλο μέγιστο μήκος εισόδου.
- **Ακριβής αντιστοίχιση όρων**: η sparse αναπαράσταση πρέπει να διατηρεί ακριβή λεξιλογική πληροφορία, ιδιαίτερα χρήσιμη σε corpora όπου αριθμοί, κωδικοί και ειδικοί όροι έχουν καθοριστική σημασία.

4.4.2 Επιλογή Μοντέλου: BGE-M3

Επιλέγεται το μοντέλο `BAAI/bge-m3` [13] στο revision `5617a9f61b028005a4858fdac845db406aefb181`. Η επιλογή βασίζεται σε τρεις ιδιότητες:

- Παράγει ταυτόχρονα dense και learned-sparse αναπαραστάσεις σε μία μόνο forward pass, αποφεύγοντας την ανάγκη χρήσης δύο μοντέλων.
- Υποστηρίζει περισσότερες από 100 γλώσσες.
- Έχει σχεδιαστεί για multi-granularity retrieval με μέγιστο μήκος εισόδου 8 192 tokens.

Η *dense* αναπαράσταση είναι ένα διάνυσμα 1 024 διαστάσεων από το [CLS] pooling, κανονικοποιημένο σε μοναδιαία ℓ_2 νόρμα. Η *sparse* αναπαράσταση είναι το learned lexical weight vector του μοντέλου, όπου κάθε μη-μηδενικό στοιχείο είναι ένα ζεύγος (index λεξιλογίου, μη-αρνητικό βάρος).

4.4.3 Διαμόρφωση Embedding

Η διαμόρφωση `EmbeddingConfig` έχει τις εξής τιμές:

Παράμετρος	**Τιμή**
`model_id`	`BAAI/bge-m3`
`model_revision`	`5617a9f61b028005a4858fdac845db406aefb181`
`embedding_kind`	hybrid (dense + learned sparse)
`dense_dimension`	1 024
`dense_precision`	FP16
`dense_normalized`	True
`device`	CUDA (NVIDIA T4)
`use_fp16`	True
`chunkbatchsize`	32
`chunkmaxlength`	512 tokens
`querybatchsize`	32
`querymaxlength`	4 098 tokens

Παρατηρείται διάκριση μεταξύ των μέγιστων μηκών chunk (512 tokens) και query (4 098 tokens). Η διάκριση αυτή οφείλεται στο ότι τα ερωτήματα του CLERK είναι πολύ μεγαλύτερα από τα chunks, και μία κοινή τιμή 512 θα οδηγούσε σε σοβαρή απώλεια πληροφορίας στην πλευρά του query.

4.4.4 Μοντέλα Δεδομένων

Τρία μοντέλα ορίζουν το στάδιο:

ChunkEmbeddingRecord. Περιέχει την ταυτότητα του chunk, τα πεδία ταυτότητας του μοντέλου (`model_id`, `model_revision`, `tokenizer_id`, `embedding_config_hash`), το dense διάνυσμα ως πλειάδα floats, το sparse διάνυσμα ως `SparseVector`, και προαιρετικά `dense_dimension`, `dense_precision`, `dense_normalized` και `source_chunk_sha256`. Οι validators απαιτούν την παρουσία τουλάχιστον μίας από τις δύο αναπαραστάσεις και τη συνέπεια μεταξύ των dense μεταδεδομένων και του διανύσματος.

SparseVector. Περιέχει δύο ευθυγραμμισμένες πλειάδες (`indices`, `values`). Οι validators επιβάλλουν ταξινομημένους, μοναδικούς, μη-αρνητικούς δείκτες και πεπερασμένες τιμές. Η ταξινόμηση των indices επιτρέπει τη σειριοποίηση σε συμπαγή μορφή χωρίς επιπλέον sorting στο write time.

EmbeddingShardHeader. Περιγράφει ένα shard: ταυτότητα, τύπος embedding (dense/sparse/hybrid), dense metadata, μέγιστο πλήθος εγγραφών.

4.4.5 Παραγωγή και Αποθήκευση Shards

Η συνάρτηση `write_embedding_shard()` είναι η κανονική οδός για την εγγραφή embedding records. Εκτελεί:

1. Επίλυση των τυπικών διαδρομών (`header.json`, `records.jsonl`, `shard.manifest.json`).
2. Φόρτωση των source chunk IDs για επικύρωση συμμετοχής.
3. Εγγραφή μέσω `AtomicJsonlWriter` με έλεγχο κάθε record έναντι του header και του source chunk ID set.
4. Εγγραφή του header με ατομικό τρόπο.
5. Κατασκευή sidecar manifest με τα SHA-256 όλων των αρχείων και εισόδων.

Εάν κάποιο βήμα αποτύχει, τα ήδη γραμμένα αρχεία διαγράφονται πριν διαδοθεί η εξαίρεση. Με τον τρόπο αυτό, μία αποτυχημένη εγγραφή δεν αφήνει μερικά τεχνουργήματα.

Το `EmbeddingRunCatalog` περιγράφει ένα πλήρες embedding run και επικυρώνει ότι τα shard indices είναι συνεχόμενα από το μηδέν, ότι το άθροισμα των record counts ισούται με το συνολικό πλήθος, και ότι κανένα chunk ID δεν εμφανίζεται σε δύο shards.

4.5 Διανυσματική Βάση Δεδομένων

4.5.1 Απαιτήσεις

Η βάση δεδομένων καλείται να διαχειριστεί:

- αποθήκευση των dense (1 024 διαστάσεων) και sparse αναπαραστάσεων·
- μεταδεδομένα που συνδέουν κάθε chunk με τον parent και το document του·
- υβριδική αναζήτηση (dense + sparse με RRF)·
- επεκτασιμότητα χωρίς αλλαγή της υπόλοιπης pipeline.

4.5.2 Επιλογή: Qdrant

Επιλέγεται η Qdrant [30]. Η επιλογή βασίζεται στην εγγενή υποστήριξη *named vectors* (ένα point μπορεί να φέρει πολλαπλές διανυσματικές αναπαραστάσεις), στην υποστήριξη `FusionQuery` με `Fusion.RRF`, και στην αποθήκευση payload χωρίς εξωτερική βάση δεδομένων.

4.5.3 Δομή Collections

Κάθε σύνολο δεδομένων αποθηκεύεται σε ένα collection με δύο named vectors:

- `dense`: 1 024 διαστάσεις, απόσταση COSINE, unquantized·
- `sparse`: learned lexical weights, εσωτερικό γινόμενο, unquantized, in-memory index.

Οι σταθερές `DENSE_VECTOR_NAME` και `SPARSE_VECTOR_NAME` ορίζονται στο module `storage.qdrant` και εξάγονται από το `__init__`.

4.5.4 Ντετερμινιστικά Point IDs

Τα point IDs υπολογίζονται μέσω της συνάρτησης `build_qdrant_point_id(chunk_id)`, η οποία επιστρέφει ένα UUID version 5 που παράγεται από το URL namespace και το σταθερό πρόθεμα `"rag-chunk:"` μαζί με το `chunk_id`. Η συνάρτηση είναι ισοδύναμη με:

```
uuid.uuid5(uuid.NAMESPACE_URL,"rag-chunk:"+chunk_id)
```

Το ίδιο chunk απεικονίζεται πάντα στο ίδιο point ID ανεξάρτητα από τη σειρά εισαγωγής ή το Qdrant instance. Αυτό καθιστά την εισαγωγή idempotent και επιτρέπει την επαναληπτική κατασκευή της συλλογής χωρίς αλλαγή ταυτοτήτων.

4.5.5 Payload

Το `build_payload()` κατασκευάζει το searchable payload κάθε point. Περιλαμβάνει τα `chunk_id`, `parent_id`, `doc_id`, `dataset`, τους δείκτες `chunk_index`, `parent_chunk_index`, το κανονικοποιημένο κείμενο, τα διαστήματα χαρακτήρων και tokens, και τα πεδία ταυτότητας του μοντέλου (`model_id`, `model_revision`, `embedding_config_hash`).

4.5.6 Εισαγωγή

Η `ingest_embedding_records()` δημιουργεί ένα point για κάθε record και τα upsertάρει σε batches των 64. Επικυρώνει ότι κάθε record αναφέρεται σε γνωστό chunk, ότι δεν υπάρχουν διπλά IDs στο ίδιο batch, και ότι το dense dimension του header είναι παρόν. Επιστρέφει ένα `QdrantIngestionSummary`.

4.6 Pipeline Ανάκτησης

4.6.1 Υβριδική Αναζήτηση

Για κάθε ερώτημα q με dense διάνυσμα $\mathbf{d}_q$ και sparse διάνυσμα $\mathbf{s}_q$ υπολογίζονται δύο ανεξάρτητα candidate sets:

$$\mathcal{C}_q^{\text{dense}} = \text{top-}\, K_{\cos}\{\, \langle \mathbf{d}_q, \mathbf{d}_p \rangle : p \in \mathcal{P} \,\},$$
$$\mathcal{C}_q^{\text{sparse}} = \text{top-}\, K_{\text{ip}}\{\, \langle \mathbf{s}_q, \mathbf{s}_p \rangle : p \in \mathcal{P} \,\},$$

όπου $\mathcal{P}$ το σύνολο των points και $K = 200$. Τα δύο sets υπολογίζονται ανεξάρτητα, χωρίς κοινή πληροφορία.

4.6.2 Fusion με Reciprocal Rank Fusion

Τα δύο rankings συνδυάζονται μέσω RRF:

$$\text{RRF}(p) = \sum_{r \in \{\text{dense},\ \text{sparse}\}} \frac{1}{k + \text{rank}_r(p)},$$

με $k = 60$ όπως προτείνεται από τους Cormack et al. [16]. Το RRF είναι rank-based, επομένως δεν απαιτεί τα δύο σκορ να βρίσκονται στην ίδια κλίμακα. Η χρήση του native `FusionQuery` της Qdrant διατηρεί τη σύντηξη εντός της βάσης, αποφεύγοντας τη μεταφορά candidate sets στην Python.

4.6.3 Συνάθροιση σε Parents

Δεδομένου του fused ranking των child chunks $c_1, \ldots, c_M$ (ταξινομημένων κατά RRF score, με tie-break στο chunk ID), τα chunks ομαδοποιούνται ανά parent. Για κάθε parent P με μέλη $m_1, \ldots, m_k$:

$$\text{score}(P) = \max_{m \in P} \text{score}(m) + w \sum_{m \in P \setminus \{m^\star\}} \text{score}(m),$$

όπου $m^\star$ το υψηλότερο-βαθμολογημένο μέλος και $w = 0.05$. Η επιλογή best-plus-margin είναι συμβιβασμός μεταξύ best-only (που αγνοεί κάθε άλλη απόδειξη) και sum-of-all (που υπερ-επιβραβεύει μεγάλα parents).

Το `score_semantics` του αποτελέσματος τεκμηριώνει ρητά τη σημασιολογία: `parent_best_plus_weighted_rest`.

4.6.4 Ανάλυση σε Documents

Τα parents ομαδοποιούνται ανά canonical document ID:

$$\text{score}(D) = \max_{P \in D} \text{score}(P).$$

Η ταξινόμηση γίνεται κατά φθίνουσα σειρά score, με tie-breaks στα `(best_parent_rank, doc_id)`. Το τελικό σύνολο περιορίζεται στα 100 κορυφαία documents.

Το `RetrievedDocument` περιλαμβάνει τα `query_id`, `doc_id`, `rank`, `score`, `best_parent_rank`, τις συνεισφέρουσες λίστες `contributing_parent_ids` και `contributing_chunk_ids`, καθώς και metadata. Οι validators αποκλείουν ρητά πεδία που θα μπορούσαν να διαρρεύσουν ground truth (`generated_answer`, `reference_answer`, `relevance`, `judgment`).

4.7 Ντετερμινιστικότητα και Αναπαραγωγιμότητα

Η αρχιτεκτονική είναι ντετερμινιστική σε κάθε επίπεδο που παράγει τεχνουργήματα. Οι εγγυήσεις συνοψίζονται ως εξής:

Ταυτότητες. Κάθε τεχνούργημα έχει content-addressable ταυτότητα:

- `parent_id` εξαρτάται από dataset, doc_id, parser config hash, parent index·
- `chunk_id` εξαρτάται από dataset, doc_id, parent_id, chunker config hash, parent chunk index·
- Qdrant point ID εξαρτάται από `chunk_id`·
- embedding shard ID εξαρτάται από dataset, model_id, embedding config hash, shard index.

Σειριοποίηση. Τα JSON/JSONL τεχνουργήματα γράφονται με `sort_keys=True` και `separators=(",",":")`. Τα Pydantic μοντέλα σειριοποιούνται σε JSON mode με `exclude_none=False`. Δύο εκτελέσεις με τα ίδια inputs παράγουν byte-identical αρχεία.

Tie-breaking. Όπου δύο στοιχεία μπορούν να ισοβαθμήσουν, η σειρά καθορίζεται από ντετερμινιστικό secondary key:

- parent aggregation: φθίνον score, μετά best chunk rank, μετά parent ID·

- document resolution: φθίνον score, μετά best parent rank, μετά document ID·
- RRF (numpy path): φθίνον RRF score, μετά αύξον chunk index.

Απομόνωση floating-point. Η μοναδική πηγή μη-ντετερμινισμού είναι η FP16 αριθμητική του embedder. Όλα τα downstream στάδια είναι bit-exact δεδομένων των embedding records.

4.8 Σύνοψη Υποσυστημάτων

Ο Πίνακας 4.2 συνοψίζει τα έξι κύρια υποσυστήματα, τις κλάσεις που τα υλοποιούν και τα κύρια μοντέλα δεδομένων τους.

Πίνακας 4.2: Σύνοψη υποσυστημάτων της αρχιτεκτονικής.

Στάδιο	**Κύρια Κλάση**	**Κύρια Μοντέλα**
Parsing	`DeterministicStructuralParser`	`SemanticParent`, `ParsedDocument`, `BoundaryEvidence`
Chunking	`HierarchicalChildChunker`	`ChildChunk`, `ChildChunkerConfig`, `TokenSpan`
Embedding	`bge_m3_embedder`, `write_embedding_shard`	`ChunkEmbeddingRecord`, `SparseVector`, `EmbeddingShardHeader`
Storage	`create_hybrid_collection`, `ingest_embedding_records`	`QdrantCollectionManifest`
Retrieval	`retrieve_hybrid_rrf`	`RetrievedChunk`
Aggregation	`aggregate_chunks_to_parents`	`RetrievedParent`
Resolution	`resolve_parents_to_documents`	`RetrievedDocument`

Το σύστημα είναι οργανωμένο σε εννέα υποπακέτα (`canonical`, `parsing`, `chunking`, `embedding`, `storage`, `retrieval`, `evaluation`, `artifacts`, `orchestration`) καθένα με σαφή ευθύνη. Η λεπτομερής πειραματική αξιολόγηση της συνολικής αρχιτεκτονικής, καθώς και η μελέτη των βέλτιστων τιμών των παραμέτρων της, παρουσιάζονται στα επόμενα κεφάλαια.

Κεφάλαιο 5

Πειραματική Αξιολόγηση Ι: Βέλτιστη Διαμόρφωση Λειτουργίας

Στο προηγούμενο κεφάλαιο παρουσιάστηκε αναλυτικά η υλοποίηση κάθε σταδίου της προτεινόμενης αρχιτεκτονικής. Το παρόν κεφάλαιο εξετάζει το ερώτημα: *πότε η προτεινόμενη αρχιτεκτονική αποδίδει βέλτιστα;* Απαντά μέσω μιας συστηματικής μελέτης της απόκρισης της αρχιτεκτονικής ως προς τις παραμέτρους που η ίδια εκθέτει, με σαφή διαχωρισμό μεταξύ διαχωρισμού ανάπτυξης και ελέγχου, και με στατιστικά τεκμηριωμένους κανόνες απόφασης.

Η μελέτη δεν αποτελεί grid search. Αντίθετα, ακολουθεί μία σταδιακή, στατιστικά φυλασσόμενη διαδικασία, στην οποία κάθε στάδιο έχει σαφή στόχο και ρητό μηχανισμό αναφοράς αποτυχίας. Στόχος δεν είναι η εύρεση της αριθμητικά βέλτιστης διαμόρφωσης, αλλά η περιγραφή, με μεθοδολογικά υπερασπίσιμο τρόπο, του τρόπου με τον οποίο η ποιότητα ανάκτησης της αρχιτεκτονικής αποκρίνεται στις παραμέτρους που η υλοποίησή της εκθέτει.

5.1 Κίνητρα και Σκοπός

5.1.1 Γιατί δεν αρκεί μία grid search

Οι μελέτες υπερπαραμέτρων σε συστήματα ανάκτησης εκτελούνται συχνά ως εξαντλητικές αναζητήσεις πλέγματος: απαρίθμηση όλων των τιμών όλων των παραμέτρων, διασταύρωσή τους με όλα τα σύνολα δεδομένων, και αναφορά της διαμόρφωσης που μεγιστοποιεί το κύριο μέτρο. Το πρωτόκολλο αυτό έχει αρκετά γνωστά προβλήματα:

- **Διόγκωση του σφάλματος Τύπου Ι**: με δεκάδες ή εκατοντάδες διαμορφώσεις αξιολογημένες στο ίδιο σύνολο ελέγχου, κάποια διαμόρφωση θα εμφανιστεί βέλτιστη από τύχη και μόνο.

- **Σιωπηλό overfitting στο σύνολο ελέγχου**: η επιλογή καθοδηγείται από τα αποτελέσματα του συνόλου ελέγχου, οπότε η ίδια η επιλογή είναι μεροληπτική.

- **Δυσερμήνευτο αποτέλεσμα**: η νικήτρια διαμόρφωση είναι παραπροϊόν της αναζήτησης και όχι ένα συνεκτικό σημείο λειτουργίας.

- **Μη πρακτικό κόστος**: στο retrieval, κάθε διαμόρφωση απαιτεί πλήρη επαναδημιουργία embeddings του corpus.

Η μελέτη που παρουσιάζεται εδώ σχεδιάστηκε ρητά ώστε να αποφύγει αυτά τα προβλήματα.

5.1.2 Σκοπός

Σκοπός της μελέτης είναι να περιγράψει, με στατιστικά υπερασπίσιμη μεθοδολογία, πώς η ποιότητα ανάκτησης της προτεινόμενης αρχιτεκτονικής αποκρίνεται στις παραμέτρους που η υλοποίησή της εκθέτει. Η μελέτη δεν στοχεύει στην ανεύρεση της αριθμητικά βέλτιστης διαμόρφωσης, αλλά στην:

1. καταγραφή των εκτιθέμενων παραμέτρων της αρχιτεκτονικής,

2. παραγωγή καμπυλών απόκρισης για κάθε παράμετρο,

3. επιβεβαίωση των υποψήφιων βέλτιστων διαμορφώσεων σε πλήρη διαχωρισμό ανάπτυξης,

4. επιλογή μίας παγωμένης διαμόρφωσης μέσω διαφανούς κανόνα,

5. εκτέλεση μίας και μόνης αξιολόγησης στο σύνολο ελέγχου,

6. αναφορά όλων των αποτελεσμάτων, συμπεριλαμβανομένων των αρνητικών.

5.2 Μεθοδολογία

5.2.1 Αρχές Σχεδιασμού

Η μελέτη διέπεται από πέντε αρχές:

1. **Παγωμένο συμβόλαιο πρώτα.** Όλοι οι χώροι παραμέτρων, οι τιμές του πλέγματος και οι αναθέσεις διαχωρισμών παγώνουν πριν από οποιαδήποτε δοκιμαστική εκτέλεση.

2. **Απομόνωση ανάπτυξης/ελέγχου.** Η επιλογή πραγματοποιείται αποκλειστικά στον διαχωρισμό ανάπτυξης. Ο διαχωρισμός ελέγχου εκτελείται μία φορά στο τέλος, μετά το πάγωμα της διαμόρφωσης.

3. **Διαχωρισμός ομαδοποιημένος κατά έγγραφο.** Ο διαχωρισμός δεν γίνεται κατά ερώτημα αλλά κατά έγγραφο, ώστε κανένα έγγραφο να μην συνεισφέρει ερωτήματα και στους δύο διαχωρισμούς. Αυτό αποτρέπει τη διαρροή μέσω κοινών αποδείξεων.

4. **Κλασματικός παραγοντικός σχεδιασμός, όχι πλέγμα.** Μετά το μονοπαραγοντικό screening, διατηρούνται μόνο δύο Pareto-eligible τιμές ανά άξονα. Ο Κλασματικός παραγοντικός σχεδιασμός περιορίζεται στις 48 διαμορφώσεις.

5. **Αναφορά μη-σημαντικών αποτελεσμάτων.** Υπόθεση της οποίας τα στοιχεία αποτυγχάνουν τον προκαθορισμένο κανόνα απόφασης αναφέρεται ως NOT SUPPORTED, και όχι ως ασαφές αποτέλεσμα που σιωπηλά παραλείπεται.

5.2.2 Εκτιθέμενος Χώρος Παραμέτρων

Η υλοποίηση εκθέτει τέσσερις παραμέτρους που επηρεάζουν την ποιότητα ανάκτησης. Ο Πίνακας 5.1 τις συνοψίζει.

Πίνακας 5.1: Εκτιθέμενες παράμετροι και τα πεδία τιμών τους.

Παράμετρος	**Πεδίο Τιμών**	**Υπόθεση**
`chunk_size`	{256, 512, 1024}	H1
`chunk_overlap`	{0, 32, 128}	H2
`retrieval_mode`	{dense, sparse, hybrid_rrf}	H5
`candidate_limit`	{50, 100, 200}	H3

Παράλληλα, ορισμένες παράμετροι είναι *παγωμένες*, είτε γιατί ορίζουν την αρχιτεκτονική είτε γιατί αποτελούν μέρος του κοινού συμβολαίου αξιολόγησης. Ο Πίνακας 5.2 τις συνοψίζει.

Πίνακας 5.2: Παγωμένες παράμετροι (αρχιτεκτονικά καθοριστικές ή συμβολαίου).

Παράμετρος	**Τιμή / Λόγος**
`parent_rest_weight`	0.05 (τύπος συνάθροισης)
RRF constant k	60 (hardcoded)
`preserve_parent_boundaries`	True (validator-enforced)
`structural_parser_policy`	προεπιλογή έργου
`document_resolution_policy`	`best_parent_by_score`
`embedding_model_id`	`BAAI/bge-m3`
`embedding_revision`	`5617a9f6…`
`dense_dimension`	1024
`parent_limit`	100 (σχεδιασμός αξιολόγησης)
`document_limit`	100 (σχεδιασμός αξιολόγησης)

Δύο επιπλέον υποθέσεις της ευρύτερης ερευνητικής ατζέντας *δεν* είναι ελέγξιμες υπό την τρέχουσα υλοποίηση:

- **context-per-row (H6)**: η αρχιτεκτονική δεν διαθέτει στάδιο κατασκευής context μετά την ανάκτηση, επομένως δεν εκθέτει αντίστοιχο προϋπολογισμό.
- **rerank depth (H7)**: η αρχιτεκτονική δεν διαθέτει reranker. Η συνάθροιση σε parents και το RRF είναι κύριες πράξεις κατάταξης και δεν μπορούν να ερμηνευτούν ως ξεχωριστός reranker.

Και οι δύο εξαιρέσεις δηλώνονται εκ των προτέρων και καταγράφονται στο closure manifest.

5.2.3 Διαχωρισμός Ανάπτυξης/Ελέγχου

Ο διαχωρισμός είναι ντετερμινιστικός, με seed `0`, και ομαδοποιημένος κατά έγγραφο. Κάθε dataset χωρίζεται σε σύνολο ανάπτυξης και σύνολο ελέγχου, και όλα τα ερωτήματα

Πίνακας 5.3: Διαχωρισμός ανάπτυξης/ελέγχου ανά σύνολο δεδομένων.

Dataset	**Συν. έγγραφα**	**Dev**	**Test**	**Dev ερωτ.**	**Test ερωτ.**
CLERC	2756	497	2259	413	587
CUAD	510	255	255	10 455	10 455
GreekBarBench	284	142	142	142	142
LaRA	131	65	66	1187	1139
Σύνολο	3681	959	3022	12 197	12 323

ενός εγγράφου ακολουθούν το έγγραφο στον αντίστοιχο διαχωρισμό. Ο Πίνακας 5.3 παρουσιάζει τα μεγέθη.

Το αποτύπωμα του διαχωρισμού είναι `cc04a27d518a7fc3a9232c61fec6a18e1e6f178ff8b932d44c58f293474065ea`, το οποίο επιτρέπει την επαλήθευση ότι διαφορετικές εκτελέσεις χρησιμοποίησαν τον ίδιο διαχωρισμό.

5.2.4 Κανόνες Απόφασης

Όλοι οι κανόνες απόφασης είναι προκαθορισμένοι και εφαρμόζονται ομοιόμορφα. Ο Πίνακας 5.4 τους συνοψίζει.

Πίνακας 5.4: Κανόνες απόφασης της μελέτης.

Κανόνας	**Ορισμός**
Μονοτονία	$\geq 80\%$ των διαδοχικών βημάτων στην ίδια κατεύθυνση, και συνολική μεταβολή μη-μηδενική στο 10^{-6}.
Κορεσμός	Μικρότερη τιμή v τέτοια ώστε, για κάθε μεγαλύτερη διαδοχική τιμή, το οριακό κέρδος στο κύριο μέτρο να είναι κάτω από 0.01.
Κυριαρχία	Η A κυριαρχεί της B όταν το κύριο μέτρο της A είναι $\geq$ και το κόστος της $\leq$, με τουλάχιστον μία αυστηρή ανισότητα.
Ζώνη 1-SE	Διατηρούνται όλες οι διαμορφώσεις των οποίων η μέση διαφορά έναντι της βέλτιστης βρίσκεται εντός ενός τυπικού σφάλματος.
Tie-break	Μικρότερη καθυστέρηση, μετά μικρότερη αποθήκευση, μετά μικρότερο chunk size, μετά μικρότερο candidate depth, μετά αύξον config_id.

5.3 Πειραματική Διαδικασία

Η μελέτη εκτελείται σε οκτώ στάδια, καθένα με σαφή στόχο και με ρητό μηχανισμό αναφοράς αποτυχίας.

M1 — Πάγωμα συμβολαίου. Φορτώνει τον εκτιθέμενο χώρο παραμέτρων από τον πηγαίο κώδικα, υπολογίζει τον διαχωρισμό ανάπτυξης/ελέγχου και γράφει ένα παγωμένο συμβόλαιο και ένα παγωμένο τεχνούργημα διαχωρισμού. Δεν επιλέγεται καμία τιμή παραμέτρου στο M1· μόνο τα πεδία τους παγώνουν.

M2 — Υλοποίηση πλέγματος chunking. Παράγει τις εννέα παραλλαγές chunking (τρεις διαστάσεις επί τρεις επικαλύψεις) για κάθε σύνολο δεδομένων. Επαναχρησιμοποιεί την έξοδο του structural parser. Κάθε παραλλαγή αποδίδεται με ντετερμινιστικό `chunker_config_hash`. Η παραλλαγή $(256, 32)$ επαληθεύεται byte-identical με το βασικό υλικό.

M3 — Πλέγμα embeddings. Πακετάρει τις 36 παραλλαγές σε αυτοτελή bundles. Εκτελεί μία και μόνη GPU session που παράγει dense και learned-sparse embeddings για κάθε παραλλαγή. Κάθε έξοδος αποθηκεύεται αμέσως, ώστε διακοπή της session να μη χάνει περισσότερα από μία παραλλαγή.

M4A — Δοκιμαστική αξιολόγηση σε δείγμα 10%. Για κάθε μία από τις 81 διαμορφώσεις (9 chunk παραλλαγές $\times$ 3 λειτουργίες $\times$ 3 βάθη υποψηφίων), αξιολογεί ντετερμινιστικό δείγμα 10% του διαχωρισμού ανάπτυξης (ελάχιστο 100, μέγιστο 500 ερωτήματα ανά dataset). Υπολογίζει macro-averaged μετρικές.

M4B — Μείωση. Παράγει:

- μονοπαραγοντικές καμπύλες απόκρισης για κάθε παράμετρο, κρατώντας τις άλλες τρεις στις προεπιλεγμένες τιμές τους (256, 32, hybrid RRF, 200)[1];
- αποφάσεις μονοτονίας·
- αποφάσεις κορεσμού·

[1] Σημειώνεται ότι το candidate_limit=200 αποτελεί παγωμένη τιμή, όπως φαίνεται στον Πίνακα 5.1· η μελέτη εξετάζει και μικρότερες τιμές.

- ταξινόμηση κυριαρχίας·
- τις δύο κορυφαίες τιμές ανά άξονα·
- μειωμένη παραγοντική λίστα περιορισμένη στις 48 διαμορφώσεις.

M5 — Επιβεβαίωση σε πλήρη διαχωρισμό ανάπτυξης. Αξιολογεί ένα παγωμένο σύνολο οκτώ διαμορφώσεων στον πλήρη διαχωρισμό ανάπτυξης. Περιλαμβάνει την παγωμένη προεπιλογή, τη βέλτιστη διαμόρφωση από το M4A, τη βέλτιστη sparse διαμόρφωση και εναλλακτικές με μεγαλύτερα chunks ή μικρότερο candidate depth. Οι per-query μετρικές αποθηκεύονται για τον υπολογισμό paired bootstrap.

M6 — Επιλογή. Εφαρμόζει τον εξής κανόνα:

1. Υπολογισμός paired bootstrap ($B = 1000$, seed 42) στον πλήρη διαχωρισμό ανάπτυξης.
2. Εντοπισμός της διαμόρφωσης με το υψηλότερο μέσο macro Recall@10.
3. Διατήρηση όλων των διαμορφώσεων εντός ενός τυπικού σφάλματος.
4. Ταξινόμηση κατά αύξουσα καθυστέρηση, μετά αύξουσα αποθήκευση, μετά αύξον chunk size, μετά αύξον candidate depth, μετά αύξον config_id.
5. Επιλογή της πρώτης.

Υπολογίζεται επίσης Pareto frontier ως προς τρεις στόχους: μεγιστοποίηση macro Recall@10, ελαχιστοποίηση καθυστέρησης, ελαχιστοποίηση αποθήκευσης (proxy: αριθμός chunks $\times$ dense dimension $\times$ 2 bytes/FP16 τιμή).

M7 — Κλειδωμένος έλεγχος. Εκτελεί τη παγωμένη διαμόρφωση μία και μόνη φορά στον διαχωρισμό ελέγχου. Καμία προσαρμογή παραμέτρων δεν πραγματοποιείται μετά την ανάγνωση των αποτελεσμάτων ελέγχου.

M8 — Κλείσιμο. Συλλέγει όλα τα προηγούμενα τεχνουργήματα σε closure manifest και operating profile, και παράγει τις τελεσίδικες αποφάσεις για κάθε υπόθεση.

5.4 Αποτελέσματα

5.4.1 Καμπύλες Απόκρισης

Ο Πίνακας 5.5 συνοψίζει τις μονοπαραγοντικές καμπύλες απόκρισης. Όλες οι καμπύλες κρατούν τις υπόλοιπες παραμέτρους στις παγωμένες προεπιλεγμένες τιμές.

Πίνακας 5.5: Μονοπαραγοντικές καμπύλες απόκρισης (macro Recall@10, 10% δείγμα ανάπτυξης).

Παράμετρος	**Τιμή**	**Macro R@10**	**Απόφαση**
`chunk_size`	256	0.4015	Μονοτονικά φθίνουσα
	512	0.3812	
	1024	0.3752	
`chunk_overlap`	0	0.3930	Μονοτονικά αύξουσα (κορεσμός στο 32)
	32	0.4015	
	128	0.4021	
`retrieval_mode`	dense	0.3623	Μη-μονότονη (βέλτιστο: hybrid)
	sparse	0.3732	
	hybrid_rrf	0.4015	
`candidate_limit`	50	0.3812	Μονοτονικά αύξουσα (κορεσμός στο 100)
	100	0.3980	
	200	0.4015	

Τρία σημεία ξεχωρίζουν:

1. Η απόκριση ως προς το `chunk_size` είναι *μονοτονικά φθίνουσα*: μικρότερα chunks αποδίδουν καλύτερα στο εξεταζόμενο φάσμα. Αυτό έρχεται σε αντίθεση με την προκαταρκτική υπόθεση H1 (βλ. §5.4.5).

2. Η απόκριση ως προς το `chunk_overlap` είναι μονοτονικά αύξουσα αλλά κορεσμένη: το οριακό κέρδος από 32 σε 128 είναι 0.0006, πολύ κάτω από το κατώφλι κορεσμού του 0.01.

3. Η απόκριση ως προς το `retrieval_mode` είναι μη-μονότονη με σαφές βέλτιστο στο `hybrid_rrf`: το χάσμα από το επόμενο καλύτερο (`sparse`) είναι 0.0283, το οποίο

είναι μια τάξη μεγέθους πάνω από την bootstrap αβεβαιότητα της paired διαφοράς.

5.4.2 Κλασματικός παραγοντικός σχεδιασμός και Επιβεβαιωτικά Αποτελέσματα

Ο Κλασματικός παραγοντικός σχεδιασμός περιείχε 16 διαμορφώσεις μετά τη σύμπτυξη μέσω κυριαρχίας. Από αυτές, 8 προωθήθηκαν στο επιβεβαιωτικό στάδιο στον πλήρη διαχωρισμό ανάπτυξης. Ο Πίνακας 5.6 παρουσιάζει τα αποτελέσματα.

Πίνακας 5.6: Επιβεβαιωτική αξιολόγηση (πλήρης διαχωρισμός ανάπτυξης, macro R@10 στα τέσσερα σύνολα).

Διαμόρφωση	**R@10**	**H@10**	**nDCG@10**
`c256_o128_hybrid_rrf_k200`	0.4138	0.4648	0.3256
`c512_o128_hybrid_rrf_k200`	0.4120	0.4621	0.3272
`c256_o128_hybrid_rrf_k100`	0.4105	0.4604	0.3283
`c256_o32_hybrid_rrf_k200`	0.4065	0.4602	0.3231
`c256_o32_hybrid_rrf_k100`	0.4037	0.4575	0.3255
`c512_o32_hybrid_rrf_k200`	0.3968	0.4469	0.3153
`c256_o128_sparse_k200`	0.3915	0.4465	0.3076
`c256_o32_sparse_k200`	0.3788	0.4343	0.3065

Δύο παρατηρήσεις:

- Η υψηλότερη μέση τιμή προέρχεται από τη διαμόρφωση `c256_o128_hybrid_rrf_k200` με macro R@10 ίσο με 0.4139 και bootstrap τυπικό σφάλμα 0.0109.
- Οι διαμορφώσεις με `hybrid_rrf` είναι σταθερά υψηλότερες από τις sparse-only σε όλες τις συγκρίσεις, κάτι που υποστηρίζει την αρχιτεκτονική απόφαση για υβριδική ανάκτηση.

5.4.3 Επιλογή Διαμόρφωσης

Η ζώνη ενός τυπικού σφάλματος περιλαμβάνει τρεις διαμορφώσεις:

- `c256_o128_hybrid_rrf_k200` (μέση R@10 0.4139, διαφορά 0)

- `c256_o32_hybrid_rrf_k200` (μέση R@10 0.4068, διαφορά 0.0071, SE 0.0096)

- `c512_o128_hybrid_rrf_k200` (μέση R@10 0.4121, διαφορά 0.0018, SE 0.0088)

Επειδή και οι τρεις έχουν πρακτικά ίδια per-query καθυστέρηση (όλες κάτω από 1 ms ανά ερώτημα στην υλοποίηση numpy) και διαφέρουν μόνο ως προς το αποτύπωμα αποθήκευσης και το μέγεθος chunk, ο λεξικογραφικός tie-break επιλέγει τη διαμόρφωση `c256_o32_hybrid_rrf_k200`, της οποίας το αποτύπωμα αποθήκευσης (208 MB) είναι μικρότερο από των άλλων δύο.

Η παγωμένη διαμόρφωση συμπίπτει επομένως με την προεπιλεγμένη διαμόρφωση της αρχιτεκτονικής. Αυτό αποτελεί ουσιαστικό εύρημα: η αρχιτεκτονική, ως υλοποιείται, είναι *ήδη* κοντά στη βέλτιστη λειτουργία εντός της ζώνης ενός SE.

5.4.4 Κλειδωμένος Έλεγχος

Ο Πίνακας 5.7 παρουσιάζει τον κλειδωμένο έλεγχο.

Πίνακας 5.7: Κλειδωμένος έλεγχος στη παγωμένη διαμόρφωση.

Dataset	**Ερωτήματα**	**H@10**	**R@10**	**nDCG@10**	**MRR@10**
CLERC	587	0.5332	0.3626	0.2936	0.3348
CUAD	10 455	0.0122	0.0122	0.0055	0.0035
GreekBarBench	142	0.2746	0.2746	0.1282	0.0841
LaRA	1139	0.9350	0.9350	0.8432	0.8135
Macro	12 323	0.4388	0.3961	0.3177	0.3090

Η διαφορά ανάπτυξης-ελέγχου στο κύριο μέτρο είναι -0.0107, εντός της ζώνης ενός SE. Το αποτέλεσμα είναι σταθερό και δεν απαιτεί επανα-ρύθμιση.

5.4.5 Αποτελέσματα Υποθέσεων

Ο Πίνακας 5.8 παρουσιάζει τη τελεσίδικη απόφαση για κάθε υπόθεση.

5.5 Συζήτηση

5.5.1 H1: γιατί δεν εμφανίστηκε plateau

Η υπόθεση H1 — ότι η ποιότητα ανάκτησης βελτιώνεται από μικρά σε ενδιάμεσα chunk sizes και κατόπιν μειώνεται λόγω απώλειας ειδικότητας — αποτελεί κοινό μοτίβο στο passage retrieval. Δεν εμφανίστηκε στην παρούσα μελέτη. Αντίθετα, η απόκριση είναι μονοτονικά φθίνουσα: τα μικρότερα chunks είναι αυστηρά καλύτερα, και η απώλεια από 256 σε 1024 είναι 0.0263 σε macro R@10.

Δύο μηχανισμοί εξηγούν εύλογα τη μονοτονικότητα:

1. **Διατήρηση parents.** Στην αρχιτεκτονική, τα chunks δεν διαπερνούν όρια semantic parents. Σε chunk size 1024, ένα chunk καλύπτει σχεδόν ολόκληρο τον parent στα μικρότερα έγγραφα (CLERC) και σημαντικό κλάσμα του parent στα μεγαλύτερα. Η ταυτότητα του chunk γίνεται σχεδόν ταυτόσημη με την ταυτότητα του parent, οπότε το στάδιο parent aggregation έχει ελάχιστο ρόλο. Σε chunk size 256, η κοκκομετρία του child είναι πραγματικά λεπτότερη από αυτή του parent, και το στάδιο συνάθροισης μπορεί να διακρίνει με μεγαλύτερη ακρίβεια.

2. **Αραίωση υβριδικού σήματος.** Η learned-sparse αναπαράσταση σε chunk size 1024 παράγει sparse διανύσματα με περισσότερα μη-μηδενικά στοιχεία (μεγαλύτερο κείμενο, περισσότερα διακριτικά tokens), οπότε η κατανομή των sparse scores γίνεται επιπεδότερη. Το RRF, το οποίο βασίζεται σε ranks, έχει λιγότερη πληροφορία να διαχωρίσει όταν και οι δύο αναπαραστάσεις είναι λιγότερο αιχμηρές.

Και οι δύο μηχανισμοί συνάδουν με τα δεδομένα και με τον σχεδιασμό. Το αρνητικό αποτέλεσμα αναφέρεται ως τεκμήριο ότι η πρόβλεψη H1 δεν ισχύει για την παρούσα αρχιτεκτονική· δεν αποτελεί ισχυρισμό ότι η H1 είναι γενικά άκυρη.

5.5.2 H2: μονότονο αλλά κορεσμένο

Η καμπύλη του overlap είναι μονοτονικά αύξουσα αλλά κορεσμένη στο overlap 32: το οριακό κέρδος από 32 σε 128 είναι 0.0006 σε macro R@10, αμελητέο σε σχέση με το bootstrap τυπικό σφάλμα. Πρακτικά, overlap 32 επαρκεί για την αρχιτεκτονική στα τέσσερα εξεταζόμενα σύνολα.

5.5.3 H3: το βάθος υποψηφίων κορεσμένο νωρίς

Το βάθος υποψηφίων βελτιώνει το R@10 μονοτονικά έως το $k = 100$ και μετά κορεσμό. Το οριακό κέρδος από $k = 100$ σε $k = 200$ είναι 0.0035, κάτω από το κατώφλι κορεσμού του 0.01. Αυτό υποστηρίζει την υπόθεση ότι το βάθος υποψηφίων έχει φυσικό plateau για τα μεγέθη corpus που εξετάστηκαν.

5.5.4 H5: το υβριδικό RRF κυριαρχεί

Το υβριδικό RRF επιτυγχάνει macro R@10 0.4015 έναντι 0.3623 για dense και 0.3732 για sparse. Το χάσμα από το επόμενο βέλτιστο είναι 0.0283, μεγάλο σε σχέση με τη bootstrap αβεβαιότητα. Το αποτέλεσμα υποστηρίζει τη υβριδική σχεδιαστική απόφαση: οι δύο αναπαραστάσεις είναι συμπληρωματικές με την έννοια ότι καμία δεν ανακτά μόνη της όλες τις αποδείξεις που ανακτά η συντηγμένη κατάταξη.

5.5.5 Σταθερότητα επιλογής

Η παγωμένη διαμόρφωση συμπίπτει με την προεπιλεγμένη. Αυτό είναι χρήσιμη παρατήρηση για δύο λόγους. Πρώτον, σημαίνει ότι η προεπιλεγμένη συμπεριφορά της αρχιτεκτονικής είναι ήδη καλά ρυθμισμένη για τα τέσσερα σύνολα της μελέτης, κάτι που μειώνει το λειτουργικό βάρος ανάπτυξης. Δεύτερον, σημαίνει ότι τα αποτελέσματα άλλων πειραμάτων που εκτελέστηκαν με την προεπιλεγμένη διαμόρφωση αντιστοιχούν σε μία διαμόρφωση που η παρούσα μελέτη ανεξάρτητα επιβεβαιώνει ως σχεδόν βέλτιστη, επομένως δεν απαιτείται επανεκτέλεση.

5.6 Περιορισμοί

5.6.1 Εύρος δεδομένων

Η μελέτη καλύπτει τέσσερα από τα επτά canonical datasets της ευρύτερης ατζέντας. Τα RULER, Loong και LongBench v2 εξαιρούνται, σύμφωνα με το παγωμένο συμβόλαιο. Τα συμπεράσματα ενδέχεται να μην επεκτείνονται στα εξαιρούμενα σύνολα.

5.6.2 Μη ελέγξιμες υποθέσεις

Δύο από τις επτά υποθέσεις (H6, H7) δεν μπορούν να αξιολογηθούν χωρίς προσθήκη συστατικών στην αρχιτεκτονική. Η προσθήκη τους θα άλλαζε την αρχιτεκτονική και είναι εκτός πεδίου. Οι αποφάσεις για H6 και H7 καταγράφονται ως NOT TESTABLE και παραμένουν ανοιχτά ερωτήματα για μελλοντική επέκταση.

5.6.3 Bootstrap και πολλαπλές συγκρίσεις

Τα τυπικά σφάλματα bootstrap που αναφέρονται δεν είναι προσαρμοσμένα για την οικογένεια των επιβεβαιωτικών διαμορφώσεων. Η ζώνη ενός SE είναι ευρετική, όχι δήλωση εμπιστοσύνης. Ο αναγνώστης που απαιτεί αυστηρή διόρθωση πολλαπλών συγκρίσεων θα πρέπει να αντιμετωπίζει τις αναφερόμενες ζώνες ως περιγραφικές και όχι ως συμπερασματικές.

5.6.4 Η αναζήτηση δεν είναι καθολική

Η μελέτη αξιολογεί πλέγμα εννέα παραλλαγών chunk, τριών λειτουργιών ανάκτησης και τριών βάθων υποψηφίων, και προσδιορίζει Κλασματικό παραγοντικό σχεδιασμό 16 διαμορφώσεων μετά τη συρρίκνωση μέσω κυριαρχίας. Διαμορφώσεις εκτός του παγωμένου πλέγματος — ειδικότερα chunk sizes μικρότερα του 256 ή βάθη υποψηφίων μεγαλύτερα του 200 — δεν αξιολογήθηκαν. Το συμπέρασμα ότι το 256 είναι το βέλτιστο chunk size πρέπει να διαβαστεί ως βέλτιστο μεταξύ των εξεταζόμενων τιμών, όχι ως καθολικό βέλτιστο.

5.6.5 Ελεγχόμενες προσαρμογές

Δύο ελεγχόμενες προσαρμογές συνοδεύουν την εκτέλεση: η υποκείμενη υλοποίηση της ανάκτησης είναι numpy και όχι Qdrant-native, και τα dense query embeddings αναδημιουργήθηκαν αντί να επαναχρησιμοποιηθούν. Και οι δύο είναι μαθηματικά ουδέτερες ως προς το αποτέλεσμα της επιλογής και τεκμηριώνονται στα closure manifests.

5.7 Σύνοψη

Παρουσιάστηκε μία σταδιακή, στατιστικά φυλασσόμενη μελέτη της απόκρισης λειτουργίας της προτεινόμενης αρχιτεκτονικής. Τέσσερις παράμετροι εξετάστηκαν υπό την τρέ-

χουσα υλοποίηση· δύο από τις επτά υποθέσεις της ευρύτερης ατζέντας εξαιρέθηκαν επειδή τα υποστηρίζοντα συστατικά δεν υπάρχουν. Τρεις ελέγξιμες υποθέσεις υποστηρίζονται (H3, H5, και η μονοτονική κατεύθυνση της H2), μία υποστηρίζεται μερικώς (ο κορεσμός της H2), και μία δεν υποστηρίζεται (H1). Το αρνητικό αποτέλεσμα της H1 αναφέρεται ως ουσιαστικό εύρημα και όχι ως ασαφές αποτέλεσμα.

Η παγωμένη διαμόρφωση είναι η `c256_o32_hybrid_rrf_k200`, η οποία συμπίπτει με την προεπιλεγμένη διαμόρφωση της αρχιτεκτονικής. Στον κλειδωμένο διαχωρισμό ελέγχου, η παγωμένη διαμόρφωση επιτυγχάνει macro-document Recall@10 ίσο με 0.3961, με διαφορά ανάπτυξης-ελέγχου -0.0107, εντός της ζώνης ενός SE της επιλογής. Το αποτέλεσμα είναι σταθερό και αναπαραγώγιμο.

Το κεφάλαιο απάντησε στο ερώτημα «πότε η αρχιτεκτονική αποδίδει βέλτιστα» διά της μεθόδου, του πλέγματος και της ζώνης ενός SE. Το επόμενο κεφάλαιο εξετάζει το συμπληρωματικό ερώτημα: «πώς συγκρίνεται η αρχιτεκτονική με άλλες αρχιτεκτονικές υπό δίκαιες συνθήκες;»

Πίνακας 5.8: Αποφάσεις υποθέσεων.

ID	Απόφαση	Βάση
H1	NOT SUPPORTED	Το `chunk_size` είναι μονοτονικά φθίνον στο εξεταζόμενο φάσμα (256 βέλτιστο, 1024 χειρότερο). Η υπόθεση προέβλεπε plateau γύρω από μία ενδιάμεση τιμή.
H2	PARTIALLY SUPPORTED	Το `chunk_overlap` είναι μονοτονικά αύξον στο εξεταζόμενο φάσμα, αλλά κορεσμένο στο 32: το οριακό κέρδος από 32 σε 128 είναι 0.0006, κάτω από το κατώφλι κορεσμού.
H3	SUPPORTED	Το `candidate_limit` βελτιώνει το R@10 μονοτονικά έως το 100, μετά κορεσμό (οριακό κέρδος από 100 σε 200: 0.0035).
H4	TESTED AS EVALUATION VIEW	Το Recall είναι μονοτονικό στο cutoff k εξ ορισμού· η Precision δεν είναι. Επιβεβαιώνεται στην παγωμένη κατάταξη.
H5	SUPPORTED	Το `hybrid_rrf` επιτυγχάνει macro R@10 0.4015 έναντι 0.3623 του dense και 0.3732 του sparse. Το χάσμα από το επόμενο βέλτιστο είναι 0.0283.
H6	NOT TESTABLE	Η αρχιτεκτονική δεν διαθέτει στάδιο κατασκευής context μετά την ανάκτηση και επομένως δεν εκθέτει παράμετρο context-per-row.
H7	NOT TESTABLE	Η αρχιτεκτονική δεν διαθέτει reranker.

Κεφάλαιο 6

Πειραματική Αξιολόγηση ΙΙ: Συγκριτική Μελέτη

Στο προηγούμενο κεφάλαιο απαντήθηκε το ερώτημα «πότε η προτεινόμενη αρχιτεκτονική αποδίδει βέλτιστα». Το παρόν κεφάλαιο εξετάζει το συμπληρωματικό ερώτημα: *πώς συγκρίνεται η προτεινόμενη αρχιτεκτονική με άλλες αρχιτεκτονικές ανάκτησης, υπό συνθήκες δίκαιης σύγκρισης;* Για τον σκοπό αυτό, η αρχιτεκτονική τοποθετείται δίπλα σε δύο άλλες υλοποιήσεις που εκτελέστηκαν στο ίδιο corpus, με τον ίδιο embedder, τα ίδια ερωτήματα, το ίδιο ground truth και τον ίδιο evaluator.

Το κεφάλαιο οργανώνεται ως εξής. Αρχικά παρουσιάζεται το κοινό πρωτόκολλο αξιολόγησης και οι αρχιτεκτονικές που συμμετέχουν. Στη συνέχεια παρουσιάζονται τα αποτελέσματα της κύριας σύγκρισης και ακολουθεί η ερμηνεία τους. Το κεφάλαιο κλείνει με τους περιορισμούς και μια σύντομη επισκόπηση των αρχιτεκτονικών που δεν κατέστη δυνατό να εκτελεστούν στο πλαίσιο της παρούσας εργασίας, οι οποίες τεκμηριώνονται αναλυτικά στο Παράρτημα Α.

6.1 Πρωτόκολλο Δίκαιης Σύγκρισης

Η αξιοπιστία κάθε συγκριτικής μελέτης εξαρτάται από τη διασφάλιση ότι οι αρχιτεκτονικές που συγκρίνονται λειτουργούν υπό τις ίδιες ακριβώς συνθήκες. Στην παρούσα εργασία, το πρωτόκολλο σύγκρισης καθορίστηκε πριν από την εκτέλεση κάθε πειράματος και παγώθηκε σε ένα κοινό συμβόλαιο. Ο Πίνακας 6.1 συνοψίζει τα συστατικά που είναι ταυτόσημα σε όλες τις αρχιτεκτονικές.

Πίνακας 6.1: Κοινά συστατικά του πρωτοκόλλου σύγκρισης.

Συστατικό	**Κοινή τιμή**
Σύνολα δεδομένων	CLERC, CUAD, GreekBarBench, LaRA
Canonical envelope	`documents.jsonl`, `examples.jsonl`, `manifest.json`, `validation.json`
Σύνολο ερωτημάτων	ταυτόσημα `query_id` ανά σύνολο
Ground truth	κανονικοποιημένο `ground_truth.relevant_ids`
Μοντέλο embedding	`BAAI/bge-m3` @ `5617a9f6`…
Ακρίβεια embedding	FP16
Συσκευή embedding	NVIDIA T4 (Google Colab)
Επίπεδο αξιολόγησης	canonical document
Cutoffs	$\{1, 5, 10, 20, 50\}$
Κύριο μέτρο	macro-averaged document `Recall@10`
Πολιτική μηδενικού GT	αποκλεισμός με ρητή αναφορά πλήθους
Boundary	μόνο ανάκτηση, χωρίς generation ή LLM-as-judge

Οριοθέτηση retrieval-only. Κανένα στάδιο καμίας αρχιτεκτονικής δεν παράγει απάντηση, δεν συνθέτει κείμενο και δεν καλεί LLM ως κριτή. Το ground truth φορτώνεται αποκλειστικά εντός του evaluator, ο οποίος εκτελείται ως ανεξάρτητη διεργασία. Ο retriever λαμβάνει μόνο ζεύγη `(query_id,query_text)`.

Παραδοχές δικαιοσύνης. Δύο αρχιτεκτονικές που συγκρίνονται θεωρούνται δίκαια συγκρίσιμες εφόσον (α) μοιράζονται τα συστατικά του Πίνακα 6.1, και (β) οι διαφορές τους περιορίζονται σε εκείνους τους άξονες που ορίζουν την αρχιτεκτονική τους ταυτότητα. Στην παρούσα μελέτη οι άξονες αυτοί είναι τρεις: η *κοκκομετρία* των μονάδων ανάκτησης, το *σήμα* ανάκτησης (dense ή υβριδικό) και ο *κανόνας συνάθροισης* από τις μονάδες στα έγγραφα.

6.2 Συμμετέχουσες Αρχιτεκτονικές

Τρεις αρχιτεκτονικές εκτελέστηκαν στο κοινό corpus και συμμετέχουν στην κύρια σύγκριση. Μια τέταρτη εκτελέστηκε μερικώς και αναφέρεται ξεχωριστά.

6.2.1 SAH-RAG (Project-Owned Reference)

Η προτεινόμενη αρχιτεκτονική, *Structure-Aware Hierarchical RAG* (SAH-RAG), όπως περιγράφηκε στα Κεφάλαια 3 και 4. Είναι δομικά ενήμερη και υβριδική: τεμαχίζει τα έγγραφα σε semantic parents, τα διασπά σε child chunks των 256 tokens που δεν διαπερνούν τα όρια των parents, παράγει ταυτόχρονα dense και learned-sparse αναπαραστάσεις μέσω BGE-M3, συντήκει τις δύο κατατάξεις με Reciprocal Rank Fusion ($k = 60$) και συναθροίζει τα αποτελέσματα σε επίπεδο parent και έπειτα document. Εκτελέστηκε ως has-shipped με δύο τεκμηριωμένες προσαρμογές υποστρώματος (numpy retrieval αντί Qdrant-native, αναπαραγωγή dense query embeddings αντί επαναχρήσης).

6.2.2 LongRAG (Controlled Adaptation)

Το LongRAG [19] μειώνει το corpus ανάκτησης ομαδοποιώντας K διαδοχικά έγγραφα σε μεγάλες μονάδες (long units) των περίπου 4096 tokens και ανακτώντας dense-only πάνω σε αυτές. Στην παρούσα εργασία εκτελείται ως *controlled adaptation*: η αρχιτεκτονικά καθοριστική λογική (ομαδοποίηση διαδοχικών εγγράφων, dense-only ανάκτηση) διατηρείται, ενώ ο embedder αντικαθίσταται από BGE-M3 dense-only, FP16, με το ίδιο pinned revision όπως σε όλες τις αρχιτεκτονικές. Η αντικατάσταση του embedder τεκμηριώνεται και δεν συνοδεύεται από ισχυρισμό native ισοδυναμίας.

6.2.3 Metadata-RAG (Paper-Derived Comparator)

Το Metadata-RAG [29] είναι ένα multi-stage πλαίσιο που αξιοποιεί μεταδεδομένα παραγόμενα από κανόνες για το φιλτράρισμα υποψηφίων πριν την dense αναζήτηση. Δεδομένου ότι το paper δεν παγιώνει σχήμα μεταδεδομένων, κανόνες εξαγωγής ή συντελεστές σύντηξης, η υλοποίηση έγινε ως *paper-derived comparator* υπό παγωμένο clean-room συμβόλαιο: εξαγωγή μεταδεδομένων με ντετερμινιστικές κανονικές εκφράσεις, ταυτόσημη συμμετρία extractor μεταξύ query και document, φιλτράρισμα με κατώφλι `min_match_ratio=0.5` και σύντηξη metadata και semantic με συντελεστές $\alpha_m = 0.3$ και $\alpha_s = 0.7$.

6.2.4 PathRAG (Structural Comparator, μερική εκτέλεση)

Το PathRAG [24] ανακτά relational paths από ένα indexing graph. Η native υλοποίηση είναι BLOCKED_ON_LICENSE (δεν υπάρχει LICENSE file στο αποθετήριο). Εκτελέστηκε

μόνο ένα δομικό comparator χωρίς semantic layer, ο οποίος πέτυχε macro Recall@10 ίσο με 0.0393, τιμή εξαιρετικά χαμηλή που αντανακλά την απουσία σημασιολογικού σήματος και όχι αδυναμία της native αρχιτεκτονικής. Λόγω της μη-δυνατότητας δίκαιης σύγκρισης, η αρχιτεκτονική δεν συμμετέχει στην κύρια σύγκριση και τα αποτελέσματά της τεκμηριώνονται στο Παράρτημα Α.

6.3 Κύρια Σύγκριση: SAH-RAG vs LongRAG

6.3.1 Κύριο Μέτρο

Το κύριο μέτρο της σύγκρισης είναι το macro-averaged document `Recall@10`. Ο Πίνακας 6.2 παρουσιάζει τα αποτελέσματα.

Πίνακας 6.2: Κύριο μέτρο σύγκρισης: macro document Recall@10.

Αρχιτεκτονική	**Recall@10**	**Διαφορά**	**Σχετική βελτίωση**
LongRAG	0.3144	—	—
SAH-RAG	0.4049	0.0905	28.79%

Η προτεινόμενη αρχιτεκτονική υπερτερεί του LongRAG κατά 28.79% στο κύριο μέτρο.

6.3.2 Πλήρης Σύγκριση σε Όλα τα Μέτρα

Ο Πίνακας 6.3 παρουσιάζει τη σύγκριση σε όλα τα δεκαοκτώ μέτρα που αναφέρονται.

Η SAH-RAG υπερτερεί σε *όλα* τα μέτρα, με τις διαφορές να κυμαίνονται από 0.0195 (Precision@10) έως 0.1729 (Hit@50).

6.3.3 Σύγκριση ανά Σύνολο Δεδομένων

Ο Πίνακας 6.4 παρουσιάζει τη σύγκριση ανά σύνολο δεδομένων.

Το μέγεθος της βελτίωσης μεταβάλλεται συστηματικά με ένα μετρήσιμο χαρακτηριστικό του corpus: το μέσο μήκος των εγγράφων. Αυτό αποτελεί το πιο ουσιαστικό εύρημα της σύγκρισης και ερμηνεύεται στην επόμενη ενότητα.

Πίνακας 6.3: Σύγκριση σε όλα τα μέτρα (macro-averaged στα τέσσερα σύνολα).

Μέτρο	LongRAG	SAH-RAG	Διαφορά	Νικητής
Hit@1	0.1957	0.2553	0.0596	SAH-RAG
Hit@5	0.2606	0.3846	0.1241	SAH-RAG
Hit@10	0.3183	0.4520	0.1338	SAH-RAG
Hit@20	0.3881	0.5416	0.1535	SAH-RAG
Hit@50	0.4929	0.6658	0.1729	SAH-RAG
Recall@1	0.1905	0.2180	0.0275	SAH-RAG
Recall@5	0.2569	0.3394	0.0825	SAH-RAG
Recall@10	0.3144	0.4049	0.0905	SAH-RAG
Recall@20	0.3833	0.4938	0.1105	SAH-RAG
Recall@50	0.4870	0.6210	0.1340	SAH-RAG
Precision@10	0.0362	0.0557	0.0195	SAH-RAG
MRR@1	0.1957	0.2553	0.0596	SAH-RAG
MRR@5	0.2193	0.3032	0.0840	SAH-RAG
MRR@10	0.2268	0.3123	0.0855	SAH-RAG
MRR@20	0.2316	0.3186	0.0870	SAH-RAG
MRR@50	0.2349	0.3225	0.0876	SAH-RAG
nDCG@10	0.2476	0.3214	0.0737	SAH-RAG
nDCG@50	0.2880	0.3733	0.0853	SAH-RAG

6.4 Ερμηνεία των Αποτελεσμάτων

6.4.1 Η Υπόθεση της Κοκκομετρίας

Η παρατηρούμενη κατανομή των αποτελεσμάτων υποστηρίζει την ακόλουθη υπόθεση:

> *Μια αρχιτεκτονική που δημιουργεί χονδροειδείς μονάδες ανάκτησης χάνει σε ποιότητα document-level όταν τα έγγραφα του corpus είναι σύντομα, διότι ένα σχετικό έγγραφο αραιώνεται από τα άλλα έγγραφα με τα οποία έχει ομαδοποιηθεί.*

Το πληροφοριακό μέγεθος που εξηγεί την παρατηρούμενη διακύμανση είναι ο μέσος αριθμός εγγράφων ανά μονάδα ανάκτησης. Ο Πίνακας 6.5 παρουσιάζει αυτό το μέγεθος για τις δύο αρχιτεκτονικές.

Πίνακας 6.4: Σύγκριση ανά σύνολο δεδομένων (document Recall@10).

Dataset	**LongRAG**	**SAH-RAG**	**Διαφορά**	**Σχετική βελτίωση**
CLERC	0.0786	0.3546	0.2760	351%
CUAD	0.0324	0.0431	0.0107	33%
GreekBarBench	0.2606	0.2852	0.0246	9.4%
LaRA	0.8861	0.9368	0.0507	5.7%
Macro	0.3144	0.4049	0.0905	28.8%

Πίνακας 6.5: Κοκκομετρία ανάκτησης και αποτελέσματα.

Dataset	**Έγγραφα**	**LongRAG units**	**Έγγραφα/unit**	**SAH-RAG Recall@10**
CLERC	2756	256	10.8	0.3546
CUAD	510	1725	0.30	0.0431
GreekBarBench	284	1437	0.20	0.2852
LaRA	131	2251	0.06	0.9368

Στο CLERC, όπου το LongRAG συσκευάζει περίπου έντεκα έγγραφα ανά μονάδα, η διαφορά είναι μεγαλύτερη: $+351\%$ σχετική βελτίωση. Στο LaRA, όπου το LongRAG παράγει περίπου μία μονάδα ανά fragment εγγράφου, η διαφορά περιορίζεται στο $+5.7\%$: και οι δύο αρχιτεκτονικές λειτουργούν ουσιαστικά σε επίπεδο σχεδόν-εγγράφου, και το πλεονέκτημα της SAH-RAG προέρχεται κυρίως από το υβριδικό σήμα και τον κανόνα συνάθροισης.

6.4.2 Το CLERC ως Ακραία Περίπτωση

Το CLERC είναι σύνολο σύντομων passages. Τα έγγραφά του έχουν μέσο μήκος λίγες εκατοντάδες tokens, πολύ κάτω από το unit budget των 4096 tokens του LongRAG. Η ομαδοποίηση συσκευάζει περίπου έντεκα έγγραφα ανά μονάδα. Όταν μια ανακτημένη μονάδα επεκτείνεται σε έγγραφα (πρώτη εμφάνιση κατά σειρά rank της μονάδας), το σχετικό έγγραφο εισάγεται σε θέση που καθορίζεται από τη θέση του μέσα στη μονάδα και όχι από τη δική του συνάφεια. Τα υπόλοιπα δέκα έγγραφα της μονάδας είναι άσχετα αλλά εκπέμπονται με τη σειρά, αραιώνοντας τη θέση του σχετικού.

Η SAH-RAG αποφεύγει αυτό εκ κατασκευής. Τα child chunks της δεν αναμιγνύονται ποτέ μεταξύ εγγράφων. Κάθε ανακτημένο chunk χαρτογραφείται σε ακριβώς ένα έγγραφο

μέσω του parent lineage. Η κατάταξη σε επίπεδο document είναι επομένως μονότονη συνάρτηση των child scores, χωρίς αραίωση.

6.4.3 Το CUAD ως Περίπτωση Σύγκλισης

Στο CUAD, το σχετικό τεκμήριο για ένα ερώτημα είναι συνήθως μία μόνο ρήτρα, ενώ το υπόλοιπο συμβόλαιο είναι τυποποιημένο κείμενο. Όταν το LongRAG διασπά ένα συμβόλαιο σε παράθυρα 4096 tokens, κάθε παράθυρο περιέχει μεγάλο κλάσμα boilerplate, και το query embedding, υπολογισμένο έναντι αυτού του θορύβου, είναι κακή αντιστοίχιση. Η SAH-RAG διαθέτει chunks 256 tokens εντός parents, αλλά τα όρια των parents σε ένα νομικό συμβόλαιο δεν ταυτίζονται απαραίτητα με τα όρια των ρητρών, οπότε και αυτή αντιμετωπίζει δυσκολίες. Η παρατηρούμενη διαφορά 33% είναι υποδεκαπλάσια αυτής του CLERC.

6.4.4 Το LaRA ως Περίπτωση Σύγκλισης

Στο LaRA, το corpus αποτελείται από ελάχιστα πολύ μακρά έγγραφα. Και οι δύο αρχιτεκτονικές λειτουργούν ουσιαστικά σε επίπεδο near-document: το LongRAG παράγει πολλαπλές μονάδες ανά έγγραφο μέσω του oversize-split, ενώ η SAH-RAG παράγει εκατοντάδες child chunks ανά έγγραφο. Σε κάθε περίπτωση, το ανακτημένο τεκμήριο είναι fragment ενός μοναδικού source document, και η κατάταξη είναι σχεδόν τέλεια και για τις δύο.

6.4.5 Σύνοψη Ερμηνείας

Η σύγκριση απομονώνει με σπάνια καθαρότητα μία αρχιτεκτονική μεταβλητή: το μέγεθος της μονάδας ανάκτησης. Δεδομένου ότι οι δύο αρχιτεκτονικές μοιράζονται embedder, πρωτόκολλο και σύνολα δεδομένων, η διαφορά στα αποτελέσματα αποδίδεται αποκλειστικά στη διαφορά κοκκομετρίας και σήματος ανάκτησης. Στα τέσσερα εξεταζόμενα σύνολα, η λεπτότερη κοκκομετρία είναι καλύτερη, και το πλεονέκτημα αυξάνεται όσο πιο σύντομα είναι τα έγγραφα.

6.5 Σύγκριση με το Metadata-RAG

Παράλληλα με τη σύγκριση με το LongRAG, εκτελέστηκε το Metadata-RAG [29] υπό το ίδιο πρωτόκολλο. Ο Πίνακας 6.6 παρουσιάζει τα αποτελέσματα και των τριών αρχιτεκτο-

νικών.

Πίνακας 6.6: Σύγκριση τριών αρχιτεκτονικών (macro document Recall@10).

Dataset	**LongRAG**	**Metadata-RAG**	**SAH-RAG**
CLERC	0.0786	0.2726	0.3546
CUAD	0.0324	0.0294	0.0431
GreekBarBench	0.2606	0.2711	0.2852
LaRA	0.8861	0.8874	0.9368
Macro	0.3144	0.3651	0.4049

Το Metadata-RAG τοποθετείται μεταξύ LongRAG και SAH-RAG στο κύριο μέτρο. Δύο αρχιτεκτονικά γεγονότα εξηγούν αυτή τη σειρά.

Γιατί το Metadata-RAG υπερτερεί του LongRAG. Το LongRAG συσκευάζει γειτονικά έγγραφα σε μονάδες των 4096 tokens. Στο CLERC αυτό συσκευάζει περίπου έντεκα έγγραφα ανά μονάδα, αραιώνοντας το σχετικό. Το Metadata-RAG δεν ομαδοποιεί: η μονάδα ανάκτησής του είναι μεμονωμένο window εγγράφου. Ακόμη και με ανενεργό το metadata στάδιο, η λεπτότερη μονάδα διατηρεί την ταυτότητα του εγγράφου στην κατάταξη. Αυτό παράγει το πλεονέκτημα $3.47\times$ στο CLERC.

Γιατί η SAH-RAG υπερτερεί του Metadata-RAG. Η SAH-RAG συνδυάζει τρεις μηχανισμούς που το Metadata-RAG δεν διαθέτει: hierarchical chunking που δεν διαπερνά τα όρια των parents, learned-sparse λεξιλογικό σήμα συντηγμένο με το dense μέσω RRF, και κανόνα συνάθροισης parent που επιβραβεύει parents με πολλαπλά ισχυρά child chunks.

Σημείωση για την ενεργοποίηση του metadata σταδίου. Το Metadata-RAG, όπως εκτελέστηκε, παρουσίασε ένα σημαντικό εύρημα: το στάδιο φιλτραρίσματος μεταδεδομένων δεν ενεργοποιήθηκε σε τρία από τα τέσσερα σύνολα δεδομένων. Η αναλογία ενεργοποίησης ήταν 0.1% στο CLERC, 2.4% στο CUAD, 7.7% στο GreekBarBench, και 66.3% στο LaRA. Στις τρεις περιπτώσεις μη-ενεργοποίησης, η αρχιτεκτονική λειτούργησε ουσιαστικά ως dense-only retriever. Αυτό αποτελεί ιδιότητα της αλληλεπίδρασης του παγωμένου σχεδιασμού με τα χαρακτηριστικά των corpora και όχι σφάλμα υλοποίησης, αλλά περιορίζει την ερμηνεία των αποτελεσμάτων του Metadata-RAG στα τρία αυτά σύνολα.

6.6 Περιορισμοί και Απειλές Εγκυρότητας

6.6.1 Εύρος Δεδομένων

Η σύγκριση καλύπτει τέσσερα από τα επτά canonical datasets του προγράμματος. Τα RULER, Loong και LongBench-v2 εξαιρούνται για λόγους που τεκμηριώνονται στο Παράρτημα Α. Τα συμπεράσματα ενδέχεται να μην επεκτείνονται σε αυτά.

6.6.2 Στατιστική Αβεβαιότητα

Και οι τρεις αρχιτεκτονικές εκτελέστηκαν μία φορά, ντετερμινιστικά, στο πλήρες σύνολο ερωτημάτων. Δεν αναφέρονται bootstrap διαστήματα εμπιστοσύνης, επαναλήψεις ή paired στατιστικοί έλεγχοι. Οι παρατηρούμενες διαφορές είναι επομένως περιγραφικές και όχι συμπερασματικές. Η επόμενη φάση του προγράμματος θα εισάγει διαχωρισμό ανάπτυξης/ελέγχου και ανάλυση αβεβαιότητας.

6.6.3 Ακρίβεια Αναπαράστασης

Όλες οι αρχιτεκτονικές χρησιμοποιούν FP16 embeddings. Ένα bounded FP32 reference profile υπάρχει στο συμβόλαιο αλλά δεν εκτελέστηκε. Δεν προβάλλεται ισχυρισμός ισοδυναμίας FP32.

6.6.4 Επίπεδο Αξιολόγησης

Όλες οι αρχιτεκτονικές αξιολογούνται σε επίπεδο canonical document. Ορισμένα σύνολα (CUAD, GreekBarBench) θα μπορούσαν να αξιολογηθούν σε επίπεδο span ή clause. Το κοινό πρωτόκολλο δεσμεύεται σε επίπεδο document, και τα αποτελέσματα αντανακλούν αυτή την επιλογή.

6.6.5 Ελεγχόμενες Προσαρμογές

Και οι τρεις αρχιτεκτονικές φέρουν ελεγχόμενες προσαρμογές. Για το LongRAG: αντικατάσταση embedder και storage backend. Για τη SAH-RAG: αντικατάσταση του retrieval substrate με numpy. Για το Metadata-RAG: αντικατάσταση storage με IN_MEMORY_EXACT_DENSE και πολιτική windowing για oversize documents. Καμία από τις προσαρμογές δεν αλλάζει

την αρχιτεκτονικά καθοριστική λογική, αλλά τα αναφερόμενα αποτελέσματα αντιστοιχούν στις *εκτελεσμένες* αρχιτεκτονικές, όχι σε native reproductions.

6.6.6 Tie-breaking

Όλες οι αρχιτεκτονικές χρησιμοποιούν ντετερμινιστικά tie-breaks στα στάδια συνάθροισης. Τα αποτελέσματα είναι επομένως πλήρως αναπαραγώγιμα δεδομένων των εισόδων.

6.7 Σύνοψη

Η συγκριτική μελέτη οδηγεί στα εξής συμπεράσματα:

1. Η προτεινόμενη αρχιτεκτονική υπερτερεί του LongRAG σε όλα τα δεκαοκτώ μέτρα και σε όλα τα τέσσερα σύνολα δεδομένων, με σχετική βελτίωση 28.79% στο κύριο μέτρο.

2. Το πλεονέκτημα της SAH-RAG έναντι του LongRAG αυξάνεται όσο πιο σύντομα είναι τα έγγραφα του corpus, φτάνοντας το $+351\%$ στο CLERC.

3. Η SAH-RAG υπερτερεί επίσης του Metadata-RAG στο κύριο μέτρο (0.4049 έναντι 0.3651), με συνέπεια σε όλα τα σύνολα.

4. Η ερμηνεία των αποτελεσμάτων αποδίδει τη διαφορά σε τρεις αρχιτεκτονικούς άξονες: κοκκομετρία μονάδας, σήμα ανάκτησης και κανόνας συνάθροισης.

Τρεις αρχιτεκτονικές δεν κατέστη δυνατό να εκτελεστούν στο πλαίσιο της παρούσας εργασίας, είτε λόγω εξωτερικών περιορισμών (κόστος LLM API, άδεια χρήσης) είτε λόγω ασυμβατότητας του input contract. Αυτές τεκμηριώνονται συνοπτικά στο Παράρτημα Α, με ρητή αναγνώριση των περιορισμών των συμπερασμάτων που προκύπτουν από τη μη συμμετοχή τους.

Κεφάλαιο 7

Μελλοντική Εργασία

Η παρούσα εργασία σχεδίασε, υλοποίησε και αξιολόγησε μία δομικά ευαίσθητη, υβριδική αρχιτεκτονική ανάκτησης για long-context corpora. Τα αποτελέσματα των Κεφαλαίων 5 και 6 τεκμηριώνουν ότι η αρχιτεκτονική λειτουργεί αξιόπιστα, ότι αποδίδει βέλτιστα υπό συγκεκριμένες συνθήκες, και ότι υπερτερεί σαφώς έναντι συγκρίσιμων αρχιτεκτονικών στο κοινό corpus αξιολόγησης. Ωστόσο, όπως συμβαίνει με κάθε ερευνητική συνεισφορά, τα συμπεράσματα είναι οριοθετημένα από τις επιλογές σχεδιασμού και το εύρος των πειραμάτων. Το παρόν κεφάλαιο συζητά τις φυσικές επεκτάσεις της εργασίας, οργανωμένες σε τρεις κατηγορίες: βελτιώσεις εντός του τρέχοντος πλαισίου, επεκτάσεις σε νέα πεδία εφαρμογής, και νέες ερευνητικές κατευθύνσεις που αξιοποιούν την υποδομή που αναπτύχθηκε.

7.1 Βελτιώσεις Εντός του Τρέχοντος Πλαισίου

7.1.1 Συστηματική Απομόνωση Συστατικών (Ablation Study)

Η συγκριτική μελέτη του Κεφαλαίου 6 απομόνωσε τη συνολική συνεισφορά της αρχιτεκτονικής έναντι του LongRAG και του Metadata-RAG, αλλά δεν απομόνωσε τη συνεισφορά κάθε επιμέρους συστατικού. Μια συστηματική μελέτη ablation θα επέτρεπε την ποσοτικοποίηση της συνεισφοράς:

- της ιεραρχικής οργάνωσης (parent-child) έναντι του flat chunking·
- της διατήρησης των ορίων των parents·
- του learned-sparse σήματος έναντι της dense-only ανάκτησης·

- του RRF έναντι εναλλακτικών στρατηγικών σύντηξης·
- του κανόνα συνάθροισης best-plus-margin έναντι best-only ή sum-of-all.

Μια τέτοια μελέτη θα παρήγαγε έναν πίνακα σχετικής σημασίας κάθε συστατικού, ο οποίος θα ήταν χρήσιμος τόσο για την κατανόηση του μηχανισμού όσο και για την καθοδήγηση μελλοντικών σχεδιαστικών αποφάσεων.

7.1.2 Επέκταση του Διαχωρισμού Δεδομένων

Η μελέτη παραμέτρων του Κεφαλαίου 5 χρησιμοποίησε διαχωρισμό ανάπτυξης/ελέγχου σε επίπεδο εγγράφου. Μια φυσική επέκταση είναι η εισαγωγή πολλαπλών διαχωρισμών με διαφορετικά seeds, ώστε να ποσοτικοποιηθεί η διακύμανση των αποτελεσμάτων λόγω της τυχαιότητας του διαχωρισμού. Παράλληλα, θα μπορούσε να εισαχθεί ένα τρίτο, ανεξάρτητο σύνολο ελέγχου (locked test set) που να μην έχει χρησιμοποιηθεί ούτε για screening ούτε για confirmatory αξιολόγηση, ώστε να ελεγχθεί η σταθερότητα της επιλεγμένης διαμόρφωσης σε εντελώς νέα δεδομένα.

7.1.3 Επέκταση σε Εναπομείναντα Σύνολα Δεδομένων

Η παρούσα εργασία εκτέλεσε τα τέσσερα από τα επτά canonical datasets του προγράμματος. Τα τρία εναπομείναντα (RULER, Loong, LongBench-v2) έχουν έγγραφα με μέσο μήκος που ξεπερνά τις εκατοντάδες χιλιάδες tokens, γεγονός που τα καθιστά ακραία σενάρια long-context. Η εκτέλεση της αρχιτεκτονικής σε αυτά τα σύνολα θα επέτρεπε να ελεγχθεί αν το πλεονέκτημα της λεπτότερης κοκκομετρίας που παρατηρήθηκε στο Κεφάλαιο 6 παραμένει ή αντιστρέφεται όταν τα έγγραφα γίνονται εξαιρετικά μεγάλα. Παράλληλα, θα επέτρεπε την εκτίμηση του υπολογιστικού κόστους και του χρόνου απόκρισης σε πραγματικά μεγάλης κλίμακας corpora.

7.1.4 Ενσωμάτωση Σταδίου Παραγωγής

Η παρούσα εργασία περιορίστηκε ρητά στην ανάκτηση, χωρίς στάδιο παραγωγής απαντήσεων. Μια φυσική επέκταση είναι η ενσωμάτωση ενός γλωσσικού μοντέλου ως καταναλωτή των ανακτημένων ενοτήτων. Αυτό θα επέτρεπε τη μέτρηση της *end-to-end* ποιότητας,

δηλαδή όχι μόνο αν το σύστημα ανακτά τα σωστά τεκμήρια, αλλά και αν τα ανακτημένα τεκμήρια είναι αρκετά για την παραγωγή ορθών και τεκμηριωμένων απαντήσεων. Η μέτρηση θα μπορούσε να πραγματοποιηθεί είτε μέσω αυτόματων μετρικών (π.χ. faithfulness, answer correctness) είτε μέσω ανθρώπινης αξιολόγησης σε δείγμα ερωτημάτων.

7.1.5 Βελτιστοποίηση της Αποδοτικότητας

Η αρχιτεκτονική παράγει περίπου $101\,814$ child chunks για τα τέσσερα σύνολα δεδομένων, περίπου δεκαοκτώ φορές περισσότερα από τα 5669 long units του LongRAG. Παρότι η ποιότητα ανάκτησης δικαιολογεί αυτό το κόστος, υπάρχουν περιθώρια βελτιστοποίησης:

- **Συμπίεση διανυσμάτων**: η χρήση quantization ή product quantization θα μείωνε το αποτύπωμα αποθήκευσης κατά μία τάξη μεγέθους, με πιθανή μικρή απώλεια ακρίβειας.

- **Δείκτες ANN**: η χρήση κατάλληλου HNSW index αντί για brute-force scan θα επέτρεπε την κλιμάκωση σε corpora εκατομμυρίων chunks.

- **Δειγματοληψία υποψηφίων**: η μείωση του `candidate_limit` από 200 σε 100 έχει ήδη δείξει ελάχιστη απώλεια ποιότητας (Κεφάλαιο 5), υποδηλώνοντας ότι περαιτέρω βελτιστοποίηση είναι εφικτή.

- **Caching σεναρίων**: η αποθήκευση embeddings των συχνών queries θα μείωνε την καθυστέρηση σε περιβάλλοντα παραγωγής.

7.1.6 Επέκταση σε Πολυγλωσσικά και Πολυτροπικά Corpora

Η αρχιτεκτονική έχει σχεδιαστεί ανεξάρτητα από τη γλώσσα, και η επιλογή του BGE-M3 υποστηρίζει περισσότερες από 100 γλώσσες. Η εκτέλεση σε πολυγλωσσικά corpora πέραν της ελληνικής και της αγγλικής θα επέτρεπε τον έλεγχο της γενικευσιμότητας. Παράλληλα, επεκτάσεις σε πολυτροπικά corpora (έγγραφα με πίνακες, εικόνες, διαγράμματα) θα απαιτούσαν την επέκταση του structural parser ώστε να αναγνωρίζει δομικά όρια και σε μη-κειμενικά στοιχεία, θέτοντας το έδαφος για υβριδικές αναπαραστάσεις.

7.1.7 Επέκταση σε Δυναμικά Corpora

Η παρούσα αρχιτεκτονική προϋποθέτει στατικό corpus, με επεξεργασία που εκτελείται μία φορά για κάθε έκδοση. Μια φυσική επέκταση είναι η υποστήριξη δυναμικών ενημερώσεων: προσθήκη νέων εγγράφων, τροποποίηση υφιστάμενων, διαγραφή παρωχημένων. Αυτό θα απαιτούσε (α) μηχανισμούς incremental indexing, (β) πολιτικές ακύρωσης παλαιών embeddings, και (γ) στρατηγικές για τη διατήρηση της συνέπειας μεταξύ parents και children υπό ενημερώσεις. Η υποδομή ντετερμινιστικών ταυτοτήτων (content-addressable IDs) που υλοποιήθηκε στην παρούσα εργασία αποτελεί κατάλληλη βάση για μια τέτοια επέκταση.

7.2 Επέκταση σε Μεγάλης Κλίμακας Δομημένα Corpora

Μια από τις σημαντικότερες κατευθύνσεις μελλοντικής έρευνας αφορά την εφαρμογή της αρχιτεκτονικής σε μεγάλης κλίμακας corpora στα οποία η δομή είναι ρητά παρούσα. Η παρούσα εργασία έδειξε ότι η αναγνώριση της εσωτερικής δομής ενός εγγράφου, όταν αυτή υπάρχει, βελτιώνει σημαντικά την ποιότητα ανάκτησης (Κεφάλαιο 6). Το εύρημα αυτό δημιουργεί φυσικά το ερώτημα: *πώς συμπεριφέρεται η αρχιτεκτονική όταν εφαρμοστεί σε corpora που αποτελούνται από χιλιάδες ή εκατομμύρια δομημένα έγγραφα;*

7.2.1 Υποψήφια Πεδία Εφαρμογής

Τα καταλληλότερα πεδία για μια τέτοια επέκταση είναι εκείνα όπου η δομή των εγγράφων είναι (α) ρητή, (β) σχετικά ομοιόμορφη μεταξύ εγγράφων, και (γ) σημασιολογικά σημαντική. Τέτοια πεδία περιλαμβάνουν:

- **Βιβλία και ακαδημαϊκά συγγράμματα**: κεφάλαια, ενότητες, υποενότητες, παράγραφοι, υποσημειώσεις.
- **Νομικά corpora μεγάλης κλίμακας**: νομοθεσία, νομολογία, συμβόλαια, δικαστικές αποφάσεις, διοικητικά έγγραφα.
- **Ιατρικά και κλινικά corpora**: κατευθυντήριες οδηγίες, κλινικές μελέτες, εγχειρίδια, διαγνωστικά πρωτόκολλα.
- **Τεχνικά εγχειρίδια και πρότυπα**: πρότυπα ISO, τεχνικές προδιαγραφές, εγχειρίδια μηχανικής.

- **Δημόσια διοικητικά αρχεία**: εγκύκλιοι, αποφάσεις, διατάγματα, πρακτικά συνεδριάσεων.

7.2.2 Προκλήσεις Κλίμακας

Η εφαρμογή σε τέτοια corpora θα έθετε νέες προκλήσεις που δεν αντιμετωπίστηκαν στην παρούσα εργασία:

- **Ετερογένεια δομής**: διαφορετικά έγγραφα εντός του ίδιου corpus ενδέχεται να ακολουθούν διαφορετικές δομικές συμβάσεις. Αυτό απαιτεί είτε προσαρμοστικό parser είτε ιεραρχία parsers.
- **Κλίμακα αποθήκευσης**: corpus εκατομμυρίων εγγράφων απαιτεί κατανεμημένη αποθήκευση και δείκτες ANN αντί brute-force.
- **Οριζόντια κλιμάκωση**: η ανάγκη για παράλληλη επεξεργασία χιλιάδων documents απαιτεί αρχιτεκτονικές streaming με batching και συνεπή state management.
- **Ποιοτικός έλεγχος parsing**: σε μεγάλης κλίμακας corpora, τα σφάλματα parsing πολλαπλασιάζονται. Απαιτείται μηχανισμός αυτόματης ανίχνευσης ανωμαλιών.
- **Διαχρονική εξέλιξη**: corpora όπως η νομοθεσία ενημερώνονται συνεχώς, απαιτώντας μηχανισμούς versioning και ενημέρωσης.

7.2.3 Ερευνητικά Ερωτήματα

Η εφαρμογή σε μεγάλης κλίμακας δομημένα corpora θα επέτρεπε τη διερεύνηση ερωτημάτων όπως:

1. Πώς κλιμακώνεται η ποιότητα ανάκτησης με το μέγεθος του corpus;
2. Ποιες κατηγορίες δομικών σχέσεων (π.χ. cross-references, αναδρομικές παραπομπές) αξιοποιούνται καλύτερα;
3. Πώς επηρεάζεται η απόδοση από την ομοιομορφία της δομής των εγγράφων;
4. Πώς μπορεί η αρχιτεκτονική να επεκταθεί ώστε να αξιοποιεί σχέσεις *μεταξύ* εγγράφων, πέραν των εντός-εγγράφου σχέσεων;

5. Ποιες είναι οι πραγματικές ανάγκες των χρηστών σε τέτοια συστήματα, και πώς διαφέρουν από τα ερωτήματα των προτύπων αξιολόγησης;

Η μετάβαση από το στάδιο της εργαστηριακής αξιολόγησης στο στάδιο της εφαρμογής σε πραγματικά μεγάλης κλίμακας corpora αποτελεί φυσική συνέχεια της παρούσας εργασίας και θα επέτρεπε την αξιολόγηση της αρχιτεκτονικής υπό συνθήκες που προσεγγίζουν τις πραγματικές ανάγκες εφαρμογών παραγωγής.

7.3 Διαχείριση Πληροφορίας σε Γλωσσικά Μοντέλα Μειωμένου Context Window

Η δεύτερη κύρια κατεύθυνση μελλοντικής έρευνας αξιοποιεί την υποδομή που αναπτύχθηκε στην παρούσα εργασία ως θεμέλιο για τη μελέτη της διαχείρισης πληροφορίας σε γλωσσικά μοντέλα με περιορισμένο context window. Η παρούσα εργασία έδειξε ότι ένα κατάλληλα δομημένο σύστημα εξωτερικής μνήμης μπορεί να περιορίσει σημαντικά την ανάγκη διατήρησης ολόκληρου του corpus εντός του context ενός LLM. Το επόμενο λογικό βήμα είναι η μελέτη του τρόπου με τον οποίο ένα γλωσσικό μοντέλο μπορεί να αξιοποιήσει αυτή την εξωτερική μνήμη για τη διαχείριση πληροφορίας που υπερβαίνει το διαθέσιμο context του.

7.3.1 Το Ερευνητικό Πρόβλημα

Τα σύγχρονα LLMs διαθέτουν context windows που κυμαίνονται από μερικές χιλιάδες έως εκατομμύρια tokens. Ωστόσο, όπως τεκμηριώθηκε στο Κεφάλαιο 2, η αύξηση του context window δεν αρκεί για την αποτελεσματική αξιοποίηση της πληροφορίας. Τα μοντέλα τείνουν να αγνοούν πληροφορία στο μέσο του context (lost-in-the-middle effect), ενώ το υπολογιστικό κόστος αυξάνεται τετραγωνικά με το μήκος της εισόδου. Το πρόβλημα γίνεται εντονότερο σε σενάρια όπου το μοντέλο πρέπει να διατηρήσει κατάσταση (state) πάνω σε πολλαπλές αλληλεπιδράσεις ή να επεξεργαστεί περιεχόμενο που υπερβαίνει το context του.

Η ιδέα της χρήσης ενός μικρού context window LLM σε συνδυασμό με μηχανισμούς εξωτερικής μνήμης προσφέρει μια εναλλακτική προσέγγιση: αντί να αυξάνεται το context του μοντέλου, το μοντέλο καλείται να διαχειριστεί ενεργά τη ροή πληροφορίας μεταξύ του context του και ενός εξωτερικού χώρου αποθήκευσης.

7.3.2 Προτεινόμενη Αρχιτεκτονική

Η προτεινόμενη κατεύθυνση έρευνας περιλαμβάνει τον σχεδιασμό και την αξιολόγηση ενός συστήματος που αποτελείται από τα εξής συστατικά:

- **Γλωσσικό μοντέλο περιορισμένου context**: ένα μοντέλο του οποίου το context window είναι σκόπιμα περιορισμένο, ώστε να ασκείται πίεση στους μηχανισμούς διαχείρισης.
- **Scratchpad**: ένας εξωτερικός χώρος αποθήκευσης που λειτουργεί ως επέκταση της μνήμης του μοντέλου. Περιέχει περιλήψεις, ενδιάμεσα συμπεράσματα, και σημαντικές πληροφορίες που δεν χωρούν στο άμεσο context του μοντέλου.
- **Μηχανισμός εξωτερικής ανάκτησης**: το σύστημα ανάκτησης που αναπτύχθηκε στην παρούσα εργασία, το οποίο παρέχει στο μοντέλο τα σχετικά τεκμήρια όταν αυτό τα χρειάζεται.
- **Agent οργανωτής**: ένας μηχανισμός που αποφασίζει ενεργά:
  - πότε να ανακτήσει νέα πληροφορία από την εξωτερική μνήμη·
  - ποια τμήματα του τρέχοντος context να διατηρήσει·
  - ποια τμήματα να απορρίψει (eviction)·
  - πότε να συμπιέσει πληροφορία σε περίληψη·
  - πότε να αποθηκεύσει περίληψη στο scratchpad·
  - πότε να ανακτήσει παλαιότερη περίληψη από το scratchpad.

Η αρχιτεκτονική θα μπορούσε να λειτουργήσει σε δύο επίπεδα: ένα επίπεδο διαχείρισης (ο agent οργανωτής) και ένα επίπεδο επεξεργασίας (το LLM). Ο agent θα λειτουργούσε ως μετα-επεξεργαστής, αποφασίζοντας τη ροή πληροφορίας μεταξύ των συστατικών, ενώ το LLM θα εκτελούσε τη βασική εργασία (απάντηση ερωτημάτων, παραγωγή περιλήψεων, εξαγωγή πληροφορίας).

7.3.3 Ερευνητικά Ερωτήματα

Η έρευνα θα μπορούσε να εξετάσει τα ακόλουθα ερωτήματα:

1. Ποιοι κανόνες (heuristics) για eviction και summarization είναι αποτελεσματικοί σε σενάρια long-context;

2. Πώς επηρεάζει η πολιτική eviction την ποιότητα των τελικών απαντήσεων;

3. Πώς μπορεί ο agent να εκπαιδευτεί (με reinforcement learning ή άλλες μεθόδους) ώστε να λαμβάνει βέλτιστες αποφάσεις διαχείρισης;

4. Πώς συγκρίνεται η προσέγγιση με μοντέλα μεγάλου context window ως προς την ποιότητα, το κόστος και την καθυστέρηση;

5. Ποιες είναι οι συνθήκες υπό τις οποίες ένα μικρό μοντέλο με εξωτερική μνήμη υπερτερεί ενός μεγάλου μοντέλου με άμεσο context;

6. Πώς κλιμακώνεται η προσέγγιση με το μέγεθος της πληροφορίας που πρέπει να διαχειριστεί;

7.3.4 Αναμενόμενη Συνεισφορά

Η κατεύθυνση αυτή θα είχε δύο κύριες συνεισφορές. Πρώτον, θα επέκτεινε την κατανόηση των μηχανισμών διαχείρισης πληροφορίας σε LLMs, παρέχοντας εμπειρικά δεδομένα για το πώς διαφορετικές πολιτικές eviction και summarization επηρεάζουν την ποιότητα. Δεύτερον, θα παρήγαγε μια αρχιτεκτονική που θα μπορούσε να εφαρμοστεί πρακτικά σε σενάρια όπου το μέγεθος του μοντέλου ή το κόστος του context είναι περιορισμένοι, όπως σε τοπικές εφαρμογές, σε περιβάλλοντα με περιορισμένους υπολογιστικούς πόρους, ή σε εφαρμογές όπου η καθυστέρηση είναι κρίσιμη.

Η υποδομή που αναπτύχθηκε στην παρούσα εργασία παρέχει τη βάση για μια τέτοια έρευνα: το σύστημα ανάκτησης λειτουργεί ως ο μηχανισμός εξωτερικής μνήμης, ενώ τα δομημένα τεχνουργήματα (parents, children, ταυτότητες, manifests) επιτρέπουν τη διατήρηση της συνέπειας μεταξύ των διαφόρων σταδίων της διαδικασίας διαχείρισης.

7.3.5 Σχέση με την Παρούσα Εργασία

Η παρούσα εργασία αποτελεί απαραίτητο προπαρασκευαστικό βήμα για τη συγκεκριμένη κατεύθυνση. Χωρίς ένα αξιόπιστο σύστημα εξωτερικής ανάκτησης, οποιαδήποτε προσπάθεια διαχείρισης πληροφορίας σε LLM θα βασιζόταν σε ανακριβή ή ελλιπή τεκμήρια.

Το σύστημα που παρουσιάστηκε στα Κεφάλαια 3 και 4, και αξιολογήθηκε στα Κεφάλαια 5 και 6, αποδεικνύει ότι είναι εφικτή η αξιόπιστη ανάκτηση σχετικής πληροφορίας από μεγάλα corpora με λεπτομερή κοκκομετρία και διατήρηση της δομής. Αυτό αποτελεί τη βάση πάνω στην οποία μπορεί να οικοδομηθεί η έρευνα για τη διαχείριση του context.

7.4 Άλλες Κατευθύνσεις

Πέραν των παραπάνω κύριων κατευθύνσεων, υπάρχουν αρκετές ακόμη πτυχές που θα μπορούσαν να εξεταστούν σε μελλοντική έρευνα.

7.4.1 Επέκταση των Δυνατοτήτων Ανάκτησης

Η αρχιτεκτονική θα μπορούσε να επεκταθεί με πρόσθετους μηχανισμούς ανάκτησης:

- **Cross-encoder reranking**: η προσθήκη ενός σταδίου reranking με cross-encoder μετά την αρχική ανάκτηση θα μπορούσε να βελτιώσει την ακρίβεια σε βάρος της καθυστέρησης.
- **Query expansion**: η επέκταση των queries με συνώνυμους όρους ή σχετικές έννοιες θα μπορούσε να βελτιώσει την ανάκτηση σε περιπτώσεις όπου το ερώτημα είναι πολύ σύντομο.
- **Multi-vector retrieval**: η χρήση πολλαπλών διανυσμάτων ανά chunk (π.χ. ColBERT-style late interaction) θα μπορούσε να βελτιώσει τη λεπτομερή αντιστοίχιση.
- **Query routing**: η δρομολόγηση ερωτημάτων σε διαφορετικά υποσυστήματα ανάκτησης ανάλογα με τον τύπο τους (factual, multi-hop, thematic) θα μπορούσε να βελτιώσει τη συνολική απόδοση.

7.4.2 Αξιολόγηση με Ανθρώπινους Χρήστες

Η παρούσα εργασία αξιολόγησε την αρχιτεκτονική με αυτόματες μετρικές. Μια φυσική επέκταση είναι η αξιολόγηση με πραγματικούς χρήστες, η οποία θα επέτρεπε:

- τη μέτρηση της αντιληπτής χρησιμότητας των ανακτημένων ενοτήτων·
- την κατανόηση των αναγκών των χρηστών σε πραγματικά σενάρια·

- την αξιολόγηση της ευχρηστίας του συστήματος πέραν της τεχνικής ορθότητας·
- τον εντοπισμό περιπτώσεων όπου οι αυτόματες μετρικές αποκλίνουν από την ανθρώπινη κρίση.

7.4.3 Ενοποίηση με Βάσεις Δεδομένων Γνώσης

Η αρχιτεκτονική θα μπορούσε να ενοποιηθεί με εξωτερικές βάσεις δεδομένων γνώσης (knowledge graphs, ontologies) ώστε να αξιοποιεί δομημένες σχέσεις πέραν των εντός-εγγράφου σχέσεων. Αυτό θα επέτρεπε:

- την ανάκτηση βάσει σημασιολογικών σχέσεων (π.χ. «όλα τα έγγραφα που αναφέρονται στον νόμο Χ»)·
- τη συλλογιστική πάνω σε δομημένες σχέσεις (π.χ. «ποιοι νόμοι τροποποιήθηκαν από τον νόμο Υ»)·
- τη διασύνδεση εγγράφων μέσω κοινών οντοτήτων, πέραν της σημασιολογικής ομοιότητας.

7.4.4 Εφαρμογή σε Πραγματικά Συστήματα

Τέλος, μια φυσική κατεύθυνση είναι η εφαρμογή της αρχιτεκτονικής σε πραγματικά συστήματα υποστήριξης αποφάσεων, όπως:

- **Νομικά συστήματα**: υποστήριξη δικηγόρων στην ανεύρεση σχετικής νομολογίας και νομοθεσίας.
- **Ιατρικά συστήματα**: υποστήριξη ιατρών στην ανεύρεση σχετικών κλινικών μελετών και κατευθυντήριων οδηγιών.
- **Ερευνητικά συστήματα**: υποστήριξη ερευνητών στη βιβλιογραφική επισκόπηση.
- **Εκπαιδευτικά συστήματα**: υποστήριξη μαθητών και φοιτητών στην ανεύρεση σχετικού εκπαιδευτικού υλικού.

Η εφαρμογή σε τέτοια συστήματα θα απαιτούσε προσαρμογή της αρχιτεκτονικής στις ειδικές ανάγκες κάθε πεδίου, αλλά θα παρείχε πολύτιμη εμπειρία για τη γενικότερη κατανόηση του τρόπου με τον οποίο λειτουργούν τα συστήματα RAG σε πραγματικές συνθήκες.

7.5 Σύνοψη

Το παρόν κεφάλαιο παρουσίασε τις κύριες κατευθύνσεις μελλοντικής έρευνας που προκύπτουν από την παρούσα εργασία. Οι κατευθύνσεις οργανώθηκαν σε τρεις κατηγορίες:

- **Βελτιώσεις εντός του τρέχοντος πλαισίου**: ablation studies, επεκτάσεις του διαχωρισμού δεδομένων, εκτέλεση σε εναπομείναντα σύνολα, ενσωμάτωση σταδίου παραγωγής, βελτιστοποίηση αποδοτικότητας, πολυγλωσσικές και πολυτροπικές επεκτάσεις, δυναμικά corpora.

- **Επέκταση σε μεγάλης κλίμακας δομημένα corpora**: εφαρμογή σε βιβλία, νομικά έγγραφα, ιατρικά corpora, τεχνικά εγχειρίδια, διοικητικά αρχεία, με έμφαση στις προκλήσεις κλίμακας και στα νέα ερευνητικά ερωτήματα.

- **Διαχείριση πληροφορίας σε LLMs μειωμένου context window**: σχεδιασμός και αξιολόγηση ενός συστήματος που συνδυάζει μικρό context window LLM, scratchpad, agent οργανωτή και εξωτερική μνήμη.

Οι δύο τελευταίες κατευθύνσεις αποτελούν τις πλέον φιλόδοξες επεκτάσεις της παρούσας εργασίας. Η πρώτη αξιοποιεί την τεκμηριωμένη ικανότητα της αρχιτεκτονικής να αξιοποιεί τη δομή των εγγράφων, επεκτείνοντάς την σε μεγάλης κλίμακας corpora. Η δεύτερη αξιοποιεί την υποδομή εξωτερικής ανάκτησης ως θεμέλιο για τη μελέτη της διαχείρισης του context σε γλωσσικά μοντέλα, ανοίγοντας ένα νέο πεδίο έρευνας που βρίσκεται στο μεταίχμιο μεταξύ ανάκτησης πληροφορίας, γλωσσικών μοντέλων και μηχανισμών μνήμης. Και οι δύο κατευθύνσεις θα μπορούσαν να οδηγήσουν σε ουσιαστικές συνεισφορές στο πεδίο των συστημάτων RAG και της διαχείρισης γνώσης σε μεγάλη κλίμακα.

Κεφάλαιο 8

Συμπεράσματα

8.1 Σύνοψη της Εργασίας

Η παρούσα εργασία εξέτασε το πρόβλημα της αποδοτικής ανάκτησης πληροφορίας από μεγάλα, δομημένα corpora, με έμφαση στα long-context σενάρια όπου η σχετική πληροφορία για ένα ερώτημα είναι διάσπαρτη σε εκτενή έγγραφα και συχνά απαιτεί τη συνδυασμένη αξιοποίηση απομακρυσμένων τμημάτων. Αφετηρία της εργασίας υπήρξε η παρατήρηση ότι, παρότι τα συστήματα Retrieval-Augmented Generation έχουν ωριμάσει ως προς τη βασική τους αρχιτεκτονική, η ποιότητα του μηχανισμού ανάκτησης παραμένει ο κύριος περιοριστικός παράγοντας της συνολικής τους απόδοσης. Όταν το στάδιο retrieval επιστρέφει ελλιπή ή μη σχετικά τεκμήρια, ακόμη και ένα ισχυρό γλωσσικό μοντέλο παράγει ανακριβείς απαντήσεις.

Με βάση την παρατήρηση αυτή, η εργασία έθεσε ως κεντρικό ερευνητικό ερώτημα τον τρόπο με τον οποίο διαφορετικές αρχιτεκτονικές επιλογές στο στάδιο της ανάκτησης — κοκκομετρία, τρόπος αναπαράστασης, σήμα ανάκτησης, κανόνας συνάθροισης— επηρεάζουν την ποιότητα της ανάκτησης από πραγματικά long-context corpora. Για τη διερεύνηση του ερωτήματος αυτού σχεδιάστηκε, υλοποιήθηκε και αξιολογήθηκε η SAH-RAG (*Structure-Aware Hierarchical RAG*), μία δομικά ενήμερη, ιεραρχική, υβριδική αρχιτεκτονική ανάκτησης.

Η αρχιτεκτονική οργανώνει τη γνώση σε τρία επίπεδα. Τα έγγραφα αναλύονται αρχικά από έναν ντετερμινιστικό structural parser, ο οποίος παράγει semantic parents που αντιστοιχούν σε λογικές ενότητες. Κάθε parent διασπάται σε μικρότερα child chunks των 256 tokens, τα οποία δεν διαπερνούν ποτέ τα όρια του parent. Τα child chunks αποτελούν τη μονάδα

ανάκτησης, ενώ τα parents και τα canonical documents αποτελούν τις μονάδες κατάταξης. Η ανάκτηση πραγματοποιείται παράλληλα από δύο αναπαραστάσεις — dense και learned-sparse — μέσω του μοντέλου BGE-M3, και οι δύο κατατάξεις συντήκονται με Reciprocal Rank Fusion. Τα αποτελέσματα συναθροίζονται σε επίπεδο parent μέσω ενός κανόνα best-plus-margin και σε επίπεδο document μέσω επιλογής του βέλτιστου parent.

Η υλοποίηση της αρχιτεκτονικής πραγματοποιήθηκε με έμφαση στη ντετερμινιστικότητα και την αναπαραγωγιμότητα. Κάθε τεχνούργημα (parent, chunk, embedding, qdrant point) έχει content-addressable ταυτότητα, όλες οι σειριοποιήσεις είναι byte-deterministic, και όλα τα στάδια είναι resume-safe μέσω SHA-256 manifests.

Η αξιολόγηση της αρχιτεκτονικής πραγματοποιήθηκε σε δύο φάσεις. Στην πρώτη φάση (Κεφάλαιο 5) μελετήθηκε η απόκριση της αρχιτεκτονικής ως προς τις παραμέτρους που η ίδια εκθέτει, με στόχο τον προσδιορισμό της βέλτιστης διαμόρφωσης λειτουργίας. Στη δεύτερη φάση (Κεφάλαιο 6) πραγματοποιήθηκε συγκριτική μελέτη της αρχιτεκτονικής έναντι άλλων αρχιτεκτονικών ανάκτησης υπό κοινό πρωτόκολλο.

8.2 Κύρια Ευρήματα

8.2.1 Βέλτιστη Διαμόρφωση Λειτουργίας

Η μελέτη παραμέτρων του Κεφαλαίου 5 κατέληξε σε πέντε κύρια ευρήματα. Πρώτον, η απόκριση της αρχιτεκτονικής ως προς το `chunk_size` είναι μονοτονικά φθίνουσα στο εξεταζόμενο φάσμα (256, 512, 1024 tokens): τα μικρότερα chunks αποδίδουν καλύτερα, γεγονός που έρχεται σε αντίθεση με την αρχική υπόθεση για plateau γύρω από μία ενδιάμεση τιμή. Το εύρημα αυτό αποδόθηκε στη διατήρηση των ορίων των parents και στην ανάγκη για πραγματική διάκριση μεταξύ child και parent κοκκομετρίας. Δεύτερον, η απόκριση ως προς το `chunk_overlap` είναι μονοτονικά αύξουσα αλλά κορεσμένη στο 32 tokens: περαιτέρω αύξηση δεν προσφέρει μετρήσιμο όφελος. Τρίτον, το `candidate_limit` βελτιώνει την ποιότητα έως το 100 και μετά κορεσμό. Τέταρτον, το υβριδικό σήμα (dense + sparse με RRF) υπερτερεί σαφώς τόσο του dense-only όσο και του sparse-only, με διαφορά που υπερβαίνει το τυπικό σφάλμα bootstrap. Πέμπτον, η προεπιλεγμένη διαμόρφωση της αρχιτεκτονικής (`c256_o32_hybrid_rrf_k200`) αποδείχθηκε σχεδόν βέλτιστη εντός της ζώνης ενός τυπικού σφάλματος, γεγονός που σημαίνει ότι η αρχιτεκτονική είναι καλά ρυθμισμένη εξ αρχής.

Στον κλειδωμένο διαχωρισμό ελέγχου, η παγωμένη διαμόρφωση πέτυχε macro-document

Recall@10 ίσο με 0.3961, με διαφορά ανάπτυξης-ελέγχου -0.0107, εντός της ζώνης ενός τυπικού σφάλματος. Το αποτέλεσμα είναι σταθερό και αναπαραγώγιμο.

8.2.2 Συγκριτική Αξιολόγηση

Η συγκριτική μελέτη του Κεφαλαίου 6 οδήγησε σε τρία κύρια συμπεράσματα. Πρώτον, η SAH-RAG υπερτερεί του LongRAG σε *όλα* τα δεκαοκτώ μέτρα που αναφέρθηκαν και σε *όλα* τα τέσσερα σύνολα δεδομένων, με σχετική βελτίωση 28.79% στο κύριο μέτρο (macro document Recall@10: 0.4049 έναντι 0.3144). Δεύτερον, το μέγεθος του πλεονεκτήματος αυξάνεται συστηματικά με τη μείωση του μέσου μήκους των εγγράφων του corpus: από $+5.7\%$ στο LaRA (όπου τα έγγραφα είναι εξαιρετικά μεγάλα και οι δύο αρχιτεκτονικές λειτουργούν σε near-document κοκκομετρία) έως $+351\%$ στο CLERC (όπου τα έγγραφα είναι σύντομα και η ομαδοποίηση του LongRAG αραιώνει σοβαρά τα σχετικά τεκμήρια). Το εύρημα αυτό αποδίδεται σε μία σαφή αρχιτεκτονική αιτία: τη διαφορά κοκκομετρίας των μονάδων ανάκτησης. Τρίτον, η SAH-RAG υπερτερεί επίσης του Metadata-RAG στο κύριο μέτρο (0.4049 έναντι 0.3651), με συνέπεια σε όλα τα σύνολα δεδομένων, γεγονός που επιβεβαιώνει τη σημασία του υβριδικού σήματος και του κανόνα συνάθροισης.

Συνολικά, η σύγκριση απομόνωσε με ασυνήθιστη καθαρότητα τον ρόλο της κοκκομετρίας της μονάδας ανάκτησης ως καθοριστικού παράγοντα της ποιότητας σε long-context corpora. Δεδομένου ότι οι αρχιτεκτονικές που συγκρίθηκαν μοιράστηκαν embedder, πρωτόκολλο, σύνολα δεδομένων και evaluator, οι παρατηρούμενες διαφορές αποδίδονται αποκλειστικά σε αρχιτεκτονικούς άξονες.

8.3 Συνεισφορές της Εργασίας

Η παρούσα εργασία συνεισφέρει σε τέσσερα επίπεδα.

Αρχιτεκτονική συνεισφορά. Σχεδιάστηκε και υλοποιήθηκε η SAH-RAG, μία ντετερμινιστική, δομικά ενήμερη, ιεραρχική, υβριδική αρχιτεκτονική ανάκτησης, η οποία συνδυάζει τη λεπτομερή κοκκομετρία των child chunks με τη διατήρηση του ευρύτερου πλαισίου μέσω των semantic parents, και συνδυάζει τη σημασιολογική ισχύ των dense embeddings με την ακρίβεια των learned-sparse αναπαραστάσεων. Η αρχιτεκτονική είναι ανεξάρτητη από συγκεκριμένα μοντέλα, γλώσσες και τομείς εφαρμογής.

Μεθοδολογική συνεισφορά. Διαμορφώθηκε ένα κοινό πρωτόκολλο δίκαιης σύγκρισης για αρχιτεκτονικές ανάκτησης, το οποίο ορίζει με ακρίβεια τα κοινά συστατικά (embedder, query set, ground truth, evaluator), τις επιτρεπτές αρχιτεκτονικές διαφοροποιήσεις, και τους μηχανισμούς αποφυγής διαρροής ground truth στο στάδιο της ανάκτησης. Το πρωτόκολλο εφαρμόστηκε ομοιόμορφα σε όλες τις συγκρίσεις.

Εμπειρική συνεισφορά. Παρήχθησαν μετρήσεις απόκρισης παραμέτρων και μετρήσεις συγκριτικής απόδοσης σε τέσσερα ετερογενή σύνολα δεδομένων (CLERC, CUAD, Greek-BarBench, LaRA), με πλήρη τεκμηρίωση των αποτελεσμάτων, συμπεριλαμβανομένων των αρνητικών ευρημάτων (η μη-υποστήριξη της H1 υπόθεσης περί plateau του chunk size).

Υποδομής συνεισφορά. Αναπτύχθηκε μία πλήρης, ντετερμινιστική, αναπαραγώγιμη pipeline, με content-addressable ταυτότητες, atomic writes, SHA-256 manifests, και resume-safe εκτέλεση. Η υποδομή αυτή είναι επαναχρησιμοποιήσιμη για μελλοντικές αρχιτεκτονικές και για την επέκταση της έρευνας σε νέα corpora και νέα σενάρια.

8.4 Περιορισμοί

Η εργασία έχει οριοθετημένους περιορισμούς που πρέπει να ληφθούν υπόψη στην ερμηνεία των συμπερασμάτων.

Εύρος δεδομένων. Η αξιολόγηση κάλυψε τέσσερα από τα επτά canonical datasets του προγράμματος. Τα RULER, Loong και LongBench-v2 εξαιρέθηκαν για λόγους υπολογιστικού κόστους και για διατήρηση της συνοχής του σκοπού της σύγκρισης. Τα συμπεράσματα ενδέχεται να μην επεκτείνονται σε σύνολα με πολύ μεγαλύτερα έγγραφα.

Ακρίβεια αναπαράστασης. Όλα τα embeddings παρήχθησαν σε FP16. Ένα bounded FP32 profile υπάρχει στο συμβόλαιο αλλά δεν εκτελέστηκε. Δεν προβάλλεται ισχυρισμός ισοδυναμίας FP32.

Retrieval-only scope. Η εργασία περιορίστηκε ρητά στην ανάκτηση, χωρίς στάδιο παραγωγής απαντήσεων. Τα συμπεράσματα αφορούν την ποιότητα ανάκτησης, όχι την end-to-end ποιότητα ενός συστήματος RAG.

Ελεγχόμενες προσαρμογές. Τρεις αρχιτεκτονικές που συμμετείχαν στη σύγκριση (η SAH-RAG, το LongRAG, το Metadata-RAG) εκτελέστηκαν με ελεγχόμενες προσαρμογές σε επιμέρους συστατικά (storage substrate, embedder, windowing). Καμία προσαρμογή δεν αλλοίωσε την αρχιτεκτονικά καθοριστική λογική, αλλά τα αναφερόμενα αποτελέσματα αντιστοιχούν στις εκτελεσμένες αρχιτεκτονικές.

Στατιστική αβεβαιότητα. Οι συγκρίσεις εκτελέστηκαν μία φορά, ντετερμινιστικά, στο πλήρες σύνολο ερωτημάτων. Δεν αναφέρονται bootstrap διαστήματα εμπιστοσύνης ή paired στατιστικοί έλεγχοι. Οι διαφορές είναι περιγραφικές.

Μη εκτελεσθείσες αρχιτεκτονικές. Πέντε αρχιτεκτονικές αναφοράς (HippoRAG 2, RAPTOR, LightRAG, DISRetrieval, HiKEY) δεν κατέστη δυνατό να εκτελεστούν, λόγω εξωτερικών περιορισμών (κόστος LLM API, άδεια χρήσης, ασυμβατότητα εισόδου). Οι περιορισμοί αυτοί οριοθετούν ρητά το εύρος των συμπερασμάτων της συγκριτικής μελέτης.

8.5 Αναστοχασμός πάνω στα Αποτελέσματα

Το πιο ουσιαστικό εύρημα της εργασίας δεν είναι το απόλυτο μέγεθος του πλεονεκτήματος της SAH-RAG έναντι του LongRAG, αλλά ο *μηχανισμός* που εξηγεί το πλεονέκτημα αυτό. Η σύγκριση έδειξε ότι σε long-context corpora η κοκκομετρία της μονάδας ανάκτησης επηρεάζει καθοριστικά την ποιότητα, και ότι η επίδραση αυτή είναι συστηματική και προβλέψιμη: όσο πιο σύντομα είναι τα έγγραφα, τόσο μεγαλύτερο είναι το κόστος της χονδροειδούς ομαδοποίησης. Το εύρημα αυτό έχει γενικότερη αξία πέραν της συγκεκριμένης σύγκρισης, καθώς υποδεικνύει μία σχεδιαστική αρχή: οι αρχιτεκτονικές long-context θα πρέπει να αποφεύγουν τη συσκευασία ετερογενών εγγράφων σε ενιαίες μονάδες, εκτός αν υπάρχει σαφής λόγος (π.χ. πολύ μεγάλα έγγραφα ή ομοιογενές corpus).

Παράλληλα, η εργασία έδειξε ότι η επίτευξη υψηλής ποιότητας ανάκτησης σε long-context corpora δεν απαιτεί ούτε εξαντλητική υπολογιστική ισχύ ούτε σύνθετες αρχιτεκτονικές με μη-ντετερμινιστικά συστατικά. Μία σχετικά απλή αρχιτεκτονική, βασισμένη σε δομική ανάλυση, ιεραρχική οργάνωση, υβριδικό σήμα ανάκτησης και ντετερμινιστική συνάθροιση, μπορεί να επιτύχει σημαντικά καλύτερα αποτελέσματα από μία state-of-the-art αρχιτεκτονική που βασίζεται σε χονδροειδή ομαδοποίηση, και να υπερβεί μία άλλη state-of-the-art αρχιτεκτονική που βασίζεται σε metadata filtering, όταν αυτό το φιλτράρισμα δεν

ενεργοποιείται.

Το εύρημα αυτό υποδεικνύει επίσης τη σημασία της *διατήρησης της δομής* ως αρχιτεκτονικής αρχής. Οι περισσότερες σύγχρονες αρχιτεκτονικές RAG αντιμετωπίζουν τα έγγραφα ως επίπεδες ακολουθίες κειμένου, χωρίς να αξιοποιούν την εσωτερική τους δομή. Η παρούσα εργασία έδειξε ότι, τουλάχιστον για corpora όπου η δομή είναι ρητά παρούσα, η αξιοποίησή της προσφέρει σαφές πλεονέκτημα.

8.6 Προς το Μέλλον

Το Κεφάλαιο 7 παρουσίασε αναλυτικά τις κατευθύνσεις μελλοντικής έρευνας. Εδώ συνοψίζονται οι δύο σημαντικότερες, οι οποίες αποτελούν φυσικές επεκτάσεις της παρούσας εργασίας.

Η πρώτη αφορά την εφαρμογή της αρχιτεκτονικής σε μεγάλης κλίμακας δομημένα corpora, όπως βιβλία, νομικά αρχεία, ιατρικά κείμενα ή τεχνικά εγχειρίδια. Δεδομένου ότι η αρχιτεκτονική απέδειξε την ικανότητά της να αξιοποιεί τη δομή των εγγράφων, και δεδομένου ότι τα αποτελέσματα υποδεικνύουν ότι η απόδοσή της είναι σταθερή σε ετερογενή corpora, η επέκταση σε μεγαλύτερης κλίμακας εφαρμογές αποτελεί λογικό επόμενο βήμα. Μια τέτοια επέκταση θα απαιτούσε την προσαρμογή των μηχανισμών αποθήκευσης και ανάκτησης σε μεγαλύτερες κλίμακες, καθώς και την αντιμετώπιση νέων προκλήσεων όπως η ετερογένεια δομής και η διαχρονική εξέλιξη των corpora.

Η δεύτερη αφορά τη μελέτη της διαχείρισης πληροφορίας σε γλωσσικά μοντέλα με περιορισμένο context window. Η παρούσα εργασία παρείχε ένα αξιόπιστο σύστημα εξωτερικής ανάκτησης, το οποίο μπορεί να λειτουργήσει ως βάση για τη μελέτη μηχανισμών εξωτερικής μνήμης. Η ιδέα συνίσταται στον συνδυασμό ενός μικρού context window LLM με έναν εξωτερικό χώρο αποθήκευσης (scratchpad) και έναν μηχανισμό που αποφασίζει πότε να διατηρήσει, να απορρίψει ή να συμπιέσει πληροφορία. Μια τέτοια προσέγγιση θα μπορούσε να οδηγήσει σε συστήματα που λειτουργούν με μικρότερα και φθηνότερα μοντέλα, διατηρώντας παράλληλα την ικανότητα διαχείρισης μεγάλου όγκου πληροφορίας.

Και οι δύο κατευθύνσεις αξιοποιούν την υποδομή που αναπτύχθηκε στην παρούσα εργασία και επεκτείνουν τη συνεισφορά της σε νέα πεδία.

8.7 Καταληκτική Παρατήρηση

Η παρούσα εργασία ξεκίνησε από μία απλή παρατήρηση: τα συστήματα Retrieval-Augmented Generation είναι τόσο καλά όσο το στάδιο ανάκτησης που τα τροφοδοτεί. Η διερεύνηση της παρατήρησης αυτής οδήγησε στον σχεδιασμό και την αξιολόγηση μιας αρχιτεκτονικής που αντιμετωπίζει το corpus όχι ως επίπεδη συλλογή κειμένου αλλά ως δομημένη γνώση. Η SAH-RAG δεν είναι επαναστατική ως προς τα επιμέρους συστατικά της — η ιεραρχική οργάνωση, το υβριδικό σήμα ανάκτησης και η συνάθροιση σε επίπεδο parent είναι όλα γνωστές τεχνικές. Αυτό που προσφέρει είναι η *σύνθεσή* τους σε ένα συνεκτικό, ντετερμινιστικό, αναπαραγώγιμο σύστημα, και η συστηματική εμπειρική τεκμηρίωση της αποτελεσματικότητάς του σε πραγματικά long-context corpora.

Τα αποτελέσματα της εργασίας δείχνουν ότι η επίτευξη υψηλής ποιότητας ανάκτησης σε long-context σενάρια είναι εφικτή με προσεκτικό σχεδιασμό, χωρίς απαραίτητα την χρήση σύνθετων ή μη-ντετερμινιστικών μηχανισμών. Παράλληλα, τα αποτελέσματα υποδεικνύουν ότι το πεδίο παραμένει ανοιχτό: η κοκκομετρία, το σήμα ανάκτησης και ο κανόνας συνάθροισης είναι μόνο τρεις από τους άξονες σχεδιασμού, και περαιτέρω έρευνα μπορεί να αναδείξει νέες αρχιτεκτονικές που να συνδυάζουν τα πλεονεκτήματα διαφορετικών προσεγγίσεων.

Η εργασία αφήνει πίσω της ένα σύνολο από πραγματικά αποτελέσματα, μία επαναχρησιμοποιήσιμη υποδομή, και μία σειρά από ανοιχτά ερωτήματα. Ελπίζεται ότι η συνεισφορά αυτή θα αποτελέσει χρήσιμη βάση για μελλοντική έρευνα στο πεδίο της ανάκτησης πληροφορίας και της διαχείρισης γνώσης σε μεγάλη κλίμακα.

Βιβλιογραφία

[1] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, and Illia Polosukhin. Attention is all you need. *Advances in Neural Information Processing Systems*, 30, 2017.

[2] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. BERT: Pre-training of deep bidirectional transformers for language understanding. In *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (NAACL-HLT)*, pages 4171–4186, 2019.

[3] Tom B. Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, Sandhini Agarwal, Ariel Herbert-Voss, Gretchen Krueger, Tom Henighan, Rewon Child, Aditya Ramesh, Daniel M. Ziegler, Jeffrey Wu, Clemens Winter, Christopher Hesse, Mark Chen, Eric Sigler, Mateusz Litwin, Scott Gray, Benjamin Chess, Jack Clark, Christopher Berner, Sam McCandlish, Alec Radford, Ilya Sutskever, and Dario Amodei. Language models are few-shot learners. *Advances in Neural Information Processing Systems*, 33:1877–1901, 2020.

[4] Yuhong Zhang, Siqi Hao, Hongshen Xu, et al. A survey on hallucination in large language models: Principles, taxonomy, challenges, and open questions. *arXiv preprint arXiv:2311.05232*, 2023.

[5] Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Wen tau Yih, Tim Rocktäschel, Sebastian Riedel, and Douwe Kiela. Retrieval-augmented generation for knowledge-intensive NLP tasks. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 33, pages 9459–9474, 2020.

[6] Nelson F. Liu, Kevin Lin, John Hewitt, Ashwin Paranjape, Michele Bevilacqua, Fabio Petroni, and Percy Liang. Lost in the middle: How language models use long contexts. *Transactions of the Association for Computational Linguistics*, 12:157–173, 2024.

[7] Christopher D. Manning, Prabhakar Raghavan, and Hinrich Schütze. *Introduction to Information Retrieval*. Cambridge University Press, Cambridge, United Kingdom, 2008.

[8] Stephen Robertson and Hugo Zaragoza. The probabilistic relevance framework: BM25 and beyond. *Foundations and Trends in Information Retrieval*, 3(4):333–389, 2009.

[9] Justin Zobel and Alistair Moffat. Inverted files for text search engines. *ACM Computing Surveys*, 38(2):6, 2006.

[10] Vladimir Karpukhin, Barlas Oğuz, Sewon Min, Patrick Lewis, Ledell Wu, Sergey Edunov, Danqi Chen, and Wen tau Yih. Dense passage retrieval for open-domain question answering. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 6769–6781. Association for Computational Linguistics, 2020.

[11] Nils Reimers and Iryna Gurevych. Sentence-BERT: Sentence embeddings using siamese BERT-networks. In *Proceedings of EMNLP-IJCNLP*, 2019.

[12] Thibault Formal, Carlos Lassance, Benjamin Piwowarski, and Stéphane Clinchant. SPLADE v2: Sparse lexical and expansion model for information retrieval. In *arXiv preprint arXiv:2109.10086*, 2021.

[13] Jianlv Chen, Shitao Xiao, Peitian Zhang, Kun Luo, Defu Lian, and Zheng Liu. BGE M3-embedding: Multi-lingual, multi-functionality, multi-granularity text embeddings through self-knowledge distillation. *arXiv preprint arXiv:2402.03216*, 2024.

[14] Yunfan Gao, Yun Xiong, Xinyu Gao, Kangxiang Jia, Jinliu Pan, Yuxian Meng, Jie Liang, Zhiyuan Liu, Maosong Sun, and Haofen Wang. Retrieval-augmented generation for large language models: A survey. *arXiv preprint arXiv:2312.10997*, 2023.

[15] Yuxuan Chen, Daniel Röder, Justus-Jonas Erker, Leonhard Hennig, Philippe Thomas, Sebastian Möller, and Roland Roller. Retrieval-augmented knowledge integration into language models: A survey. *Proceedings of the 1st Workshop on Towards Knowledgeable Language Models (KnowLLM)*, pages 45–63, 2024.

[16] Gordon V. Cormack, Charles L.A. Clarke, and Stefan Buettcher. Reciprocal rank fusion outperforms condorcet and individual rank learning methods. In *Proceedings of SIGIR*, 2009.

[17] LlamaIndex. *LlamaIndex Documentation: Hierarchical Node Parser and Auto-Merging (Parent Document) Retriever*, 2026. Accessed: July 13, 2026.

[18] Omar Khattab and Matei Zaharia. ColBERT: Efficient and effective passage search via contextualized late interaction over BERT. In *Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval*, pages 39–48, 2020.

[19] Ziyan Jiang, Xueguang Ma, and Wenhu Chen. LongRAG: Enhancing retrieval-augmented generation with long-context LLMs. *arXiv preprint arXiv:2406.15319*, 2024.

[20] Parth Sarthi, Salman Abdullah, Aditi Tuli, Shubh Khanna, Anna Goldie, and Christopher D. Manning. RAPTOR: Recursive abstractive processing for tree-organized retrieval. In *International Conference on Learning Representations (ICLR)*, 2024.

[21] Bernal Jiménez Gutiérrez, Yiheng Shu, Yu Gu, Michihiro Yasunaga, and Yu Su. HippoRAG: Neurobiologically inspired long-term memory for large language models. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2024.

[22] Bernal Jiménez Gutiérrez, Yiheng Shu, Weijian Qi, Sizhe Zhou, and Yu Su. From RAG to memory: Non-parametric continual learning for large language models. *arXiv preprint arXiv:2502.14802*, 2025.

[23] Zirui Guo, Lianghao Xia, Yanhua Yu, Tu Ao, and Chao Huang. LightRAG: Simple and fast retrieval-augmented generation. *arXiv preprint arXiv:2410.05779*, 2024.

[24] Boyu Chen, Zirui Guo, Zidan Yang, Yuluo Chen, Junze Chen, Zhenghao Liu, Chuan Shi, and Cheng Yang. PathRAG: Pruning graph-based retrieval augmented generation with relational paths. *arXiv preprint arXiv:2502.14902*, 2025.

[25] Hongjin Qian, Zheng Liu, Peitian Zhang, Kelong Mao, Defu Lian, Zhicheng Dou, and Tiejun Huang. MemoRAG: Boosting long context processing with global memory-

enhanced retrieval augmentation. In *Proceedings of the ACM Web Conference (WWW)*, 2025.

[26] Lei Liang, Mengshu Sun, Zhengke Gui, Zhongshu Zhu, Zhouyu Jiang, Ling Zhong, Yuan Qu, Peilong Zhao, Zhongpu Bo, Jin Yang, Huaidong Xiong, Lin Yuan, Jun Xu, Zaoyang Wang, Zhiqiang Zhang, Wen Zhang, Huajun Chen, Wenguang Chen, and Jun Zhou. KAG: Boosting LLMs in professional domains via knowledge augmented generation. *arXiv preprint arXiv:2409.13731*, 2024.

[27] Huiyao Chen, Yi Yang, Yinghui Li, Meishan Zhang, and Min Zhang. DISRetrieval: Harnessing discourse structure for long document retrieval. *arXiv preprint arXiv:2506.06313*, 2025.

[28] Joongmin Shin, Gyuho Shim, Jeongbae Park, Jaehyung Seo, and Heuiseok Lim. HiKEY: Hierarchical multimodal retrieval for open-domain document question answering. In *Proceedings of the 2026 Conference of the Association for Computational Linguistics (ACL)*, 2026. arXiv:2605.29606.

[29] Michail Dadopoulos, Anestis Ladas, Stratos Moschidis, and Ioannis Negkakis. Metadata-driven retrieval-augmented generation for financial question answering. *arXiv preprint arXiv:2510.24402*, 2025.

[30] Qdrant Solutions GmbH. *Qdrant Vector Database Documentation*, 2026. Accessed: July 13, 2026.

[31] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, and Illia Polosukhin. Attention is all you need. In *Advances in Neural Information Processing Systems*, volume 30, pages 5998–6008, 2017.

[32] Tom B. Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, Sandhini Agarwal, Ariel Herbert-Voss, Gretchen Krueger, Tom Henighan, Rewon Child, Aditya Ramesh, Daniel M. Ziegler, Jeffrey Wu, Clemens Winter, Christopher Hesse, Mark Chen, Eric Sigler, Mateusz Litwin, Scott Gray, Benjamin Chess, Jack Clark, Christopher Berner, Sam McCandlish, Alec Radford, Ilya Sutskever, and Dario Amodei. Language models are few-shot learners. *Advances in Neural Information Processing Systems*, 33:1877–1901, 2020.

[33] Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Wen tau Yih, Tim Rocktäschel, Sebastian Riedel, and Douwe Kiela. Retrieval-augmented generation for knowledge-intensive NLP tasks. *Advances in Neural Information Processing Systems*, 33:9459–9474, 2020.

[34] Vladimir Karpukhin, Barlas Oğuz, Sewon Min, Patrick Lewis, Ledell Wu, Sergey Edunov, Danqi Chen, and Wen tau Yih. Dense passage retrieval for open-domain question answering. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 6769–6781. Association for Computational Linguistics, 2020.

[35] Nils Reimers and Iryna Gurevych. Sentence-BERT: Sentence embeddings using siamese BERT-networks. *Proceedings of EMNLP-IJCNLP*, 2019.

[36] Liang Wang, Nan Yang, Xiaolong Huang, Linjun Yang, Rangan Majumder, and Furu Wei. Improving text embeddings with large language models. In *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (ACL)*, 2024.

[37] Hongjin Su, Weijia Shi, Jungo Kasai, Yizhong Wang, Yushi Hu, Mari Ostendorf, Wen tau Yih, Noah A. Smith, Luke Zettlemoyer, and Tao Yu. One embedder, any task: Instruction-finetuned text embeddings. *Findings of the Association for Computational Linguistics: ACL 2023*, 2023.

[38] Akari Asai, Zeqiu Wu, Yizhong Wang, Avirup Sil, and Hannaneh Hajishirzi. Self-RAG: Learning to retrieve, generate, and critique through self-reflection. In *International Conference on Learning Representations (ICLR)*, 2024.

[39] Shi-Qi Yan, Jia-Chen Gu, Yun Zhu, and Zhen-Hua Ling. Corrective retrieval augmented generation. *arXiv preprint arXiv:2401.15884*, 2024.

[40] LangChain AI. *LangChain Python Documentation*, 2026. Accessed: July 13, 2026.

[41] Chroma Inc. *Chroma Core Documentation*, 2026. Accessed: July 13, 2026.

[42] Jeff Johnson, Matthijs Douze, and Hervé Jégou. Billion-scale similarity search with GPUs. *IEEE Transactions on Big Data*, 7(3):535–547, 2019.

[43] Ilias Chalkidis, Manos Fergadiotis, Prodromos Malakasiotis, Nikolaos Aletras, and Ion Androutsopoulos. LEGAL-BERT: The muppets straight out of law school. In *Findings of the Association for Computational Linguistics: EMNLP 2020*, pages 2898–2904. Association for Computational Linguistics, 2020.

[44] Ilias Chalkidis, Abhik Jana, Dirk Hartung, Michael Bommarito, Ion Androutsopoulos, Daniel Martin Katz, and Nikolaos Aletras. LexGLUE: A benchmark dataset for legal language understanding in english. In *Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (ACL)*, 2022.

[45] Lucia Zheng, Neel Guha, Brandon R. Anderson, Peter Henderson, and Daniel E. Ho. When does pretraining help? assessing self-supervised learning for law and the CaseHOLD dataset of 53,000+ legal holdings. In *Proceedings of the Eighteenth International Conference on Artificial Intelligence and Law (ICAIL)*, pages 159–168, 2021.

[46] Dan Hendrycks, Collin Burns, Anya Chen, and Spencer Ball. CUAD: An expert-annotated NLP dataset for legal contract review. In *Proceedings of the Neural Information Processing Systems Track on Datasets and Benchmarks*, volume 1, 2021.

[47] Microsoft. Graphrag documentation, 2026. Accessed: July 13, 2026.

[48] Microsoft. Graphrag github repository, 2026. Accessed: July 13, 2026.

[49] Python Software Foundation. *Python 3 Documentation*, 2026. Accessed: July 13, 2026.

[50] Hugging Face. *Hugging Face Official Documentation*, 2026. Accessed: July 13, 2026.

[51] Nils Reimers and Iryna Gurevych. *Sentence-Transformers Documentation*, 2026. Accessed: July 13, 2026.

[52] Ollama. *Ollama Documentation*, 2026. Accessed: July 13, 2026.

[53] Docker Inc. *Docker Engine Documentation*, 2026. Accessed: July 13, 2026.

[54] OpenAI. *OpenAI API Documentation*. OpenAI, v6.0 / responses api edition, 2026. Available at `https://developers.openai.com/api/docs`. Accessed: July 13, 2026.

[55] Yunfan Gao, Yun Xiong, Xinyu Gao, Kangxiang Jia, Jinliu Pan, Yuxi Bi, Yi Dai, Jiawei Sun, Meng Wang, and Haofen Wang. Retrieval-augmented generation for large language models: A survey. *arXiv preprint arXiv:2312.10997*, 2023.

[56] Qinggang Zhang, Shengyuan Chen, Yuanchen Bei, Zheng Yuan, Huachi Zhou, Zijin Hong, Hao Chen, Yilin Xiao, Chuang Zhou, Junnan Dong, Yi Chang, and Xiao Huang. A survey of graph retrieval-augmented generation for customized large language models. *arXiv preprint arXiv:2501.13958*, 2025.

[57] Stephen Robertson and Hugo Zaragoza. The probabilistic relevance framework: BM25 and beyond. *Foundations and Trends in Information Retrieval*, 3(4):333–389, 2009.

[58] Luyu Gao, Xueguang Ma, Jimmy Lin, and Jamie Callan. Precise zero-shot dense retrieval without relevance labels. In *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (ACL)*, 2023.

[59] Ziwei Ji, Nayeon Lee, Rita Frieske, Tiezheng Yu, Dan Su, Yan Xu, Etsuko Ishii, Yejin Bang, Delong Chen, Wenliang Dai, Ho Shu Chan, Andrea Madotto, and Pascale Fung. Survey of hallucination in natural language generation. *ACM Computing Surveys*, 55(12):1–38, 2023.

[60] Gordon V. Cormack, Charles L. A. Clarke, and Stefan Buettcher. Reciprocal rank fusion outperforms condorcet and individual rank learning methods. In *Proceedings of the 32nd International ACM SIGIR Conference on Research and Development in Information Retrieval*, pages 758–759, 2009.

[61] Β. Πίσχος and S. Πατακιούτης. Semantic search in legal data, 2025. Undergraduate Thesis, Department of Electrical and Computer Engineering, University of Thessaly.

[62] Junkang Chen, Shitao Xiao, Zheng Liu, Peitian Zhang, Kun Luo, and Defu Lian. BGE M3-embedding: Multi-lingual, multi-functionality, multi-granularity text embeddings through self-knowledge distillation. *arXiv preprint arXiv:2402.03216*, 2024.

[63] Christopher D. Manning, Prabhakar Raghavan, and Hinrich Schütze. *Introduction to Information Retrieval*. Cambridge University Press, 2008.

[64] Bhaskarjit Sarmah, Dhagash Mehta, Benika Hall, Rohan Rao, Sunil Patel, and Stefano Pasquali. HybridRAG: Integrating knowledge graphs and vector retrieval augmented

generation for efficient information extraction. In *Proceedings of the 5th ACM International Conference on AI in Finance (ICAIF)*, 2024.

[65] Yuxuan Chen, Daniel Röder, Justus-Jonas Erker, Leonhard Hennig, Philippe Thomas, Sebastian Möller, and Roland Roller. Retrieval-augmented knowledge integration into language models: A survey. In *Proceedings of the 1st Workshop on Towards Knowledgeable Language Models (KnowLLM)*, pages 45–63, 2024.

[66] Hai Toan Nguyen, Tien Dat Nguyen, and Viet Ha Nguyen. Enhancing retrieval augmented generation with hierarchical text segmentation chunking. *arXiv preprint arXiv:2507.09935*, 2025.

[67] Rishi Kalra, Zekun Wu, Ayesha Gulley, Airlie Hilliard, Xin Guan, Adriano Koshiyama, and Philip Treleaven. HyPA-RAG: A hybrid parameter adaptive retrieval-augmented generation system for AI legal and policy applications. In *Proceedings of the 1st Workshop on Customizable NLP (CustomNLP4U)*, 2024. Also presented at NAACL 2025 Industry Track.

[68] Justin Ho, Alexandra Colby, and William Fisher. Incorporating legal structure in retrieval-augmented generation: A case study on copyright fair use. *arXiv preprint arXiv:2505.02164*, 2025.

[69] Qingfei Zhao, Ruobing Wang, Yukuo Cen, Daren Zha, Shicheng Tan, Yuxiao Dong, and Jie Tang. LongRAG: A dual-perspective retrieval-augmented generation paradigm for long-context question answering. In *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 22600–22632, Miami, Florida, USA, 2024. Association for Computational Linguistics.

[70] Rakshita Goel, S Pranav Kumar, Anmol Agrawal, Divyan Poddar, Pratik Narang, and Dhruv Kumar. Domain-partitioned hybrid RAG for legal reasoning: Toward modular and explainable legal AI for india. *arXiv preprint arXiv:2602.23371*, 2025. Useful parallel for hybrid dense+sparse + structured legal retrieval.

[71] Huiyao Chen, Yi Yang, Yinghui Li, Meishan Zhang, and Min Zhang. DISRetrieval: Harnessing discourse structure for long document retrieval. *arXiv preprint arXiv:2506.06313*, 2025.

[72] Haoyu Huang, Yongfeng Huang, Junjie Yang, Zhenyu Pan, Yongqiang Chen, Kaili Ma, Hongzhi Chen, and James Cheng. Retrieval-augmented generation with hierarchical knowledge. *Findings of the Association for Computational Linguistics: EMNLP 2025*, 2025.

ΠΑΡΑΡΤΗΜΑΤΑ

Παράρτημα Α

Αρχιτεκτονικές που δεν Εκτελέστηκαν

Στο παρόν παράρτημα τεκμηριώνονται οι αρχιτεκτονικές αναφοράς που δεν κατέστη δυνατό να εκτελεστούν στο πλαίσιο της παρούσας εργασίας. Η τεκμηρίωση είναι απαραίτητη για δύο λόγους. Πρώτον, οριοθετεί ρητά το εύρος της συγκριτικής μελέτης του Κεφαλαίου 6 και αποτρέπει τη σιωπηλή υπεργενίκευση των συμπερασμάτων. Δεύτερον, καταγράφει με ακρίβεια τους λόγους αποκλεισμού, ώστε η εξαίρεση να είναι επαναλήψιμη από οποιονδήποτε αναγνώστη και να μην αποτελεί προϊόν αυθαίρετης επιλογής.

Α.1 Σύνοψη Αποκλεισμών

Ο Πίνακας Α.1 συνοψίζει την κατάσταση κάθε αρχιτεκτονικής.

Α.2 Αναλυτική Τεκμηρίωση

Α.2.1 HippoRAG 2

Η αρχιτεκτονική απαιτεί εξαγωγή πληροφορίας με LLM (named-entity recognition και triple extraction) σε κάθε chunk του corpus κατά το indexing. Για τα τέσσερα σύνολα δεδομένων της παρούσας εργασίας, ο συνολικός αριθμός κλήσεων API ανέρχεται σε περίπου $95\,041$. Δεδομένου ότι δεν υπήρχε διαθέσιμος προϋπολογισμός για hosted LLM API, και δεδομένου ότι η αντικατάσταση του OpenIE σταδίου με κανόνες θα μετέτρεπε την αρχιτεκτονική σε διαφορετικό σύστημα, η αρχιτεκτονική αποκλείστηκε. Η υλοποίηση ολοκληρώθηκε και επικυρώθηκε σε synthetic fixtures, αλλά δεν εκτελέστηκε σε πραγματικά δεδομένα.

A.2.2 RAPTOR

Η αρχιτεκτονική απαιτεί παραγωγή περίληψης από LLM για κάθε cluster σε κάθε επίπεδο του αναδρομικού δέντρου. Ο συνολικός αριθμός κλήσεων για τα τέσσερα σύνολα ανέρχεται σε περίπου $10\,558$. Όπως και στην περίπτωση του HippoRAG 2, η αντικατάσταση του summarization σταδίου θα αλλοίωνε την αρχιτεκτονική, και ο απαιτούμενος προϋπολογισμός API δεν ήταν διαθέσιμος. Η υλοποίηση ολοκληρώθηκε, συμπεριλαμβανομένης της προετοιμασίας ενός Qwen2.5-1.5B-Instruct τοπικού summarizer, αλλά δεν εκτελέστηκε σε πραγματικά δεδομένα.

A.2.3 LightRAG

Η αρχιτεκτονική απαιτεί εξαγωγή οντοτήτων και σχέσεων από LLM για κάθε chunk. Από τις τρεις graph-based αρχιτεκτονικές, παρουσιάζει το υψηλότερο κόστος indexing, με περίπου $119\,561$ κλήσεις API για τα τέσσερα σύνολα. Η αρχιτεκτονική αποκλείστηκε για τους ίδιους λόγους με τις δύο προηγούμενες.

A.2.4 DISRetrieval

Το αποθετήριο της αρχιτεκτονικής δεν φέρει άδεια χρήσης (LICENSE file). Ο architecture-defining neural RST parser, ο οποίος αποτελεί τον πυρήνα της καινοτομίας του paper, δεν μπορεί να εκτελεστεί, να εισαχθεί, να τροποποιηθεί ή να αναδιανεμηθεί υπό τις προεπιλεγμένες συνθήκες πνευματικής ιδιοκτησίας. Η αντικατάστασή του με heuristic ή με γενικό constituency parser θα μετέτρεπε την αρχιτεκτονική σε διαφορετικό σύστημα, παραβιάζοντας την αρχή της αρχιτεκτονικής ακεραιότητας. Η αρχιτεκτονική αναβλήθηκε με ρητό λόγο.

A.2.5 HiKEY

Η αρχιτεκτονική απαιτεί multimodal εισόδους (PDF, πίνακες, εικόνες, layout πληροφορία) και δεν διαθέτει δημόσιο αποθετήριο. Το canonical envelope της παρούσας εργασίας είναι text-only, και η προσαρμογή του σε multimodal θα απαιτούσε επανασχεδιασμό της εισόδου που ξεπερνά το πεδίο της εργασίας. Η αρχιτεκτονική αποκλείστηκε λόγω ασυμβατότητας του input contract.

A.3 Μεθοδολογική Σημείωση

Η εξαίρεση των παραπάνω αρχιτεκτονικών δεν αποτελεί αδυναμία της σύγκρισης. Η συμπερίληψη αρχιτεκτονικών που δεν μπορούν να εκτελεστούν δίκαια θα ήταν μεθοδολογικά χειρότερη από την εξαίρεσή τους με ρητή τεκμηρίωση. Οι λόγοι εξαίρεσης είναι επαληθεύσιμοι από οποιονδήποτε αναγνώστη:

- Το κόστος LLM API είναι μετρήσιμο και ανεξάρτητο από την υλοποίηση.
- Η απουσία άδειας χρήσης είναι αντικειμενικό γεγονός που επαληθεύεται στο αποθετήριο.
- Η ασυμβατότητα εισόδου είναι δομική και δεν εξαρτάται από υποκειμενικές εκτιμήσεις.

Η εξαίρεση αυξάνει την εσωτερική εγκυρότητα της σύγκρισης που πραγματοποιήθηκε: οι αρχιτεκτονικές που συμμετείχαν μοιράζονται το ίδιο canonical envelope, τον ίδιο embedder, τα ίδια ερωτήματα, τις ίδιες μετρικές και το ίδιο συμβόλαιο αξιολόγησης. Τυχόν μελλοντική επέκταση της σύγκρισης με τις εξαιρεθείσες αρχιτεκτονικές θα απαιτούσε πόρους και συνθήκες που τεκμηριώνονται στα αντίστοιχα reports που διατηρούνται στο αποθετήριο του έργου.

Πίνακας Α.1: Αρχιτεκτονικές που δεν εκτελέστηκαν και αιτιολόγηση.

Αρχιτεκτονική	**Κατάσταση**	**Λόγος**	**Επίπτωση στα συμπεράσματα**
HippoRAG 2 [22]	Αποκλείστηκε	Απαιτεί LLM στο στάδιο OpenIE κατά το indexing· το συνολικό κόστος ξεπερνά τις 95 000 κλήσεις API ανά σύνολο, μη βιώσιμο στο διαθέσιμο προϋπολογισμό	Καμία σύγκριση με την native αρχιτεκτονική. Οι ισχυρισμοί για multi-hop graph retrieval παραμένουν ανεξέλεγκτοι.
RAPTOR [20]	Αποκλείστηκε	Απαιτεί LLM σε κάθε επίπεδο του δέντρου περιλήψεων· οι κλήσεις ξεπερνούν τις 10 000 ανά σύνολο	Καμία σύγκριση. Ο ισχυρισμός περί πολυεπίπεδης αφαίρεσης δεν επαληθεύεται εμπειρικά.
LightRAG [23]	Αποκλείστηκε	Απαιτεί LLM για entity και relation extraction· οι κλήσεις ξεπερνούν τις 119 000 ανά σύνολο	Καμία σύγκριση. Ο ισχυρισμός περί dual-level graph retrieval δεν επαληθεύεται.
DISRetrieval [27]	Αναβλήθηκε	Ο architecture-defining neural RST parser δεν φέρει άδεια χρήσης στο αποθετήριο· η αντικατάστασή του θα άλλαζε την αρχιτεκτονική	Καμία σύγκριση. Η αρχιτεκτονική διατηρείται ως αναφορά.
HiKEY [28]	Αποκλείστηκε	Απαιτεί multimodal εισόδους (PDF, πίνακες, εικόνες, layout)· το canonical envelope είναι text-only	Καμία σύγκριση. Η αρχιτεκτονική δεν είναι συγκρίσιμη στο παρόν corpus.

Παράρτημα Β

Πόροι, Δεδομένα και Κώδικας

Στο παρόν παράρτημα συγκεντρώνονται οι εξωτερικοί πόροι που χρησιμοποιήθηκαν ή παρήχθησαν στο πλαίσιο της παρούσας εργασίας. Σκοπός είναι η διευκόλυνση της αναπαραγωγής των αποτελεσμάτων από μελλοντικούς ερευνητές.

Β.1 Σύνολα Δεδομένων

Τα σύνολα δεδομένων που χρησιμοποιήθηκαν έχουν κανονικοποιηθεί στο ενιαίο canonical envelope που περιγράφεται στην Ενότητα 4.1 και είναι διαθέσιμα στο ακόλουθο αποθετήριο:

- **Αποθετήριο canonical dataset suite**: `https://github.com/npaidopl/canonical-rag-dataset-suite`

Το αποθετήριο περιλαμβάνει τα τέσσερα σύνολα που χρησιμοποιήθηκαν στην εργασία:

- **LaRA** (Long-context Retrieval Assessment)
- **CLERC** (CLERC Legal Retrieval)
- **CUAD** (Contract Understanding Atticus Dataset)
- **GreekBarBench**

Κάθε σύνολο περιλαμβάνει τα αρχεία `documents.jsonl`, `examples.jsonl`, `validation.json` και `manifest.json`, με SHA-256 checksums για όλα τα αρχεία. Αναλυτική περιγραφή των συνόλων παρέχεται στην Ενότητα 4.1.

Β.2 Κώδικας και Τεκμηρίωση

Ο κώδικας της προτεινόμενης αρχιτεκτονικής, καθώς και τα scripts που χρησιμοποιήθηκαν για την εκτέλεση των πειραμάτων και την αξιολόγηση, είναι διαθέσιμα στο ακόλουθο αποθετήριο:

- **Αποθετήριο έργου**: `https://github.com/npaidopl/sah-rag`
- **Έκδοση**: `v1.0.0`
- **Τελικό commit**: `4e52d47`

Το αποθετήριο περιλαμβάνει:

- Τον πηγαίο κώδικα της αρχιτεκτονικής, οργανωμένο στα υποπακέτα `canonical`, `parsing`, `chunking`, `embedding`, `storage`, `retrieval`, `evaluation` και `artifacts`.
- Τα παγωμένα συμβόλαια των πειραμάτων (`baseline_audit/*.yaml`).
- Τα scripts εκτέλεσης (`scripts/run_*.py`).
- Τα manifests και τα checksums όλων των παραγόμενων τεχνουργημάτων.
- Το σύνολο δοκιμών (unit tests, integration tests, synthetic acceptance).

Β.3 Αναπαραγωγιμότητα

Για την αναπαραγωγή των αποτελεσμάτων απαιτούνται:

- Python 3.12.10 ή νεότερη έκδοση.
- Το μοντέλο `BAAI/bge-m3` στο revision `5617a9f61b028005a4858fdac845db406aefb181`.
- Πρόσβαση σε GPU για την παραγωγή embeddings, κατά προτίμηση NVIDIA T4 ή ισοδύναμη.
- Περίπου 15 GB ελεύθερου χώρου αποθήκευσης για τα ενδιάμεσα τεχνουργήματα.

Η πλήρης ακολουθία εκτέλεσης, οι παράμετροι και τα αναμενόμενα αποτελέσματα τεκμηριώνονται στα αρχεία τεκμηρίωσης του αποθετηρίου. Όλα τα στάδια είναι ντετερμινιστικά δεδομένων των εισόδων τους, και κάθε στάδιο επικυρώνει τα SHA-256 των εισόδων του πριν εκτελεστεί.